# Calidad, Estadística y preprocesamientos de Datos

*Exploración, Preprocesamiento de datos*

## De la exploración a la calidad de datos

En la unidad anterior aprendimos a realizar una primera exploración de un conjunto de datos utilizando NumPy y Pandas. Pudimos conocer sus dimensiones, observar registros, identificar tipos de variables, calcular estadísticas básicas, realizar filtros y comenzar a detectar valores faltantes. Sin embargo, explorar un dataset no significa todavía que estemos en condiciones de utilizarlo para entrenar un modelo de Machine Learning. Conocer qué contiene un conjunto de datos es solamente el primer paso; el siguiente consiste en determinar si aquello que contiene puede considerarse confiable para el problema que queremos resolver.

Esta distinción es fundamental porque un modelo de aprendizaje automático no tiene la capacidad de comprender, por sí mismo, si los datos que recibe son razonables desde el punto de vista del problema. El algoritmo trabaja con los valores que le proporcionamos y encuentra relaciones dentro de ellos de acuerdo con el procedimiento para el cual fue diseñado. Si una variable contiene errores, categorías inconsistentes, valores imposibles o mediciones realizadas con escalas diferentes, el modelo puede incorporar esas características como si fueran información válida.

Por eso, antes de hablar nuevamente de algoritmos, debemos introducir una pregunta mucho más importante:

***¿Qué significa que nuestros datos sean de calidad?***

No existe una respuesta completamente independiente del problema. Un valor puede parecer extraño y, sin embargo, ser correcto. Otro puede encontrarse dentro de un rango aparentemente normal y ser incorrecto. La calidad de los datos no depende únicamente de que los números «se vean bien», sino de que sean coherentes con aquello que representan y con el propósito para el cual serán utilizados.

Imaginemos que en nuestro dataset de comercio electrónico encontramos un cliente de 17 años que realizó 45 compras durante el último mes. A primera vista, 45 compras podría parecernos un valor extremadamente elevado. Sin embargo, no podemos afirmar que sea un error solamente por ser poco frecuente: podría tratarse de un cliente particularmente activo, de una cuenta utilizada por varias personas o de un usuario que realiza compras pequeñas con mucha frecuencia. El valor merece ser investigado, pero no necesariamente eliminado.

En cambio, si encontramos una edad de 247 años, la situación es diferente: existe una razón mucho más fuerte para sospechar que estamos frente a un problema de calidad. La diferencia importante entre ambos casos no es simplemente que uno sea grande y otro todavía más grande, sino que en el segundo caso tenemos conocimiento del dominio que nos permite establecer que el valor es incompatible con el significado de la variable.

Esta idea va a acompañarnos durante toda la clase:

***Detectar un problema no significa haber decidido todavía cómo solucionarlo.***

**Los datos y las variables**

Para poder hablar de calidad necesitamos primero comprender con precisión qué estamos analizando. Un dataset puede entenderse como un conjunto de observaciones sobre determinados elementos de interés. En nuestro proyecto, una observación podría corresponder a una compra, a un cliente, a una interacción o a un producto, dependiendo de cómo hayamos construido la tabla.

Cada observación está caracterizada por diferentes variables. Si tenemos una tabla en la que cada fila representa una compra, podríamos tener variables como fecha, cliente, producto, cantidad, precio, categoría y método de pago. Si, en cambio, cada fila representa un cliente, las variables podrían ser edad, cantidad de compras, gasto acumulado, frecuencia de compra y categoría preferida.

Esta diferencia es mucho más importante de lo que parece: una misma columna puede tener un significado completamente diferente dependiendo de qué representa una fila. «Gasto» puede significar el importe de una única compra o el gasto acumulado de un cliente. Antes de analizar los valores necesitamos conocer qué representa cada registro y qué significa cada variable.

Por esta razón, cuando trabajamos con datos no debemos pensar solamente en una tabla formada por números y textos. Una tabla representa una determinada visión de la realidad, y la calidad del análisis dependerá también de que esa representación sea adecuada para el problema que queremos resolver.

Podemos formalizar esta idea considerando un conjunto de observaciones:

$$D = \{ x_1, x_2, \dots, x_n \}$$

donde cada observación $x_i$ está formada por un conjunto de variables:

$$x_i = ( x_{i1}, x_{i2}, \dots, x_{ip} )$$

En términos prácticos, si tenemos 5.000 clientes y 10 variables por cliente, tendremos 5.000 observaciones y 10 características para cada observación.

Esta representación será especialmente importante cuando lleguemos al entrenamiento de modelos: allí hablaremos de features, es decir, variables utilizadas como información de entrada para el modelo, y de target, que será la variable que queremos predecir cuando trabajemos con aprendizaje supervisado. Pero antes de llegar a ese punto necesitamos conocer mejor la naturaleza de nuestras variables.

## Tipos de variables

No todas las variables representan información del mismo tipo. Una primera distinción fundamental consiste en separar las variables numéricas de las categóricas.

Una variable numérica representa una cantidad que puede ser utilizada en operaciones matemáticas. La edad, el precio, la cantidad de productos comprados o el monto total gastado son ejemplos de este tipo.

Dentro de las variables numéricas podemos distinguir entre variables discretas y continuas. Una variable discreta toma valores que podemos contar: la cantidad de compras de un cliente, por ejemplo, puede ser 0, 1, 2, 3, etc., pero no tiene sentido hablar de 2,37 compras. En cambio, el precio de un producto puede tomar valores dentro de un intervalo mucho más amplio y puede considerarse una variable continua, aunque en la práctica pueda estar registrada con una determinada precisión.

Las variables categóricas representan categorías o grupos. Una variable como «medio de pago» podría contener valores como tarjeta, transferencia o efectivo. No tendría sentido calcular el promedio de esas categorías asignándoles arbitrariamente los valores 1, 2 y 3, porque esos números no representan cantidades.

También encontramos variables binarias, que solamente poseen dos estados posibles, por ejemplo:

```
compró      →  sí / no

suscripto   →  1 / 0
```

Las variables binarias son particularmente frecuentes en problemas de clasificación.

La distinción entre estos tipos de variables no es simplemente académica: determinadas operaciones estadísticas tienen sentido para algunas variables y no para otras, y muchos algoritmos requieren que las variables sean representadas numéricamente antes de poder utilizarlas. Por ejemplo, si tenemos:

```
categoría = Ropa

categoría = Electrónica

categoría = Hogar
```

no podemos asumir que «Electrónica» es mayor que «Ropa» ni que «Hogar» está a una distancia determinada de las otras categorías. La representación numérica que utilicemos posteriormente tendrá que respetar la naturaleza de la variable.

## Población y muestra

Otra distinción importante cuando trabajamos con datos es la existente entre población y muestra.

La población es el conjunto completo de elementos sobre los cuales queremos obtener información. Supongamos que una empresa quiere analizar el comportamiento de todos sus clientes durante un año: esa totalidad constituye la población de interés.

En muchos casos, sin embargo, trabajar con toda la población puede ser difícil, costoso o directamente imposible. Entonces podemos trabajar con una muestra, es decir, un subconjunto de esa población.

La estadística nos permite utilizar información obtenida de una muestra para intentar comprender determinadas características de la población. Esto introduce una cuestión importante: la muestra debe ser suficientemente representativa para que nuestras conclusiones tengan sentido.

Si queremos conocer el comportamiento de los clientes de un comercio y analizamos únicamente a los diez clientes que más compraron, podemos calcular estadísticas perfectamente correctas sobre esos diez clientes, pero probablemente no podamos generalizar esos resultados a todos los clientes.

Esta cuestión se conecta directamente con Machine Learning. Cuando más adelante dividamos los datos en conjuntos de entrenamiento, validación y prueba, estaremos trabajando también con subconjuntos de información que cumplen funciones diferentes. Por eso es importante empezar desde ahora a comprender que un conjunto de datos no es simplemente una colección arbitraria de filas.

## Estadística descriptiva

Una vez que conocemos nuestras variables podemos utilizar la estadística descriptiva para resumir el comportamiento de los datos.

La estadística descriptiva no intenta necesariamente explicar por qué ocurre algo: su objetivo inicial es ayudarnos a describir qué está ocurriendo en nuestros datos. Para ello utilizamos medidas como la media, la mediana, la moda, la varianza, la desviación estándar, los percentiles y el rango. Estas medidas permiten reducir grandes cantidades de información a valores que nos ayudan a interpretar la distribución de una variable.

Supongamos que tenemos los siguientes gastos mensuales de cinco clientes:

$$100,\ 120,\ 130,\ 150,\ 500$$

La media se obtiene sumando todos los valores y dividiendo por la cantidad de observaciones:

$$\bar{x} = (100 + 120 + 130 + 150 + 500) / 5 = 200$$

El promedio es 200. Sin embargo, observemos los datos: cuatro de los cinco clientes gastan entre 100 y 150, mientras que uno gasta 500. El promedio de 200 puede dar la impresión de que un gasto de aproximadamente 200 es representativo, pero si miramos la distribución vemos que la mayoría de los valores está bastante por debajo.

Aquí aparece la importancia de la mediana. Ordenados, los mismos datos tienen mediana 130:

$$\text{media} = 200 \qquad \text{mediana} = 130$$

La diferencia nos está dando información: el valor extremo de 500 está desplazando la media hacia arriba, mientras que la mediana permanece mucho más cerca del centro de la mayoría de los datos. Por eso no deberíamos interpretar una variable mirando únicamente su promedio.

## Media, mediana y moda

La media aritmética es probablemente la medida de tendencia central más conocida. Se calcula sumando los valores y dividiendo por la cantidad de observaciones. Es muy útil cuando los datos no presentan comportamientos extremos que distorsionen significativamente el resultado.

La mediana es el valor que ocupa la posición central cuando los datos están ordenados. Resulta especialmente útil cuando existen valores extremos o cuando la distribución es asimétrica.

La moda, por su parte, representa el valor o categoría que aparece con mayor frecuencia. En una variable categórica como «método de pago», la moda puede resultar más significativa que la media, porque no tendría sentido calcular un promedio entre categorías. Por ejemplo, si observamos:

Tarjeta, Tarjeta, Transferencia, Tarjeta, Efectivo

la moda es «Tarjeta»: esto nos permite conocer cuál es la categoría más frecuente.

La elección de una medida estadística depende, por lo tanto, del tipo de variable y de la pregunta que queremos responder.

## Variabilidad: varianza y desviación estandar

Conocer el promedio de una variable no nos indica cuánto se dispersan los datos alrededor de ese promedio. Supongamos dos grupos de estudiantes que obtienen los siguientes resultados:

Grupo A: 48, 49, 50, 51, 52

Grupo B: 10, 30, 50, 70, 90

Ambos grupos tienen una media de 50. Sin embargo, claramente no se comportan de la misma manera: en el Grupo A los valores están muy próximos entre sí, mientras que en el Grupo B están mucho más separados.

Para cuantificar esta dispersión podemos utilizar la varianza y la desviación estándar. La varianza mide, en términos generales, cuánto se alejan los valores respecto de la media considerando el cuadrado de esas diferencias. La desviación estándar corresponde a la raíz cuadrada de la varianza y tiene la ventaja de expresarse en las mismas unidades que la variable original.

Si analizamos una variable de gasto expresada en pesos, una desviación estándar también estará expresada en pesos. Esto resulta útil porque nos permite interpretar aproximadamente cuánto se dispersan los valores respecto del promedio.

No necesitamos memorizar únicamente las fórmulas: lo importante es comprender qué pregunta responde cada medida.

- *¿Cuál es el centro promedio de los datos?* → *responde la media*
- *¿Qué tan dispersos están los datos alrededor de ese centro?* → *responde la desviación estándar*

## Percentiles y cuartiles

Los percentiles nos permiten observar la posición relativa de los datos dentro de una distribución.

El percentil 50 coincide con la mediana. El percentil 25 indica que aproximadamente el 25 % de las observaciones se encuentra por debajo de ese valor, mientras que el percentil 75 indica que aproximadamente el 75 % se encuentra por debajo.

Estos dos valores reciben especial importancia porque permiten definir los cuartiles:

$$Q_1 = P_{25} \qquad Q_2 = P_{50} \qquad Q_3 = P_{75}$$

Entre $Q_1$ y $Q_3$ se encuentra el 50 % central de los datos. La distancia entre ambos se denomina rango intercuartílico, o IQR:

$$IQR = Q_3 - Q_1$$

Esta medida tendrá un papel fundamental cuando estudiemos los outliers.

## Distribución y rango

El rango de una variable puede obtenerse mediante la diferencia entre el valor máximo y el mínimo. Es una medida sencilla y fácil de interpretar, pero tiene una limitación importante: depende exclusivamente de los extremos.

$$Rango = x_{max} - x_i$$

Si tenemos los valores 100, 110, 120, 130 y 500, el rango es:

$$500 - 100 = 400$$

Pero ese valor no nos dice cómo están distribuidos los valores intermedios. Por eso el análisis estadístico necesita combinar diferentes medidas: el rango, la mediana, los percentiles y la desviación estándar proporcionan perspectivas diferentes sobre los mismos datos.

En Machine Learning esto resulta especialmente importante porque muchos algoritmos pueden verse afectados por la distribución de las variables. No alcanza con saber que una columna contiene valores numéricos: necesitamos comprender cómo se distribuyen.

## Correlación

Una de las preguntas que podemos formular durante el análisis exploratorio es si dos variables presentan algún tipo de relación. Por ejemplo, podríamos preguntarnos si existe una relación entre la cantidad de compras de un cliente y su gasto total. Una herramienta habitual para estudiar este tipo de relación es la correlación.

Una correlación positiva significa, en términos generales, que cuando una variable aumenta la otra tiende también a aumentar. Una correlación negativa indica que cuando una aumenta, la otra tiende a disminuir. El coeficiente de correlación suele expresarse en un intervalo entre -1 y 1.

Un valor cercano a 1 indica una relación lineal positiva fuerte, mientras que un valor cercano a -1 indica una relación lineal negativa fuerte. Un valor cercano a 0 indica que no observamos una relación lineal fuerte entre las variables.

***Correlación no implica causalidad.***

Si observamos que dos variables están correlacionadas, no podemos concluir automáticamente que una sea la causa de la otra.

Supongamos que durante determinados meses aumentan tanto las ventas de un comercio como el uso de una determinada aplicación móvil: podrían estar correlacionados, pero eso no demuestra que el aumento del uso de la aplicación sea la causa del incremento de ventas. Puede existir una tercera variable, como una campaña publicitaria, una fecha especial o un cambio estacional, que explique ambos fenómenos.

Esta diferencia entre asociación y causalidad es fundamental para interpretar correctamente los resultados de un análisis de datos.

## Calidad de los datos

Una vez comprendidos los conceptos estadísticos básicos podemos volver al problema central de la clase: la calidad.

Un dataset puede presentar diferentes tipos de problemas. Algunos son evidentes, como valores faltantes; otros requieren análisis estadístico; otros dependen de reglas del dominio. Entre los problemas más habituales encontramos duplicados, valores faltantes, inconsistencias de formato, categorías escritas de diferentes maneras, valores fuera de rango y datos que no respetan las restricciones lógicas de la variable.

Consideremos una columna denominada edad. Podemos encontrar:

```
22, 35, 41, NaN, 29, 250
```

Aquí tenemos al menos dos cuestiones diferentes: NaN representa un valor faltante, mientras que 250 representa un valor que parece incompatible con el significado de la variable.

No debemos tratar ambos problemas de la misma manera. Uno representa ausencia de información; el otro puede representar un error o un caso excepcional. Esta diferencia parece sencilla, pero es una de las ideas más importantes de esta unidad.

## Duplicados e inconsistencias

Otro problema habitual aparece cuando existen registros duplicados. Supongamos que una compra aparece dos veces exactamente igual:

Cliente A | Producto X | $50.000 | 10/05/2026

Cliente A | Producto X | $50.000 | 10/05/2026

Podría tratarse de un registro duplicado, pero tampoco debemos asumirlo automáticamente: es posible que el cliente haya realizado realmente dos compras idénticas.

Para determinarlo necesitamos comprender qué identifica de manera única una transacción. Si existe un identificador de compra y observamos que el mismo identificador aparece dos veces, la sospecha de duplicación es mucho más fuerte. Esto vuelve a mostrar que la limpieza de datos no consiste simplemente en aplicar funciones: necesitamos conocer la semántica del dataset.

Algo similar ocurre con las categorías:

Ropa, ropa, ROPA, Ropa

Desde una perspectiva humana probablemente representan la misma categoría; para una computadora, en cambio, son cadenas diferentes. Por eso una etapa de limpieza puede incluir normalización de texto, eliminación de espacios innecesarios y unificación de formatos.

## Valores imposibles y valores extremos

Ahora podemos introducir una distinción que será fundamental:

***Un valor extremo no necesariamente es un error.***

Un outlier es una observación que se encuentra significativamente alejada del comportamiento general de los datos. Pero que sea poco frecuente no significa que sea incorrecta.

Supongamos que una tienda normalmente registra compras entre 10.000 y 100.000 pesos, pero aparece una compra de 2.000.000. Ese valor merece investigación: podría tratarse de un error de carga —

2 000 000 → debía registrarse como → 200 000

— pero también podría ser una compra completamente legítima de una empresa que adquirió una gran cantidad de productos. Eliminarla automáticamente sería un error.

Por eso debemos diferenciar el outlier estadístico del error de datos. Un outlier es una observación que se comporta de manera inusual respecto del resto; un error es una observación cuyo valor no representa correctamente la realidad que debería representar. Pueden coincidir, pero no son sinónimos.

## Detección de outliers mediante IQR

Una de las técnicas más utilizadas para detectar valores extremos utiliza el rango intercuartílico. Recordemos:

$$IQR = Q_3 - Q_1$$

La regla habitual considera potencialmente extremos aquellos valores que se encuentran por debajo de:

$$Q_1 - 1.5\ (IQR)$$

o por encima de:

$$Q_3 + 1.5\ (IQR)$$

Esta regla no afirma que esos valores sean errores: simplemente permite identificarlos como observaciones que merecen atención. Supongamos que tenemos:

$$Q_1 = 100 \qquad Q_3 = 200$$

Entonces:

$$IQR = 200 - 100 = 100$$

El límite inferior sería:

$$100 - 1.5\ (100) = -50$$

y el superior:

$$200 + 1.5\ (100) = 350$$

Por lo tanto, un valor de 500 sería considerado potencialmente extremo según esta regla. Pero nuevamente debemos preguntarnos qué representa ese 500.

***La estadística nos ayuda a detectar. El conocimiento del problema nos ayuda a decidir.***

## Boxplot

Una herramienta gráfica muy utilizada para visualizar este comportamiento es el boxplot o diagrama de caja. El boxplot permite representar de manera compacta los cuartiles, la mediana y valores que aparecen alejados del comportamiento central. Conceptualmente podemos imaginarlo así:

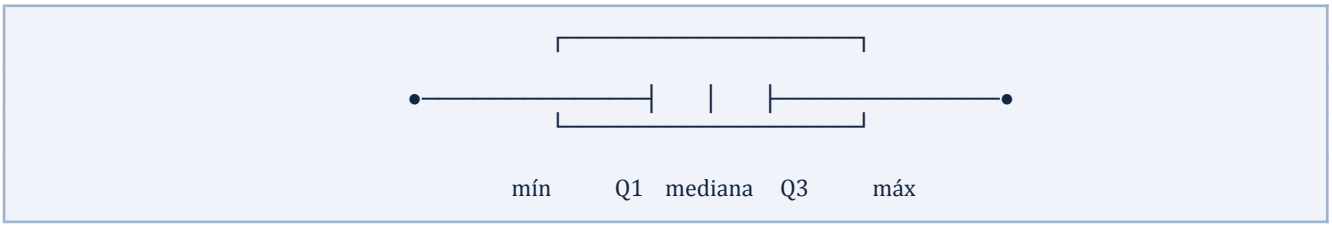



*Diagrama de caja: bigotes (mín–máx), caja (Q1–Q3) y línea de mediana*

La caja representa el intervalo entre Q1 y Q3, mientras que la línea interior representa la mediana. Los valores que aparecen más allá de los límites habituales pueden visualizarse como puntos separados.

El boxplot resulta especialmente útil durante la exploración porque permite detectar rápidamente variables con comportamientos extremos.

## Regla de las tres sigmas

Otra estrategia para identificar valores extremos utiliza la desviación estándar. Si una variable presenta aproximadamente una distribución normal, una gran parte de las observaciones se concentra alrededor de la media. La regla de tres sigmas considera potencialmente extremos los valores que se encuentran a más de tres desviaciones estándar de la media:

$$x < \mu - 3\sigma \qquad x > \mu + 3\sigma$$

Esta estrategia es útil en determinadas situaciones, pero requiere mayor cuidado cuando la distribución no es aproximadamente normal. Por eso no existe una única técnica universal para detectar outliers: IQR puede resultar conveniente en determinadas distribuciones, mientras que la regla de tres sigmas puede ser adecuada en otras.

## ¿Eliminar, conservar o transformar?

Llegamos a una de las decisiones más delicadas del preprocesamiento: encontramos un valor extremo, ¿qué hacemos? La respuesta depende de su origen y del problema.

Si tenemos evidencia de que el valor es producto de un error de carga, podríamos corregirlo o eliminar el registro, dependiendo del caso. Si el valor es legítimo y representa un comportamiento real, probablemente debamos conservarlo. Si el valor es válido pero afecta excesivamente determinadas operaciones estadísticas o algoritmos, podríamos considerar una transformación.

Por ejemplo, las variables de gasto suelen presentar distribuciones muy asimétricas: en lugar de eliminar automáticamente las compras grandes, puede resultar más apropiado transformar la variable mediante una transformación logarítmica.

La decisión correcta no se obtiene mirando únicamente el número. Debemos preguntarnos:

- *¿Este valor representa una situación real?*
- *¿Es importante para el problema?*
- *¿Es consecuencia de un error?*
- *¿Qué efecto tendrá eliminarlo?*
- *¿Qué efecto tendrá conservarlo?*

Esta forma de razonamiento es mucho más importante que memorizar una función de Pandas.

## Las escalas de las variables

Otro problema que aparece frecuentemente en datasets reales es que las variables pueden utilizar escalas muy diferentes. Imaginemos dos variables:

$$\text{edad} \rightarrow 18 \text{ a } 80$$

$$\text{gasto} \rightarrow 5.000 \text{ a } 2.000.000$$

Si utilizamos un algoritmo basado en distancias, como KNN, la diferencia de escala puede provocar que la variable gasto tenga una influencia mucho mayor que edad. Esto no necesariamente significa que el gasto sea más importante para el problema: puede ser simplemente una consecuencia de la forma en que están expresados los números.

Supongamos dos clientes:

$$\text{Cliente A} \rightarrow \text{edad } 25,\ \text{gasto } 100.000$$

$$\text{Cliente B} \rightarrow \text{edad } 35,\ \text{gasto } 110.000$$

La diferencia de edad es 10 y la diferencia de gasto es 10.000. Si calculamos una distancia directamente utilizando esos valores, la segunda variable dominará el cálculo. Por eso determinados algoritmos requieren que las variables sean llevadas a escalas comparables.

## Normalización Min-Max

Una de las estrategias utilizadas es la normalización Min-Max. La transformación lleva los valores a un intervalo, habitualmente entre 0 y 1:

$$x' = (x - x_{min}) / (x_{max} - x_{min})$$

Supongamos una variable cuyos valores van de 10 a 100. Para un valor de 55:

$$x' = (55 - 10) / (100 - 10) = 45 / 90 = 0.5$$

El valor queda ubicado en la mitad del intervalo. En Scikit-Learn podemos realizar esta transformación utilizando MinMaxScaler.

La ventaja es que las variables quedan en una escala comparable. Sin embargo, existe una consideración importante: Min-Max depende de los valores mínimo y máximo, por lo que si aparece un outlier muy grande puede afectar fuertemente la transformación.

## Estandarización

Otra estrategia es la estandarización. La transformación clásica es:

$$z = (x - \mu) / \sigma$$

donde μ representa la media y σ la desviación estándar. Después de la transformación, la variable queda expresada en términos de cuántas desviaciones estándar se encuentra cada observación respecto de la media. En Scikit-Learn podemos utilizar:

```
from sklearn.preprocessing import StandardScaler
```

y posteriormente aplicar StandardScaler.

La estandarización es utilizada frecuentemente en algoritmos que pueden verse afectados por las escalas de las variables. Pero nuevamente debemos evitar convertir esto en una receta automática.

***No todas las variables ni todos los algoritmos requieren exactamente el mismo tratamiento.***

## ¿Qué variables debemos escalar?

Esta es una pregunta que el estudiante debería aprender a formular.

Las variables numéricas continuas suelen ser candidatas naturales para el escalamiento cuando utilizamos algoritmos sensibles a la escala. Las variables categóricas, en cambio, requieren otro tipo de tratamiento. Una variable como categoría = Ropa / Hogar / Electrónica no puede ser escalada como si fuera una variable numérica continua.

Por otro lado, algunos modelos basados en árboles son mucho menos sensibles a la escala de las variables que algoritmos basados en distancias o determinados métodos de optimización. Por eso el preprocesamiento no debe separarse del modelo.

La pregunta correcta no es «¿hay que escalar los datos?», sino «¿qué transformación necesitan estos datos para este problema y este modelo?». Esta forma de pensar será fundamental cuando comencemos a experimentar con diferentes algoritmos.

## El dataset CLEAN

Después de analizar todos estos problemas podemos definir mejor qué buscamos cuando hablamos de construir nuestro dataset CLEAN. No significa simplemente que eliminamos todos los NaN, quitamos todos los valores grandes y convertimos todo a números. Un dataset CLEAN es aquel que ha pasado por un proceso razonado de preparación en función del problema que queremos resolver. Podemos representarlo así:




El paso que muchas veces se omite es justamente la decisión: encontrar un problema no nos dice automáticamente qué hacer.

- Un valor faltante puede requerir imputación.
- Un duplicado puede requerir eliminación.
- Una categoría inconsistente puede requerir normalización.
- Un outlier puede requerir conservación.

- Un error evidente puede requerir corrección.
- Una variable desescalada puede requerir transformación.

Cada situación necesita un criterio.

## Una idea fundamental: detectar no es solucionar

***Detectar un problema no implica haber encontrado automáticamente su solución.***

Un algoritmo puede indicarnos que un valor es potencialmente extremo, pero no puede decidir por sí solo qué significa ese valor en el contexto del negocio.

Una función puede indicarnos que existen valores faltantes, pero no puede saber automáticamente si la ausencia es significativa, si debemos imputarla o si debemos eliminar la observación.

Una estadística puede mostrarnos una correlación, pero no puede demostrar por sí sola una relación causal.

Por eso el trabajo con datos combina herramientas computacionales, estadística y conocimiento del dominio. Esta combinación será cada vez más importante a medida que avancemos hacia Machine Learning.

Aprendimos que un dataset no debe considerarse confiable simplemente porque pueda cargarse correctamente en Pandas: la ausencia de errores de programación no significa ausencia de errores en los datos.

Analizamos diferentes tipos de variables y revisamos conceptos estadísticos fundamentales como media, mediana, moda, varianza, desviación estándar, percentiles, cuartiles y rango. Estas herramientas nos permiten describir la distribución de nuestros datos y detectar comportamientos que merecen ser investigados.

También introdujimos la correlación como una forma de estudiar relaciones entre variables, pero estableciendo una distinción fundamental entre correlación y causalidad. Posteriormente analizamos diferentes problemas de calidad, incluyendo valores faltantes, duplicados, inconsistencias, valores imposibles y valores extremos.

Los outliers ocuparon un lugar especialmente importante porque nos permitieron comprender que un dato extremo no es necesariamente un dato incorrecto. Utilizamos el rango intercuartílico y la regla de 1,5 IQR, además de la regla de tres sigmas, como mecanismos para detectar observaciones potencialmente extremas, pero dejamos claro que la detección estadística debe ser seguida por una decisión basada en el contexto.

Finalmente analizamos el problema de las escalas y comprendimos por qué determinadas técnicas de Machine Learning necesitan que las variables numéricas estén en escalas comparables. Introdujimos la normalización Min-Max y la estandarización mediante StandardScaler, preparando el terreno para las clases en las que comenzaremos a utilizar modelos concretos.

El resultado de todo este proceso será nuestro dataset CLEAN. Pero CLEAN no significa simplemente «sin errores visibles»: significa que hemos analizado los datos, identificado problemas, tomado decisiones justificadas y aplicado transformaciones coherentes con el problema que queremos resolver.