CLASE 9 — APRENDIZAJE NO SUPERVISADO, REDUCCIÓN DIMENSIONAL Y RECOMENDACIÓN

Hasta ahora trabajamos principalmente con problemas de aprendizaje supervisado. En ese escenario existe una variable que representa aquello que queremos aprender a predecir. Si nuestro objetivo es determinar si un cliente realizará una compra, por ejemplo, podemos disponer de una variable compra que indique si finalmente compró o no. El modelo utiliza esa información durante el entrenamiento para aprender una relación entre las características de los ejemplos y el resultado esperado.

Pero muchos problemas reales no tienen una respuesta conocida. Podemos tener miles de clientes y saber cuánto compraron, cuántas veces ingresaron al sitio, qué categorías visitaron o qué productos adquirieron, pero nadie nos dice previamente cuáles pertenecen al mismo perfil. Tampoco existe necesariamente una variable que indique "cliente frecuente", "cliente ocasional" o "cliente de alto valor". Esa estructura puede estar presente en los datos, pero debemos descubrirla.

Aquí aparece el aprendizaje no supervisado.

La diferencia fundamental no está simplemente en el algoritmo utilizado, sino en la información disponible durante el aprendizaje. En el aprendizaje supervisado conocemos una respuesta que queremos predecir; en el no supervisado no contamos con ese target y buscamos encontrar alguna estructura interna en los datos.

Podemos resumir la diferencia de esta manera:

APRENDIZAJE SUPERVISADO

Datos + respuesta conocida
↓
modelo
↓
predicción

APRENDIZAJE NO SUPERVISADO

Datos sin respuesta conocida
↓
algoritmo
↓
estructura / grupos / patrones

Esta diferencia modifica también la manera en que evaluamos los resultados. En clasificación podemos comparar la predicción con una etiqueta verdadera. En clustering, muchas veces no existe una respuesta correcta previamente conocida. Por eso debemos utilizar otras estrategias para analizar si las estructuras encontradas resultan razonables.

9.1. Buscar estructura en los datos

Imaginemos que tenemos información de 5.000 usuarios de un comercio electrónico. Para cada uno conocemos, entre otras variables, la cantidad de compras realizadas, el gasto acumulado, la frecuencia de visitas y la cantidad de productos consultados.

Podríamos encontrar algo parecido a esto:

Usuario A → pocas visitas, pocas compras, bajo gasto
Usuario B → muchas visitas, muchas compras, alto gasto
Usuario C → muchas visitas, pocas compras, gasto medio

Nadie nos indicó previamente que esos tres comportamientos representan grupos diferentes. Sin embargo, podríamos sospechar que existe una estructura.

El aprendizaje no supervisado intenta precisamente encontrar este tipo de regularidades.

La pregunta deja de ser:

> ¿A qué clase pertenece este usuario?

y pasa a ser:

> ¿Qué usuarios presentan comportamientos similares?

Esta diferencia parece pequeña, pero conceptualmente cambia completamente el problema.

9.2. Similitud y distancia

Para encontrar grupos necesitamos alguna forma de determinar qué tan parecidos son dos ejemplos.

En muchos algoritmos esto se expresa mediante una distancia.

La distancia euclídea es uno de los ejemplos más conocidos. Para dos puntos representados por dos características podemos calcular:

d(x,y)=(x1−y1)2+(x2−y2)2d(x,y)=\sqrt{(x_1-y_1)^2+(x_2-y_2)^2}

Si dos puntos están próximos, podemos considerarlos similares bajo esa representación. Si están alejados, podemos considerarlos menos similares.

Esta idea será fundamental para comprender K-Means.

Pero aquí debemos recuperar algo que ya estudiamos cuando hablamos de preprocesamiento: las escalas importan.

Supongamos que tenemos:

Edad → 18 a 80
Gasto → 0 a 5.000.000

Si utilizamos directamente una distancia, el gasto tendrá una influencia mucho mayor debido a su escala numérica.

Por eso, cuando trabajamos con métodos basados en distancia, el escalamiento puede resultar fundamental.

9.3. Clustering

El clustering consiste en agrupar observaciones de acuerdo con algún criterio de similitud.

La idea general puede representarse:

Datos
↓
medida de similitud/distancia
↓
agrupamiento
↓
clusters

Un cluster es, en términos generales, un conjunto de observaciones que presentan características similares según el criterio utilizado.

Pero debemos tener cuidado con una interpretación muy común. Un cluster no necesariamente representa una categoría "real" existente en el mundo.

Si un algoritmo encuentra tres grupos de clientes, eso no significa automáticamente que la realidad esté dividida naturalmente en tres tipos de clientes.

Significa que, bajo las variables seleccionadas y el método utilizado, el algoritmo encontró una estructura que permite agruparlos de esa manera.

Esta distinción es muy importante.

9.4. K-Means

Uno de los algoritmos de clustering más conocidos es K-Means.

Su objetivo general es dividir los datos en KK grupos, intentando que los elementos pertenecientes a cada grupo estén relativamente próximos entre sí.

La letra KK representa justamente la cantidad de clusters que queremos obtener.

Por ejemplo:

K=3K=3

significa que solicitamos al algoritmo tres grupos.

A diferencia de un problema supervisado, aquí no tenemos una columna que indique previamente cuál es el grupo correcto.

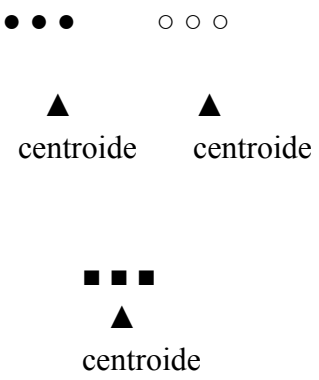
El algoritmo debe construirlos.

9.5. Los centroides

K-Means trabaja utilizando centroides.

Un centroide puede entenderse como el punto que representa el centro de un cluster.

Imaginemos tres grupos:



Los centroides inicialmente pueden ser ubicados de diferentes maneras dependiendo de la estrategia utilizada.

A partir de allí comienza un proceso iterativo.

Primero, cada observación se asigna al centroide más cercano.

Después se recalculan los centroides utilizando los elementos asignados a cada grupo.

El proceso vuelve a repetirse.

9.6. Funcionamiento iterativo

Podemos representar el proceso de K-Means de manera conceptual:

Elegir K
↓
Inicializar centroides
↓
Asignar observaciones
al centroide más cercano
↓
Recalcular centroides
↓
¿Los grupos cambiaron?
↓
Sí → repetir
↓
No → finalizar

El algoritmo continúa hasta alcanzar una condición de convergencia o hasta llegar al número máximo de iteraciones establecido.

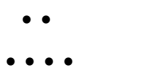
La palabra convergencia significa, en este contexto, que el algoritmo deja de producir cambios significativos en la asignación de los datos o en la posición de los centroides.

9.7. Un ejemplo con clientes

Supongamos que queremos segmentar clientes utilizando únicamente dos variables:

Gasto anual
Frecuencia de compra

Al representar los usuarios podríamos encontrar:







Podríamos solicitar:

K=3K=3

El algoritmo buscará tres centroides y asignará los usuarios al grupo cuyo centroide esté más próximo.

Podríamos terminar interpretando los grupos de manera aproximada como:

Cluster 1 → clientes de baja actividad
Cluster 2 → clientes de actividad media
Cluster 3 → clientes de alta actividad

Pero esas etiquetas son nuestras interpretaciones posteriores. K-Means simplemente encontró grupos.

Esta diferencia entre resultado matemático e interpretación del negocio es fundamental.

9.8. ¿Cómo sabemos qué K elegir?

Aquí aparece uno de los principales problemas de K-Means.

El algoritmo necesita que indiquemos previamente el valor de KK.

Pero normalmente no sabemos de antemano cuántos grupos existen.

Podríamos probar:

K=2, 3, 4, 5, 6K=2,\;3,\;4,\;5,\;6

y analizar qué ocurre.

Una de las técnicas utilizadas es el método del codo.

9.9. Inertia y WCSS

K-Means utiliza una medida relacionada con la distancia entre las observaciones y sus centroides.

Una medida habitual es la inertia, también conocida como WCSS, Within-Cluster Sum of Squares.

Conceptualmente:

WCSS=∑k=1K∑xi∈Ckd(xi,μk)2WCSS= \sum_{k=1}^{K} \sum_{x_i\in C_k} d(x_i,\mu_k)^2

donde xix_i representa una observación y μk\mu_k el centroide de su cluster.

La idea es sencilla: queremos que los elementos de un mismo grupo estén relativamente cerca de su centroide.

Cuando aumentamos K, normalmente la inertia disminuye porque estamos permitiendo más grupos.

Pero esto genera un problema: si seguimos aumentando K hasta llegar a un grupo por observación, la distancia interna puede acercarse a cero.

Por lo tanto, no podemos elegir K simplemente buscando la menor inertia.

Necesitamos observar dónde agregar más clusters deja de aportar una mejora significativa.

9.10. Método del codo

Podemos calcular la inertia para diferentes valores de K:

K	Inertia
2	820
3	520
4	350
5	310
6	285
7	270

Si representamos estos valores, normalmente veremos una disminución rápida al principio y luego una disminución más suave.

El punto donde se produce el cambio más evidente puede parecerse a un "codo".

La idea sería elegir un valor cercano a ese punto porque aumentar la cantidad de clusters después de allí aporta mejoras cada vez menores.

Sin embargo, el método del codo no constituye una verdad matemática absoluta.

El resultado debe analizarse junto con el contexto del problema.

9.11. Silhouette

Otra medida muy utilizada es el silhouette score.

Esta métrica intenta evaluar simultáneamente dos aspectos:

1. qué tan cerca está una observación de los elementos de su propio cluster;
2. qué tan separada está de los otros clusters.

Un valor alto indica que los grupos tienden a estar internamente cohesionados y relativamente separados.

Un valor bajo puede indicar que existen observaciones ambiguas o clusters que se superponen considerablemente.

Por eso silhouette puede complementar el análisis realizado mediante inertia.

Nuevamente, no debemos convertir una métrica en una respuesta automática. El valor numérico debe ser interpretado dentro del problema.

9.12. Interpretar clusters

Supongamos que ejecutamos K-Means y obtenemos tres grupos.

El algoritmo nos devuelve algo como:

Cluster 0
Cluster 1
Cluster 2

Eso no es todavía conocimiento de negocio.

Necesitamos analizar qué caracteriza a cada grupo.

Podríamos calcular:

Cluster	Compras promedio	Gasto promedio	Visitas promedio
0	2	$80.000	5
1	8	$450.000	21
2	15	$1.200.000	35

Ahora podemos comenzar a interpretar.

El cluster 0 parece representar clientes de baja actividad.

El cluster 1 podría representar clientes frecuentes.

El cluster 2 podría representar clientes de alto valor.

Pero debemos mantener una precaución: estas interpretaciones dependen de las variables utilizadas.

Si eliminamos la variable gasto, por ejemplo, probablemente los grupos cambien.

Esto significa que el clustering no descubre necesariamente "la verdad" sobre los clientes. Descubre estructuras bajo una determinada representación de los datos.

9.13. Clustering y e-commerce

Este concepto puede resultar especialmente interesante para nuestro proyecto.

Podemos construir una representación de cada usuario utilizando:

frecuencia de compra
gasto acumulado
cantidad de productos comprados
cantidad de visitas
categorías visitadas
tiempo desde última compra

Después podemos aplicar clustering para intentar encontrar perfiles.

No estamos preguntando:

> ¿Qué categoría tiene este usuario?

Estamos preguntando:

> ¿Qué patrones de comportamiento presentan nuestros usuarios?

Esta información podría ser utilizada posteriormente para diseñar estrategias comerciales.

Por ejemplo, podríamos descubrir un grupo de usuarios que visita frecuentemente el sitio pero compra poco.

Ese grupo podría representar una oportunidad para analizar problemas de conversión.

Otro grupo podría estar formado por clientes que compran con poca frecuencia pero realizan compras de gran valor.

El clustering puede ayudarnos a descubrir estas estructuras.

9.14. Reducción dimensional

Hasta ahora hemos hablado de datos con pocas variables porque resulta fácil representarlos visualmente.

Pero un dataset real puede contener decenas, cientos o incluso miles de características.

Cuando aumenta la cantidad de dimensiones aparecen diferentes dificultades.

La visualización se vuelve complicada.

Los algoritmos pueden requerir más recursos.

Las relaciones entre variables pueden resultar difíciles de interpretar.

Además, algunas características pueden aportar información redundante.

Aquí aparece la reducción dimensional.

Su objetivo general es representar los datos utilizando una cantidad menor de dimensiones intentando conservar una parte importante de la información relevante.

Podemos pensar:

100 características
↓
reducción dimensional
↓
10 componentes

No significa necesariamente que hayamos eliminado simplemente 90 columnas.

Podemos haber construido una nueva representación de los datos.

9.15. PCA

Uno de los métodos más importantes para reducción dimensional es PCA, Principal Component Analysis.

PCA busca nuevas direcciones en los datos llamadas componentes principales.

Estas direcciones se construyen de manera que permitan capturar la mayor cantidad posible de variabilidad.

La idea puede resultar abstracta inicialmente, pero podemos pensar en un conjunto de puntos distribuidos de manera alargada:



Aunque los datos estén originalmente expresados mediante dos variables, quizás la mayor parte de la variación pueda explicarse mediante una única dirección.

PCA busca precisamente este tipo de representación.

9.16. Componentes principales

Los componentes principales son nuevas variables construidas a partir de combinaciones de las variables originales.

El primer componente captura la mayor cantidad de varianza posible.

El segundo componente captura la mayor cantidad posible de varianza restante, respetando la condición de ser ortogonal al primero.

Y así sucesivamente.

Podemos representar conceptualmente:

Variables originales
X1 X2 X3 X4 X5
↓
PCA
↓
PC1 PC2 PC3

Podemos entonces trabajar con menos dimensiones.

9.17. Varianza y PCA

La palabra varianza resulta fundamental en PCA.

Recordemos que la varianza mide cuánto se dispersan los valores respecto de su media.

PCA busca direcciones donde exista una cantidad importante de variabilidad.

Si una combinación de variables permite explicar gran parte de la variación de los datos, esa combinación puede convertirse en un componente principal.

Esto permite construir una representación más compacta.

9.18. ¿Por qué utilizar PCA?

PCA puede utilizarse con diferentes objetivos.

Uno de ellos es reducir la dimensionalidad antes de aplicar otros algoritmos.

Otro es facilitar la visualización.

Por ejemplo, si tenemos 20 variables, podríamos utilizar PCA para obtener dos componentes y representar los datos en un plano.

Esto no significa que PC1 y PC2 tengan necesariamente una interpretación sencilla como "gasto" o "edad".

Son combinaciones matemáticas de las variables originales.

Por eso debemos tener cuidado al interpretar sus valores.

9.19. Número de componentes

PCA también requiere tomar una decisión: ¿cuántos componentes conservar?

Podemos utilizar:

2 componentes
5 componentes
10 componentes
...

Cuantos más componentes conservemos, mayor será la cantidad de información potencialmente retenida, pero menor será la reducción dimensional.

Aquí aparece nuevamente un equilibrio.

Reducir demasiado puede provocar pérdida de información.

Reducir muy poco puede no resolver el problema que motivó la reducción.

El porcentaje de varianza explicada puede ayudarnos a tomar esta decisión.

9.20. SVD

Otro concepto importante relacionado con reducción dimensional es la descomposición en valores singulares, o SVD.

La idea matemática consiste en descomponer una matriz en componentes que permiten analizar su estructura.

De manera simplificada:

$A=U\Sigma VTA=U\Sigma V^T$

No necesitamos desarrollar toda la demostración matemática para comprender su utilidad dentro de esta materia.

Lo importante es saber que SVD permite descomponer una matriz y que, conservando solamente una parte de sus componentes, podemos construir una representación aproximada de menor dimensionalidad.

Esto es especialmente útil cuando trabajamos con matrices grandes y dispersas.

9.21. SVD truncado

Si una matriz contiene una gran cantidad de información, podemos conservar solamente los componentes más relevantes.

Esto recibe el nombre de SVD truncado.

Conceptualmente:

Matriz original
↓
SVD
↓
muchos componentes
↓
seleccionamos los principales
↓
representación reducida

La idea es muy similar al objetivo general de PCA: obtener una representación más compacta conservando información relevante.

SVD también tendrá una importancia particular cuando más adelante trabajemos con sistemas de recomendación.

9.22. Reglas de asociación

Hasta ahora buscamos grupos de observaciones.

Ahora podemos buscar algo diferente: relaciones entre elementos que aparecen conjuntamente.

Supongamos que tenemos transacciones:

Compra 1 → mate, yerba
Compra 2 → mate, bombilla
Compra 3 → mate, yerba, bombilla
Compra 4 → yerba, bombilla

Podríamos descubrir que ciertos productos aparecen frecuentemente juntos.

Esto nos lleva a las reglas de asociación.

Una regla puede representarse:

A→BA \rightarrow B

Por ejemplo:

mate → bombilla

La interpretación sería que la presencia de mate está asociada con una mayor probabilidad de encontrar también una bombilla.

Pero debemos ser muy cuidadosos: una regla de asociación no implica causalidad.

No significa que comprar un mate provoque necesariamente la compra de una bombilla.

Simplemente existe una relación estadística de coocurrencia bajo los criterios utilizados.

9.23. Soporte

El soporte mide con qué frecuencia aparece un conjunto de elementos dentro de todas las transacciones.

Si tenemos 100 transacciones y en 20 aparece:

mate + bombilla

el soporte será:

Support=0.20Support=0.20

o 20 %.

Un soporte alto indica que el conjunto aparece frecuentemente.

9.24. Confianza

La confianza de una regla:

A→BA\rightarrow B

mide, aproximadamente, qué proporción de las transacciones que contienen A también contienen B.

La fórmula es:

Confidence(A→B)=Support(A∪B)Support(A)Confidence(A\rightarrow B)= \frac{Support(A\cup B)} {Support(A)}

Supongamos:

100 transacciones
40 contienen mate
20 contienen mate y bombilla

Entonces:

Confidence=2040=0.50Confidence= \frac{20}{40}=0.50

La confianza es 50 %.

Esto significa que, dentro de las transacciones que contienen mate, la mitad también contiene bombilla.

9.25. Lift

La confianza todavía puede resultar engañosa.

Supongamos que casi todos nuestros clientes compran bombillas.

Entonces es posible obtener una confianza alta simplemente porque la bombilla es extremadamente frecuente.

El lift permite comparar la frecuencia conjunta con lo que esperaríamos si los elementos fueran independientes.

De forma simplificada:

Lift(A→B)=Confidence(A→B)Support(B)Lift(A\rightarrow B)= \frac{Confidence(A\rightarrow B)} {Support(B)}

Un lift cercano a 1 indica una asociación que no se aleja demasiado de lo esperado por la frecuencia de B.

Un lift mayor que 1 puede indicar una asociación positiva.

Un lift menor que 1 puede indicar una asociación negativa.

Nuevamente, estamos hablando de asociación, no de causalidad.

9.26. Del análisis de asociaciones a la recomendación

Aquí podemos conectar este tema con uno de los problemas más conocidos del comercio electrónico.

Supongamos que un usuario está observando un producto.

Podemos preguntarnos:

> ¿Qué otros productos podría interesarle comprar?

Una forma sencilla de aproximarnos sería utilizar relaciones encontradas en transacciones anteriores.

Si muchos clientes que compraron el producto A también compraron B, podemos considerar B como una posible recomendación.

Sin embargo, los sistemas de recomendación modernos pueden utilizar información mucho más rica.

Aquí aparecen dos grandes enfoques que estudiaremos: basado en contenido y filtrado colaborativo.

9.27. Recomendación basada en contenido

El enfoque basado en contenido utiliza características de los productos y del perfil o historial del usuario.

Supongamos que un usuario suele consultar productos relacionados con:

running
deporte
calzado

Podemos construir una representación de sus intereses y compararla con las características de otros productos.

Si encontramos productos similares a aquellos que el usuario ya mostró interés en ellos, podemos recomendarlos.

La lógica general sería:

historial del usuario
↓
perfil de intereses
↓
comparación con productos
↓
productos similares

↓
recomendación

Este enfoque no necesita necesariamente información de otros usuarios.

Se basa principalmente en la relación entre el perfil del usuario y las características de los productos.

9.28. Filtrado colaborativo

El filtrado colaborativo parte de una idea diferente.

En lugar de concentrarse exclusivamente en las características de los productos, utiliza el comportamiento colectivo de los usuarios.

Supongamos que tenemos:

	Producto A	Producto B	Producto C
Usuario 1	✓	✓	
Usuario 2	✓	✓	✓
Usuario 3		✓	✓

Si dos usuarios presentan comportamientos similares, podemos utilizar esa similitud para realizar recomendaciones.

La intuición sería:

> Usuarios que se comportaron de manera similar en el pasado podrían estar interesados en productos similares en el futuro.

Aquí aparece la llamada matriz usuario-producto.

9.29. Matriz de utilidad

Podemos representar las interacciones mediante una matriz:

	Producto A	Producto B	Producto C
Usuario 1	5	4	?
Usuario 2	5	?	4
Usuario 3	?	5	4

Los valores pueden representar compras, puntuaciones, clics, visualizaciones u otro tipo de interacción.

Los signos de interrogación representan información que todavía no conocemos.

El sistema intenta estimar qué productos podrían interesar al usuario.

Esto transforma la recomendación en un problema de predicción.

9.30. Similitud entre usuarios y productos

El filtrado colaborativo puede analizar similitud entre usuarios o entre productos.

Si dos usuarios tienen patrones de comportamiento parecidos, podemos aprovechar esa similitud.

También podemos analizar productos que suelen recibir interacciones similares.

Por ejemplo:

Producto A ↔ Producto B

podrían considerarse similares porque suelen ser consumidos por usuarios similares.

La similitud puede calcularse mediante diferentes técnicas, dependiendo de la representación utilizada.

Aquí volvemos a encontrarnos con conceptos que ya aparecieron anteriormente: vectores, distancias, representaciones numéricas y reducción dimensional.

Esto demuestra que los contenidos de la materia no son compartimentos aislados.

9.31. El problema de los datos faltantes en recomendación

La matriz usuario-producto suele ser extremadamente dispersa.

Imaginemos:

100.000 usuarios
50.000 productos

No significa que cada usuario haya interactuado con los 50.000 productos.

La enorme mayoría de las combinaciones probablemente estén vacías.

Esto genera una matriz con muchísimos valores desconocidos.

Por eso las técnicas de reducción dimensional, como SVD, pueden resultar útiles para encontrar una representación más compacta de la información.

Conceptualmente:

Matriz usuario-producto
↓
SVD
↓
representación latente
↓
similitudes / predicciones
↓
recomendaciones

9.32. Usuario + historial + productos

Podemos integrar los conceptos de esta clase mediante una representación sencilla:

Usuario
+
Historial
+
Productos
↓
Representación
↓
Similitud / estructura
↓
Recomendación

El sistema de recomendación intenta transformar grandes cantidades de interacciones en decisiones que puedan resultar útiles para el usuario.

En un comercio electrónico esto puede utilizarse para diferentes situaciones:

"También te puede interesar..."

"Usuarios que compraron esto también compraron..."

"Productos similares..."

"Recomendado para vos..."

Aunque la interfaz final parezca sencilla, detrás de esas recomendaciones puede existir un proceso matemático bastante complejo.

9.33. Una cuestión importante: recomendación no significa causalidad

Supongamos que nuestro análisis encuentra:

A→BA\rightarrow B

No debemos concluir automáticamente que comprar A provoca comprar B.

Puede existir una tercera variable que explique ambas compras.

Por ejemplo, determinados productos pueden ser comprados conjuntamente porque pertenecen a una misma actividad.

Por eso, tanto en clustering como en reglas de asociación y recomendación, debemos diferenciar cuidadosamente entre:

encontrar una estructura en los datos

y

demostrar una explicación causal.

Machine Learning puede encontrar patrones extremadamente útiles sin demostrar por qué esos patrones existen.

9.34. Integración de la clase

En esta clase cambiamos radicalmente la pregunta respecto de las anteriores.

En aprendizaje supervisado preguntábamos:

> ¿Podemos aprender una función que transforme las características en una respuesta conocida?

Ahora preguntamos:

> ¿Podemos encontrar estructuras útiles cuando no conocemos previamente la respuesta?

Comenzamos con clustering y vimos cómo K-Means utiliza centroides y distancias para construir grupos.

Después analizamos cómo elegir K mediante herramientas como inertia, WCSS, método del codo y silhouette.

Luego ampliamos el problema hacia datasets con muchas variables y estudiamos reducción dimensional mediante PCA y SVD.

Finalmente utilizamos estas ideas para comprender reglas de asociación y sistemas de recomendación, diferenciando el enfoque basado en contenido del filtrado colaborativo.

Todo esto puede relacionarse con el e-commerce, pero no necesariamente tiene que utilizar exactamente el mismo dataset para cada actividad. El clustering puede trabajar con perfiles de usuarios; las reglas de asociación necesitan información transaccional; un recomendador puede necesitar una matriz usuario-producto.

La idea importante es que el problema determina qué datos necesitamos y qué técnica resulta apropiada.

9.35. Cierre

Hasta ahora hemos recorrido dos formas fundamentales de aprendizaje.

En el aprendizaje supervisado disponíamos de una respuesta conocida y buscábamos aprender a predecirla. En el aprendizaje no supervisado eliminamos esa respuesta y buscamos estructuras que puedan ayudarnos a comprender los datos.

K-Means nos permitió introducir la idea de agrupamiento. PCA y SVD nos mostraron que podemos construir representaciones de menor dimensionalidad. Las reglas de asociación nos permitieron descubrir relaciones entre elementos de una misma transacción y los sistemas de recomendación nos mostraron cómo utilizar información sobre usuarios, productos e interacciones para generar sugerencias.

Pero todavía nos falta una transformación importante en nuestro recorrido.

Hasta ahora los modelos que estudiamos trabajan fundamentalmente con representaciones estructuradas de los datos. Sin embargo, muchos de los problemas más interesantes de Inteligencia Artificial involucran información mucho más compleja: imágenes, audio, texto y secuencias.

Para abordar estos problemas necesitamos modelos capaces de aprender representaciones cada vez más sofisticadas.

Ese será el siguiente paso de nuestro recorrido.

En la próxima clase dejaremos atrás progresivamente los modelos clásicos y entraremos en el mundo de las redes neuronales artificiales. Comenzaremos por la neurona artificial y el perceptrón, entenderemos qué papel cumplen los pesos y el bias, veremos por qué necesitamos funciones de activación y llegaremos al mecanismo mediante el cual una red aprende: descenso por gradiente y backpropagation.