Propuesta Académica y Planificación de Cátedra: Inteligencia Artificial (Trayecto Programador Universitario de Sistemas)

1. Información General de la Materia

Ficha Técnica	Detalle
Nombre de la Materia	Inteligencia Artificial
Carga Horaria Total	60 horas
Duración	15 semanas
Carga Semanal	4 horas (2h Teoría / 2h Laboratorio Práctico)
Marco Normativo	Cumplimiento estricto con la **Resolución C.S. N° 95-2024**

2. Fundamentación y Enfoque Pragmático

La presente asignatura se fundamenta en el lema pedagógico **"entender para implementar y consumir"**. En el escenario actual de la industria tecnológica, el perfil del Programador Universitario de Sistemas requiere una transición desde el enfoque tradicional de ingeniería —centrado en el diseño matemático de algoritmos desde cero— hacia un enfoque de implementación robusta.

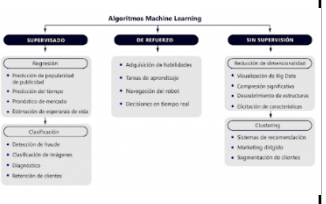
El objetivo central es que el estudiante domine la aplicación de modelos existentes mediante librerías líderes como **Scikit-Learn**. Se prioriza la capacidad de integrar soluciones de IA en software comercial, interpretando datos y seleccionando el modelo óptimo según el problema de negocio. El egresado no será un investigador de algoritmos, sino un implementador estratégico capaz de transformar requisitos de negocio en arquitecturas de software inteligentes.

3. Objetivos de Aprendizaje

Al finalizar el trayecto académico, el estudiante será capaz de:

1. **Implementar** soluciones de aprendizaje supervisado y no supervisado utilizando herramientas estándar de la industria.
2. **Configurar** hiperparámetros críticos en modelos de clustering y clasificación para maximizar la precisión en entornos productivos.
3. **Evaluar** la performance de los modelos mediante métricas técnicas (Inercia, Silhouette, Lift) traduciendo dichos resultados a valor de negocio.
4. **Consumir** modelos pre-entrenados y librerías de Machine Learning para el procesamiento eficiente de grandes volúmenes de datos.
5. **Integrar** sistemas de recomendación y motores de reglas de asociación en aplicaciones web y móviles comerciales.

4. Cronograma Detallado (Planificación de 15 Semanas)

Semana	Eje Temático	Teoría (2h)	Laboratorio Práctico (2h)	Referencia a Fuente
1-4	Fundamentos y Aprendizaje Supervisado	Diferenciación entre Regresión y Clasificación. Enfoque en detección de patrones etiquetados.	Implementación de modelos de detección de fraude, diagnóstico y **Retención de Clientes (Churn)**.	
5-7	Profundización y Evaluación	Métricas de performance: Precisión, Recall y F1-Score. Conceptos de Overfitting vs. Underfitting.	Evaluación y ajuste de modelos de clasificación de imágenes comerciales.	Aprendizaje No supervisado 2025.pptx
8-9	Clustering: K-Means y DBSCAN	**K-Means:** Centroides e iteraciones. **DBSCAN:** Densidad, Epsilon y MinPoints. **Diferencia clave:** DBSCAN identifica ruido (outliers) mientras que K-Means es sensible a ellos.	Segmentación de clientes. Uso de simuladores visuales de Naftali Harris para observar la sensibilidad a parámetros.	SOURCE_IMAGE_6 a SOURCE_IMAGE_15
10	Evaluación de Clusters	Optimización: Método del Codo (Inercia) y Coeficiente de Silhouette (Cohesión vs. Separación).	Práctica: Ajuste de hiperparámetros para mejorar la separación de grupos de usuarios.	SOURCE_IMAGE_12, SOURCE_IMAGE_21
11	Reducción de Dimensionalidad	PCA (Varianza máxima) y SVD (Descomposición en valor singular). **Analogía de Géneros:** Transformación de una matriz de ratings de películas en géneros latentes (Ciencia Ficción vs. Romance).	Reducción de features: De una matriz de 5 películas a 2 dimensiones (X, Z) representando géneros, según SOURCE_IMAGE_25.	SOURCE_IMAGE_24, SOURCE_IMAGE_25
12	Reglas de Asociación	Algoritmo Apriori. Métricas: Soporte, Confianza y Lift. **Interpretación:** Un Lift mayor a 1 indica	Análisis de canasta de compras. Caso: "Pan -> Manteca"	Aprendizaje No supervisado 2025.pptx

		correlación positiva y valor predictivo.	(75% confianza, Lift 2.14).	
13	Sistemas de Recomendación I	Tipos de datos: **Explícitos** (ratings/puntuaciones) vs. **Implícitos** (inferencia a partir de compras o visualizaciones). Filtro basado en contenido.	Implementación de recomendador basado en etiquetas y perfiles de usuario.	SOURCE_IMAGE_27
14	Sistemas de Recomendación II	Filtrado Colaborativo y similitud entre usuarios. Abordaje del problema del "arranque frío" (cold start).	Implementación de un recomendador de productos/películas integrando matrices de ratings.	Aprendizaje No supervisado 2025.pptx
15	Evaluación Final y Cierre	Defensa de Proyecto Integrador: Aplicación de un modelo de IA a un caso de negocio real.	Presentación de código funcional y justificación técnica de la solución elegida.	Evaluación Final

5. Metodología de Enseñanza y Recursos

La cátedra adopta una metodología de **Taller de Implementación**:

- **Entornos Laboratorio:** Uso obligatorio de Notebooks (Jupyter o Google Colab) para la experimentación directa con código.
- **Gestión de Datos:** Los estudiantes trabajarán directamente con **matrices de ratings y vectores de features**, aprendiendo a estructurar la información como se observa en SOURCE_IMAGE_6 para su consumo por algoritmos.
- **Adaptación de Modelos:** En lugar de teorías abstractas, cada sesión práctica parte de un modelo funcional de ingeniería que el alumno debe adaptar para resolver una problemática de software comercial.
- **Simulación Visual:** Incorporación de herramientas interactivas (Naftali Harris) en las semanas 8, 9 y 13 para internalizar el comportamiento de los algoritmos antes de la codificación.

6. Sistema de Evaluación

Para obtener la aprobación, el estudiante deberá cumplir con:

- **Asistencia:** Mínimo del 75% en las sesiones de laboratorio.
- **Portfolio de Laboratorios:** Entrega semanal de los Notebooks desarrollados en clase, con énfasis en la limpieza y documentación del código.
- **Examen Final Práctico:** Defensa de un proyecto donde se implemente una solución completa (ej. un recomendador o un segmentador de clientes), demostrando la correcta

interpretación de métricas (especialmente el valor de Lift en reglas de asociación e Inercia en clusters).

7. Bibliografía y Referencias Institucionales

Las siguientes referencias vinculan los contenidos con el material de fuente institucional:

1. **Fundamentos de IA:** Clasificación y aplicaciones de negocio (Churn, Fraude), ver filmina 1 en [SOURCE_IMAGE_1].
2. **Clustering y K-Means:** Proceso iterativo y actualización de centroides, consultar filminas 5 a 15 de "Aprendizaje No supervisado 2025.pptx".
3. **DBSCAN y Outliers:** Manejo de ruido y parámetros de densidad, ver filmina 14 en [SOURCE_IMAGE_14].
4. **Validación de Modelos (Formularios en texto plano):**
    - **Inercia (K-Óptimo):** Verificación visual del "codo" en [SOURCE_IMAGE_12].
    - **Coeficiente de Silhouette:** s(i) = (b(i) - a(i)) / max(a(i), b(i)). Donde a(i) es la distancia media interna al cluster y b(i) la distancia al cluster más cercano. Ver [SOURCE_IMAGE_21].
5. **Reducción de Dimensionalidad:** Uso de SVD para pasar de ítems individuales a géneros (X=Ciencia Ficción, Z=Romance), ver matrices en [SOURCE_IMAGE_25].
6. **Reglas de Asociación (Métricas):**
    - Soporte(X -> Y) = Transacciones(X, Y) / Total
    - Confianza(X -> Y) = Transacciones(X, Y) / Transacciones(X)
    - Lift(X -> Y) = Confianza(X -> Y) / Soporte(Y)
    - *Nota: Un Lift de 2.14 significa que el antecedente hace 2.14 veces más probable el consecuente respecto al promedio.*
7. **Sistemas de Recomendación:** Comparativa de filtros y análisis de interfaces de usuario (Netflix/Amazon), ver [SOURCE_IMAGE_27] y sección final de "Aprendizaje No supervisado 2025.pptx".