

UNIVERSIDAD NACIONAL DE VILLA MERCEDES

UNViMe — Escuela de Ingeniería y Ciencias Ambientales

Programador Universitario de Sistemas

Materia: Inteligencia Artificial

Guía Teórica

Introducción a la Inteligencia Artificial

Prof. Elio Nicolás Baigorria

Villa Mercedes, San Luis — 2026

Unidad 1: Introducción a la Inteligencia Artificial

1.1. La Inteligencia Artificial como respuesta a un problema, no como una moda

Cuando un estudiante escucha por primera vez el término *Inteligencia Artificial* suele imaginar robots humanoides, computadoras capaces de mantener conversaciones como una persona o escenas extraídas de películas de ciencia ficción. Esta imagen ha sido alimentada durante décadas por el cine, la televisión y, más recientemente, por el enorme impacto que han tenido herramientas como Chat GPT, Gemini o Copilot entre otras. Sin embargo, comenzar con esta asignatura desde esa perspectiva puede conducir a una comprensión superficial del verdadero propósito de la Inteligencia Artificial.

La Inteligencia Artificial no nació para construir robots que imiten a los seres humanos. Tampoco surgió para reemplazar a los programadores ni para desarrollar máquinas conscientes. Su origen responde a una necesidad mucho más concreta y profundamente ligada a la evolución de la informática: **resolver problemas que dejaron de poder abordarse mediante programación tradicional**.

Esta idea constituye probablemente el concepto más importante de toda la asignatura y será el hilo conductor de las siguientes clases. Antes de estudiar algoritmos, modelos matemáticos o librerías como Scikit-Learn, es necesario comprender cuál fue el problema que motivó el desarrollo de estas técnicas. De lo contrario, corremos el riesgo de memorizar nombres de algoritmos sin entender por qué existen ni cuándo conviene utilizarlos.

Durante más de cincuenta años el desarrollo de software estuvo dominado por un paradigma relativamente simple. Ante un problema, un programador analizaba la situación, identificaba las reglas que debían cumplirse y las traducía a un lenguaje de programación. Si una empresa necesitaba calcular el sueldo de un empleado, el desarrollador implementaba las fórmulas correspondientes. Si un banco requería determinar el interés de un préstamo, el algoritmo aplicaba las ecuaciones financieras previamente definidas. En ambos casos, el sistema obtenía un resultado correcto porque todas las reglas necesarias eran conocidas de antemano.

Esta forma de construir software continúa siendo extremadamente válida y constituye la base de millones de aplicaciones que utilizamos diariamente. Un sistema de facturación, un cajero automático, una aplicación para gestionar turnos médicos o un sistema académico universitario funcionan correctamente porque el comportamiento esperado puede describirse mediante reglas claras y explícitas. En estos casos, el desafío principal consiste en diseñar correctamente la lógica del programa y traducirla al código fuente.

Sin embargo, a medida que las organizaciones comenzaron a almacenar cantidades cada vez mayores de información, apareció una clase completamente distinta de problemas. Ya no se

trataba simplemente de ejecutar reglas conocidas, sino de tomar decisiones en contextos donde dichas reglas eran demasiado numerosas, demasiado complejas o incluso desconocidas.

Imaginemos por un momento una empresa de comercio electrónico como Mercado Libre. Cada día millones de usuarios realizan búsquedas, consultan productos, concretan compras, califican vendedores y dejan comentarios. Toda esa actividad genera una enorme cantidad de datos. Ahora supongamos que el director comercial plantea la siguiente pregunta:

> ***¿Qué productos deberíamos mostrar primero a cada usuario para aumentar la probabilidad de compra?***

A primera vista podría parecer una pregunta sencilla. Sin embargo, si intentáramos resolverla utilizando únicamente programación tradicional, rápidamente aparecería un problema.

Podríamos escribir reglas como las siguientes:

- Si el usuario compró celulares anteriormente, mostrar más celulares.
- Si realizó búsquedas relacionadas con computadoras, priorizar notebooks.
- Si suele comprar artículos deportivos, recomendar zapatillas o ropa deportiva.

Hasta aquí el planteo parece razonable. Pero inmediatamente surgen nuevas preguntas.

- ¿Qué ocurre si un usuario nunca realizó una compra?
- ¿Qué sucede si busca productos para otra persona?
- ¿Cómo diferenciamos un interés ocasional de una preferencia permanente?
- ¿Cómo influyen la edad, la ubicación geográfica, la época del año o el dispositivo desde el cual realiza la compra?

Cada nueva situación obliga a escribir nuevas reglas y cada nueva regla interactúa con todas las anteriores.

En pocas semanas el programa comienza a crecer de forma descontrolada.

Lo que inicialmente parecía un algoritmo relativamente simple termina convirtiéndose en miles de condiciones anidadas, difíciles de mantener y prácticamente imposibles de optimizar.

Aquí aparece el primer gran límite de la programación tradicional.

No porque esté mal diseñada sino porque existen problemas cuya complejidad supera la capacidad humana para describir todas las reglas manualmente. En ese momento la pregunta cambia completamente, ya no nos preguntamos:

> ***¿Qué reglas debemos programar?***

Ahora nos preguntamos:

¿Existe alguna forma de que el propio sistema descubra esas reglas analizando ejemplos?

Esa pregunta representa uno de los pilares conceptuales sobre los cuales se construyó la Inteligencia Artificial moderna.

En lugar de indicarle al programa exactamente qué debe hacer en cada situación, comenzamos a proporcionarle grandes cantidades de información para que identifiquen regularidades, encuentre patrones y construya automáticamente un modelo capaz de tomar decisiones sobre nuevos casos.

Obsérvese que el cambio es mucho más profundo de lo que parece.

- **En la programación tradicional, el conocimiento proviene del programador.**
- **En la Inteligencia Artificial, gran parte del conocimiento proviene de los datos.**

Esta diferencia modifica completamente la manera en que diseñamos software.

Ya no alcanza con escribir un buen algoritmo.

Ahora también debemos obtener datos de calidad, prepararlos correctamente, analizarlos y utilizarlos para entrenar modelos capaces de generalizar hacia situaciones que nunca habían visto anteriormente.

Resulta interesante observar que esta transformación no implica abandonar la programación clásica. De hecho, ocurre exactamente lo contrario. Los modelos de Inteligencia Artificial viven dentro de sistemas informáticos desarrollados por programadores. Un recomendador de películas necesita una aplicación web, una base de datos, un servidor, mecanismos de autenticación, interfaces de usuario y servicios capaces de comunicarse entre sí. El algoritmo de recomendación constituye únicamente una parte del sistema completo.

Esta observación es especialmente importante para ud *(Programador Universitario de Sistemas)*. A lo largo del cursado no se pretende formar investigadores especializados en el diseño matemático de nuevos algoritmos de aprendizaje automático. El objetivo consiste en desarrollar la capacidad de integrar modelos existentes dentro de aplicaciones reales, comprendiendo qué problema resuelven, cuáles son sus limitaciones y en qué situaciones resulta conveniente utilizarlos. Este enfoque coincide con la fundamentación de la asignatura, que prioriza la implementación práctica de soluciones mediante herramientas consolidadas antes que el desarrollo de algoritmos desde cero.

Para comprender mejor esta idea conviene analizar un segundo caso, esta vez relacionado con el ámbito financiero.

Cada minuto un banco procesa miles de transferencias, pagos con tarjeta, retiros de efectivo y operaciones electrónicas. Entre todas esas transacciones pueden ocultarse algunas fraudulentas. El desafío consiste en identificarlas antes de que el dinero sea retirado definitivamente.

¿Cómo resolveríamos este problema mediante programación tradicional?

Podríamos establecer reglas como las siguientes:

1. Si el monto supera cierta cantidad, generar una alerta.
2. Si la operación proviene de otro país, solicitar una verificación adicional.
3. Si el cliente realiza diez transferencias en menos de cinco minutos, bloquear temporalmente la cuenta.

Aunque estas condiciones resultan útiles, rápidamente aparecen excepciones. Un empresario puede realizar transferencias de gran valor todos los días. Un turista puede utilizar su tarjeta en otro país durante sus vacaciones. Un comercio electrónico puede procesar cientos de operaciones legítimas en pocos minutos.

- Cada excepción obliga a modificar nuevamente el programa.
- Con el paso del tiempo las reglas aumentan hasta volverse inmanejables.

En cambio, un modelo entrenado con millones de operaciones históricas puede aprender que determinadas combinaciones de variables aparecen con mucha frecuencia en los fraudes y muy pocas veces en las operaciones legítimas. No necesita conocer el concepto humano de "robo". Simplemente identifica patrones estadísticos que permiten estimar la probabilidad de que una nueva transacción sea anómala.

Este ejemplo resulta especialmente útil para introducir una idea que lo acompañará durante toda la materia: **la Inteligencia Artificial trabaja sobre probabilidades, no sobre certezas absolutas**.

Un sistema de detección de fraude nunca afirmará con seguridad que una operación es fraudulenta. Lo que hará será asignar una probabilidad suficientemente alta como para recomendar una revisión adicional o solicitar una autenticación extra al usuario. Comprender esta diferencia permitirá más adelante interpretar correctamente métricas como precisión, recall o F1-score, que serán estudiadas en las próximas unidades del programa.

1.2. ¿Qué significa realmente que una máquina sea “inteligente”?

Una vez comprendido el contexto histórico y tecnológico que dio origen a la Inteligencia Artificial, surge inevitablemente una nueva pregunta. Cuando afirmamos que un sistema posee "inteligencia", ¿estamos diciendo realmente que piensa como una persona?

La respuesta es no.

Sin embargo, esta afirmación merece una explicación mucho más profunda, ya que constituye uno de los errores conceptuales más frecuentes entre quienes comienzan a estudiar esta disciplina. Incluso hoy, cuando los modelos generativos son capaces de mantener conversaciones,

redactar documentos, escribir código o generar imágenes sorprendentemente realistas, continúa siendo habitual atribuirles capacidades humanas que en realidad no poseen.

Este fenómeno tiene incluso un nombre dentro de la psicología cognitiva: **antropomorfización**, es decir, la tendencia natural que tienen las personas a atribuir características humanas a objetos o sistemas que muestran comportamientos complejos.

No resulta extraño escuchar frases como:

"Chat GPT entendió mi problema."

"La computadora decidió hacer esto."

"El algoritmo pensó que esa era la mejor respuesta."

Desde un punto de vista coloquial estas expresiones pueden resultar aceptables. Sin embargo, desde una perspectiva académica son incorrectas y pueden conducir a interpretaciones equivocadas acerca del funcionamiento real de los sistemas inteligentes.

Para comprender esta diferencia conviene analizar primero cómo aprende una persona.

1.2.1. El aprendizaje humano

Desde los primeros años de vida, los seres humanos construimos conocimiento a partir de experiencias extremadamente variadas. Un niño aprende a reconocer un perro después de observar muchos perros diferentes. Algunos son grandes, otros pequeños; algunos tienen el pelo largo, otros corto; algunos son blancos, otros negros. A pesar de estas diferencias, el cerebro humano logra abstraer características generales que permiten identificar correctamente un nuevo perro aunque nunca haya sido visto anteriormente.

Lo interesante de este proceso es que el niño no necesita miles de ejemplos perfectamente etiquetados. Tampoco requiere que alguien le explique matemáticamente qué distingue a un perro de cualquier otro animal. Su cerebro integra información visual, auditiva y emocional, construyendo progresivamente una representación mental del concepto.

Este tipo de aprendizaje continúa desarrollándose durante toda la vida. Las personas no solo memorizan información; también razonan, establecen relaciones entre conceptos, elaboran hipótesis y utilizan conocimientos adquiridos en situaciones completamente nuevas.

En otras palabras, el aprendizaje humano es extraordinariamente flexible.

1.2.2. El aprendizaje de una máquina

Una computadora, por el contrario, carece completamente de esa capacidad de comprensión.

Para una máquina:

- No existen perros.
- No existen gatos.

- No existen automóviles.
- Ni siquiera existen fotografías.

Lo único que recibe son números.

Esta afirmación suele sorprendernos durante las primeras primeras veces que hablamos de ello, pero constituye uno de los fundamentos más importantes de la Inteligencia Artificial moderna.

Imaginemos una fotografía digital cualquiera.

Supongamos que abrimos una imagen de un perro utilizando un editor de imágenes. Nosotros observamos inmediatamente un animal. Reconocemos su cabeza, sus patas, su cola y probablemente incluso podamos inferir la raza o el estado de ánimo del animal.

La computadora no observa absolutamente nada de eso.

Internamente, esa imagen está representada mediante millones de valores numéricos correspondientes a la intensidad de los colores de cada píxel.

Para el sistema, una fotografía no es más que una enorme matriz de números.

Por ejemplo, una imagen de apenas 1920 × 1080 píxeles contiene más de dos millones de puntos. Si cada uno almacena información correspondiente a los colores rojo, verde y azul, la cantidad de datos que procesa el algoritmo resulta gigantesca.

Entonces aparece una pregunta fundamental.

¿Cómo puede una computadora reconocer un perro si únicamente recibe números?

La respuesta es el corazón mismo del Machine Learning.

En lugar de comprender el significado de la imagen, el algoritmo descubre regularidades matemáticas presentes en millones de ejemplos similares.

Si durante el entrenamiento observa miles de fotografías correctamente etiquetadas como "perro" y miles etiquetadas como "gato", comenzará a identificar patrones estadísticos que aparecen con frecuencia en unas imágenes y no en otras.

El sistema jamás llega a comprender qué es un perro desde un punto de vista biológico. Simplemente aprende que determinadas configuraciones numéricas suelen corresponder a fotografías clasificadas por los seres humanos como "perros".

Esta diferencia puede parecer sutil, pero modifica completamente nuestra forma de entender la Inteligencia Artificial.

- La máquina no comprende.
- La máquina calcula.

1.2.3. Un ejemplo cotidiano: el filtro de spam

Uno de los mejores ejemplos para comprender este concepto se encuentra en un servicio que prácticamente todos utilizamos: el correo electrónico.

Cada día se envían miles de millones de mensajes electrónicos alrededor del mundo. Entre ellos existen comunicaciones legítimas, publicidad, intentos de fraude, campañas de phishing y una enorme cantidad de correo no deseado.

Imaginemos que trabajamos en Google o en la empresa que ud decida pero que sea válida para el ejemplo y debemos desarrollar el filtro de spam de Gmail.

La primera idea probablemente sería escribir reglas.

Podríamos indicar que si un correo contiene determinadas palabras ("ganaste", "premio", "urgente") debe clasificarse como spam.

Al principio el sistema funciona razonablemente bien.

Sin embargo, los atacantes modificarían inmediatamente sus mensajes.

1. En lugar de escribir "premio", utilizarían "pr3mio".
2. Después cambiarían "urgente" por "importante".
3. Más adelante incorporarían imágenes en lugar de texto.
4. Luego utilizarían caracteres invisibles.

Cada nueva estrategia obligaría a modificar nuevamente el programa.

La carrera nunca terminaría.

Aquí aparece nuevamente el mismo patrón observado anteriormente.

- **El problema ya no consiste únicamente en escribir mejores reglas.**
- **El problema consiste en que las reglas cambian constantemente.**

Entonces resulta mucho más eficiente entrenar un modelo utilizando millones de correos previamente clasificados por los propios usuarios.

Cada vez que una persona presiona el botón "Esto es spam", está proporcionando un nuevo ejemplo para mejorar el modelo.

Con el paso del tiempo, el algoritmo aprende combinaciones extremadamente complejas entre palabras, remitentes, horarios, dominios, frecuencia de envío y cientos de variables adicionales imposibles de programar manualmente.

Una vez más, el sistema no entiende el significado del mensaje.

- No sabe leer.

- No comprende el idioma.
- No conoce las intenciones del remitente.

Lo único que hace es detectar patrones matemáticos que históricamente estuvieron asociados con mensajes considerados spam.

1.2.4. ¿Aprender significa memorizar?

En este punto a ud le puede aparecer una pregunta muy interesante.

Si el algoritmo observa millones de ejemplos, ¿simplemente los memoriza?

La respuesta también es negativa.

Supongamos que un alumno se prepara para un examen de programación resolviendo cien ejercicios.

Si durante el examen el docente entrega exactamente uno de esos cien ejercicios, probablemente el estudiante lo resolverá rápidamente porque ya conoce la respuesta.

Pero si el profesor modifica apenas algunos datos y el alumno es incapaz de adaptarse, entonces podemos afirmar que nunca comprendió realmente el tema; únicamente memorizó las soluciones.

Con los modelos de Inteligencia Artificial ocurre algo muy parecido.

Un buen modelo no debe limitarse a recordar los ejemplos utilizados durante el entrenamiento. Debe ser capaz de resolver correctamente situaciones nuevas que nunca había observado.

En términos técnicos, esta capacidad recibe el nombre de **generalización**, y constituye uno de los objetivos centrales del aprendizaje automático.

Un modelo que memoriza todos los datos históricos pero fracasa ante nuevos casos resulta prácticamente inútil en un entorno real.

Más adelante estudiaremos que precisamente uno de los problemas más importantes del Machine Learning es el **sobreajuste** (*overfitting*), fenómeno que ocurre cuando el algoritmo aprende demasiado bien los datos de entrenamiento y pierde capacidad para generalizar. Este concepto será abordado con mayor profundidad en las semanas dedicadas a la evaluación de modelos.

1.2.5. Una pregunta para reflexionar

Llegados a este punto, y empezando a entender de qué va esto, podría formularse la siguiente pregunta:

> *Si una Inteligencia Artificial puede ganar una partida de ajedrez contra el campeón mundial, diagnosticar enfermedades con alta precisión y mantener una conversación*

aparentemente natural, ¿podemos afirmar que realmente comprende lo que está haciendo?

Esta pregunta no busca una respuesta correcta o incorrecta. Su objetivo es mostrar que existe una diferencia fundamental entre **resolver una tarea con gran eficacia** y **comprender el significado profundo de esa tarea**.

Esta distinción acompañará toda la asignatura. Como futuros desarrolladores, es importante evitar atribuir capacidades humanas a sistemas que, aunque extraordinariamente potentes, continúan operando mediante modelos matemáticos construidos a partir de datos.

1.3. Una idea brillante que tuvo que esperar más de medio siglo

Cuando ustedes comienzan a estudiar Inteligencia Artificial suele aparecer una pregunta inevitable. Si actualmente la IA parece encontrarse en todas partes, ¿por qué recién en los últimos años comenzó a hablarse de ella de forma masiva? ¿Acaso la Inteligencia Artificial fue inventada recientemente?

La respuesta es sorprendente. La idea de construir máquinas capaces de resolver problemas inteligentes no es nueva. De hecho, es mucho más antigua de lo que la mayoría imagina. Mucho antes de la existencia de Internet, de los teléfonos inteligentes o incluso de las computadoras personales, varios científicos ya se preguntaban si una máquina podría realizar tareas que tradicionalmente requerían inteligencia humana.

Esta pregunta comenzó a formularse seriamente durante la década de 1950, cuando las computadoras apenas ocupaban habitaciones completas y poseían una capacidad de procesamiento que hoy resultaría insignificante incluso para un reloj inteligente. En aquella época, la informática todavía era una disciplina emergente y las computadoras se utilizaban principalmente para realizar cálculos científicos, militares o financieros.

Uno de los primeros investigadores en plantear esta inquietud fue **Alan Turing**, matemático británico considerado uno de los padres de la informática moderna. Turing propuso una pregunta que todavía hoy continúa siendo objeto de debate:

¿Puede una máquina pensar?

Aunque la formulación parece sencilla, detrás de ella se esconde una enorme complejidad filosófica. ¿Qué significa realmente pensar? ¿Es suficiente con producir respuestas correctas? ¿O pensar implica comprender, razonar y ser consciente de lo que ocurre?

Turing comprendió rápidamente que responder directamente esa pregunta era prácticamente imposible. En lugar de intentar definir el concepto de pensamiento, propuso un experimento mucho más práctico, conocido actualmente como **Test de Turing**.

1.3.1. El Test de Turing: una conversación que cambió la historia

Imaginemos una habitación cerrada. Dentro de ella hay una persona. En otra habitación se encuentran dos interlocutores ocultos. Uno de ellos es otro ser humano. El otro es una computadora. La persona solamente puede comunicarse mediante mensajes escritos y no sabe cuál de los dos responde cada pregunta.

El objetivo consiste en identificar cuál de los interlocutores es humano y cuál es una máquina.

Si después de una conversación prolongada el evaluador no puede distinguir con suficiente seguridad quién es quién, entonces, según el criterio propuesto por Turing, podríamos considerar que la máquina exhibe un comportamiento inteligente.

Es importante detenerse un momento en este punto porque suele generar una interpretación equivocada.

Turing **nunca afirmó que la máquina pensara realmente**. Lo que sostuvo fue algo mucho más prudente: si desde el punto de vista del observador resulta indistinguible del comportamiento humano, entonces podemos considerar que manifiesta una forma de inteligencia funcional.

Este matiz es fundamental y continúa siendo válido incluso en la actualidad.

Cuando una persona conversa con Chat GPT durante varios minutos, puede tener la sensación de estar dialogando con una persona. Sin embargo, esa percepción no implica necesariamente que el modelo posea conciencia, emociones o comprensión del mundo. Lo único que demuestra es que ha logrado producir respuestas suficientemente coherentes como para generar esa impresión.

Pregunta para debatir

"Si una máquina logra engañar a una persona durante una conversación de una hora, ¿eso significa necesariamente que entiende lo que dice?"

No es necesario resolver el debate. De hecho, continúa abierto incluso entre filósofos, psicólogos e investigadores en Inteligencia Artificial.

Lo importante es que podamos comprender que la disciplina no gira alrededor de una única definición de inteligencia, sino alrededor de la capacidad de construir sistemas capaces de resolver problemas cada vez más complejos.

El entusiasmo inicial

Las ideas propuestas por Turing despertaron un enorme entusiasmo en la comunidad científica. Durante las décadas de 1950 y 1960 muchos investigadores estaban convencidos de que el problema de la Inteligencia Artificial sería resuelto en pocos años.

Hoy esa afirmación puede parecer exagerada, pero debemos situarnos en el contexto histórico.

Las primeras computadoras demostraron capacidades sorprendentes para la época. Eran capaces de realizar miles de operaciones por segundo, resolver ecuaciones complejas y ejecutar tareas que anteriormente requerían semanas de trabajo humano.

El progreso tecnológico era tan rápido que muchos científicos imaginaron que, manteniendo ese ritmo de crecimiento, las máquinas pronto podrían razonar, traducir idiomas, reconocer imágenes e incluso mantener conversaciones naturales.

Los periódicos comenzaron a publicar titulares optimistas. Se hablaba de computadoras capaces de reemplazar numerosas tareas intelectuales. Las universidades recibían financiación para crear laboratorios especializados y numerosos gobiernos impulsaban proyectos relacionados con la Inteligencia Artificial.

Parecía que el futuro estaba a la vuelta de la esquina. Sin embargo, ocurrió exactamente lo contrario.

1.3.2. El primer gran fracaso

La realidad terminó siendo mucho más difícil de lo esperado.

Los investigadores comenzaron a descubrir que muchos problemas aparentemente sencillos para una persona resultaban extraordinariamente complejos para una computadora.

- Reconocer un rostro.
- Comprender una oración.
- Identificar un objeto en una fotografía.
- Traducir correctamente un texto.
- Interpretar el contexto de una conversación.

Todas estas tareas parecían triviales para un ser humano, pero escondían una complejidad enorme.

Imaginemos una fotografía de un perro tomada en un parque. Un niño de cuatro años probablemente identifique inmediatamente al animal.

La computadora, en cambio, recibe únicamente millones de números correspondientes a los colores de cada píxel.

1. ¿Cómo distinguir un perro de un gato?
2. ¿Qué ocurre si el perro está parcialmente oculto?
3. ¿Y si la fotografía fue tomada de noche?
4. ¿Y si el animal está acostado?

Cada nueva situación obligaba a redefinir nuevamente las reglas del sistema. Los investigadores comprendieron entonces que el verdadero problema no consistía únicamente en disponer de computadoras más rápidas.

Faltaba algo mucho más importante. Las máquinas necesitaban aprender pero todavía no sabían cómo hacerlo.

1.3.3. El invierno de la Inteligencia Artificial

A finales de la década de 1970 comenzó un período conocido como **AI Winter**, traducido habitualmente como *Invierno de la Inteligencia Artificial*.

El nombre resulta bastante gráfico. Después de varios años de enormes expectativas, los resultados obtenidos eran mucho más modestos de lo prometido. Los gobiernos comenzaron a reducir el financiamiento destinado a la investigación y muchas empresas abandonaron sus proyectos relacionados con IA.

Numerosos laboratorios fueron cerrados, incluso algunos investigadores dejaron de utilizar la expresión "Inteligencia Artificial" porque asociarla con sus proyectos dificultaba la obtención de recursos económicos. Durante varios años pareció que aquella idea brillante simplemente había fracasado. Y, sin embargo, la historia todavía no había terminado.

1.3.4. ¿Realmente había fracasado?

Cuando un proyecto no produce resultados inmediatos, solemos concluir que la idea era incorrecta. Pero en este caso ocurrió algo diferente. La idea era correcta lo que faltaban eran las herramientas necesarias para hacerla realidad podemos utilizar una analogía muy sencilla.

Leonardo da Vinci imaginó máquinas voladoras cinco siglos antes de que existieran los aviones.

¿Significa eso que estaba equivocado?

No.

Simplemente vivía en una época donde todavía no existían motores suficientemente potentes, materiales livianos ni conocimientos aerodinámicos adecuados para construirlas.

Con la Inteligencia Artificial ocurrió algo muy parecido.

Los investigadores comprendían perfectamente hacia dónde querían avanzar. El problema era que las computadoras disponibles no poseían la capacidad suficiente para procesar la enorme cantidad de información necesaria. Además, existía otro obstáculo aún más importante.

No había datos.

1.4. La revolución no comenzó con mejores algoritmos: comenzó con más datos

Como vimos la Inteligencia Artificial atravesó varios períodos de desilusión. Los investigadores tenían buenas ideas, pero las computadoras eran demasiado lentas, la memoria disponible era

escasa y, sobre todo, prácticamente no existían datos suficientes para entrenar modelos capaces de aprender.

Para comprender la magnitud de este problema conviene imaginar cómo era el mundo a principios de la década de 1980. En aquella época, una computadora personal apenas podía almacenar unos pocos megabytes de información. Internet todavía no formaba parte de la vida cotidiana, los teléfonos celulares inteligentes eran inexistentes y la mayor parte de la información continuaba registrándose en papel.

Hoy resulta difícil imaginarlo porque vivimos rodeados de datos, pero durante gran parte del siglo XX el principal problema de los investigadores no era cómo analizar grandes volúmenes de información, sino cómo conseguir información suficiente para trabajar.

Supongamos que un investigador de aquella época quisiera construir un sistema capaz de reconocer automóviles en fotografías.

Actualmente bastaría con descargar millones de imágenes disponibles públicamente en Internet. Existen incluso bases de datos específicamente diseñadas para investigación, donde cada fotografía se encuentra correctamente etiquetada indicando qué objetos aparecen en ella.

Sin embargo, hace cuarenta años esa posibilidad simplemente no existía.

Si el investigador necesitaba mil fotografías de automóviles debía obtenerlas una por una. Luego debía imprimirlas o digitalizarlas utilizando equipos extremadamente costosos. Finalmente, alguien debía clasificarlas manualmente indicando cuáles contenían un automóvil y cuáles no.

El costo económico y el tiempo necesario para reunir un conjunto relativamente pequeño de datos resultaban enormes. Como consecuencia, muchos algoritmos prometedores nunca podían entrenarse adecuadamente, no porque fueran incorrectos o simplemente porque no existía información suficiente para enseñarles.

Aquí aparece una idea que merece quedar grabada en nuestra memoria.

La Inteligencia Artificial depende de los datos del mismo modo que un estudiante depende de los libros para aprender.

Intentemos imaginar una situación cotidiana: Supongamos que un alumno se presenta al examen final de una materia habiendo estudiado únicamente dos páginas del programa.

¿Puede aprobar?

Tal vez tenga suerte y responda correctamente alguna pregunta, pero difícilmente logre desarrollar una comprensión profunda de todos los contenidos.

Ahora imaginemos el caso contrario.

Otro estudiante dispone de bibliografía completa, resuelve ejercicios, consulta distintos autores, participa en clases y estudia durante varios meses.

Naturalmente llegará al examen con una preparación mucho más sólida, con los modelos de Inteligencia Artificial ocurre exactamente lo mismo.

Cuantos más ejemplos representativos reciben durante el entrenamiento, mayores posibilidades tienen de identificar patrones útiles y generalizar correctamente ante situaciones nuevas.

Esta analogía permite introducir uno de los conceptos que nos acompañará durante todo el cuatrimestre: **la calidad de un modelo depende, en gran medida, de la calidad de los datos con los que fue entrenado**.

No importa cuán sofisticado sea un algoritmo. Si la información utilizada durante el entrenamiento es incompleta, incorrecta o sesgada, el modelo inevitablemente aprenderá esas mismas limitaciones.

En ciencia de datos suele utilizarse una expresión muy conocida para describir este fenómeno: **"Garbage In, Garbage Out"**, cuya traducción aproximada sería *"si ingresan datos basura, obtendremos resultados basura"*.

Esta frase, aunque sencilla, resume uno de los principios fundamentales de toda la disciplina.

1.4.1. Internet cambió las reglas del juego

Durante la década de 1990 comenzó a producirse un cambio silencioso que transformaría completamente el panorama.

La expansión de Internet permitió que millones de personas comenzaran a generar información de manera constante.

- Cada correo electrónico enviado.
- Cada página web visitada.
- Cada fotografía publicada.
- Cada búsqueda realizada en Google.
- Cada compra efectuada en una tienda virtual.
- Cada comentario en una red social.
- Cada video reproducido.
- Cada ubicación registrada por un teléfono celular.

Todas estas acciones comenzaron a producir datos digitales, al principio nadie imaginó la importancia que tendrían. Las empresas simplemente almacenaban esa información porque el costo del almacenamiento comenzaba a disminuir rápidamente.

Sin embargo, con el paso de los años ocurrió algo extraordinario.

La humanidad comenzó a producir más información de la que cualquier persona podía analizar manualmente. Y, paradójicamente, aquello que inicialmente parecía un problema terminó convirtiéndose en la mayor oportunidad para el desarrollo de la Inteligencia Artificial.

Por primera vez en la historia existían millones de ejemplos reales sobre los cuales entrenar algoritmos.

- Google podía aprender cómo buscaban los usuarios.
- Amazon podía analizar millones de compras.
- Netflix podía estudiar qué películas veía cada persona.
- Spotify podía descubrir relaciones entre millones de reproducciones musicales.

Los datos comenzaron a convertirse en el combustible de la Inteligencia Artificial. La comparación con el combustible no es casual.

Un automóvil de Fórmula 1 puede poseer un motor extraordinariamente potente. Sin embargo, sin combustible jamás abandonará la línea de largada.

Del mismo modo, un algoritmo extremadamente sofisticado resulta prácticamente inútil si no dispone de datos suficientes para aprender.

Por este motivo, muchas de las empresas tecnológicas más importantes del mundo dedican enormes esfuerzos a recopilar, almacenar y organizar información. No lo hacen únicamente para registrar la actividad de sus usuarios, sino porque esos datos representan la materia prima con la cual entrenan sus modelos.

1.4.2. El poder de cómputo: el segundo ingrediente de la revolución

Los datos, sin embargo, no resolvían por sí solos el problema. Imaginemos nuevamente un escenario cotidiano.

Supongamos que entregamos a un estudiante todos los libros de una biblioteca universitaria y le pedimos que los estudie durante una sola noche.

Aunque disponga de la mejor bibliografía del mundo, simplemente no tendrá tiempo suficiente para procesar semejante cantidad de información, Con las computadoras ocurrió algo parecido.

Durante muchos años los algoritmos existían, los datos comenzaban a aparecer, pero la capacidad de procesamiento seguía siendo insuficiente.

Fue entonces cuando otro avance tecnológico cambió completamente el panorama: las **GPU** (*Graphics Processing Units*).

Originalmente, estas placas fueron diseñadas para renderizar gráficos en videojuegos. Su objetivo era calcular millones de operaciones simultáneamente para representar escenarios tridimensionales cada vez más complejos.

Sin embargo, algunos investigadores descubrieron que esa misma capacidad de procesamiento paralelo podía aprovecharse para entrenar modelos de Inteligencia Artificial muchísimo más rápido que utilizando procesadores tradicionales.

El impacto fue extraordinario, procesos que anteriormente requerían semanas comenzaron a completarse en pocos días.

Posteriormente, tareas que demoraban días pasaron a resolverse en horas y, finalmente, muchas de ellas comenzaron a ejecutarse en cuestión de minutos. La combinación entre grandes volúmenes de datos y mayor capacidad de procesamiento produjo un efecto multiplicador.

Los algoritmos que durante décadas parecían poco prometedores comenzaron, de repente, a obtener resultados sorprendentes, no porque los científicos hubieran descubierto una nueva forma de inteligencia sino porque, por primera vez, disponían de las condiciones necesarias para aplicar ideas que llevaban décadas esperando el momento adecuado.

1.4.3. Un caso real: Netflix y el problema de la elección

Para comprender el impacto de esta transformación, resulta útil analizar un caso conocido por prácticamente todos nosotros.

Cuando Netflix comenzó su expansión internacional, uno de sus mayores desafíos no consistía únicamente en ofrecer películas. El verdadero problema era ayudar al usuario a encontrar qué mirar.

Supongamos que una plataforma posee veinte mil títulos disponibles.

¿Cuánto tiempo tardaría una persona en recorrer manualmente todo el catálogo?

Probablemente abandonaría la aplicación antes de encontrar algo que le interese.

Aquí aparece un fenómeno conocido como **paradoja de la elección**. Cuando las opciones disponibles son excesivas, lejos de facilitar la decisión, terminan dificultándola.

Netflix comprendió rápidamente que su éxito no dependía únicamente de disponer de un gran catálogo sino, que dependía sobre todo, de mostrar rápidamente el contenido adecuado para cada usuario.

Para lograrlo comenzó a analizar enormes cantidades de información.

- Qué películas miraba cada persona.
- Cuánto tiempo permanecía viendo una serie antes de abandonarla.
- En qué horario utilizaba la plataforma.
- Qué géneros prefería.
- Qué actores aparecían con mayor frecuencia entre sus elecciones.

- Qué contenidos resultaban populares entre usuarios con comportamientos similares.

Toda esa información permitió construir modelos capaces de personalizar la experiencia de millones de personas. Es importante remarcar un aspecto que suele sorprender.

Netflix no necesita "conocer" personalmente a sus usuarios. No necesita comprender sus emociones. Ni interpretar psicológicamente sus preferencias.

Lo único que necesita es identificar patrones estadísticos suficientemente consistentes para estimar qué contenido posee mayor probabilidad de resultar atractivo para cada perfil.

Una vez más, la Inteligencia Artificial aparece como una herramienta destinada a descubrir regularidades dentro de enormes cantidades de datos y esta idea nos conduce, naturalmente, al siguiente paso de nuestro recorrido. Si una computadora puede aprender patrones observando ejemplos...

¿cómo ocurre exactamente ese aprendizaje?

Responder esa pregunta significará introducirnos, finalmente, en el concepto de **Machine Learning**, que constituirá el puente hacia el núcleo central de gran parte del resto de la asignatura.

1.5. Machine Learning: cuando el programa deja de seguir reglas y comienza a aprender de los datos

Hasta este momento hemos recorrido un largo camino. Comprendimos que la Inteligencia Artificial no apareció como una moda tecnológica ni como una consecuencia del desarrollo de robots inteligentes. Surgió porque la programación tradicional comenzó a encontrar límites frente a problemas cuya complejidad hacía prácticamente imposible escribir todas las reglas manualmente.

Sin embargo, todavía permanece sin responder la pregunta más importante.

¿Cómo aprende realmente una computadora?

La respuesta a esta pregunta marca el nacimiento de una de las ramas más importantes de la Inteligencia Artificial moderna: el **Machine Learning**, o aprendizaje automático.

El término puede generar cierta confusión durante un primer contacto con la disciplina. Hablar de "aprendizaje" invita naturalmente a pensar en la manera en que aprenden las personas. No obstante, como vimos anteriormente, una computadora no comprende el significado de aquello que observa. No posee intuición, sentido común ni experiencias personales. Entonces, ¿por qué utilizamos la palabra aprender?

En informática, aprender significa algo mucho más específico.

Un sistema aprende cuando es capaz de **modificar su comportamiento utilizando la experiencia obtenida a partir de los datos**, en lugar de depender exclusivamente de reglas escritas por un programador.

Esta definición merece ser analizada cuidadosamente.

En un programa tradicional, cada decisión proviene del código fuente. Si el desarrollador olvidó contemplar una determinada situación, el sistema simplemente no sabrá cómo actuar.

En Machine Learning ocurre algo diferente. El desarrollador continúa escribiendo el programa, pero ya no define todas las reglas del problema. En cambio, diseña un proceso mediante el cual el algoritmo puede descubrir esas reglas observando ejemplos.

En otras palabras, el programador deja de responder directamente la pregunta:

> ***¿Qué debe hacer el sistema?***

y comienza a responder otra muy distinta:

> ***¿Cómo puedo lograr que el sistema descubra por sí mismo la mejor forma de resolver este problema?***

Este cambio de perspectiva constituye probablemente la transformación conceptual más importante de toda la materia.

1.5.1. Un cambio de paradigma

Para visualizar esta diferencia conviene comparar ambos enfoques. Durante décadas, el desarrollo de software siguió una estructura relativamente sencilla.

- Disponíamos de datos de entrada.
- El programador analizaba el problema.
- Escribía las reglas necesarias.
- Y finalmente obteníamos un resultado.

Podríamos representarlo de la siguiente manera.



Figura 1.1 — El enfoque tradicional: el programador define las reglas.

Todo el conocimiento del sistema se encontraba dentro del código escrito por el desarrollador.

Machine Learning invierte completamente ese proceso.

Ahora disponemos de datos y también conocemos cuál debería ser la respuesta correcta para muchos ejemplos. El algoritmo analiza ambos elementos simultáneamente e intenta construir automáticamente un modelo capaz de explicar la relación existente entre ellos. El resultado final ya no es únicamente una respuesta. El resultado es un **modelo**.

Ese modelo será posteriormente utilizado para realizar predicciones sobre datos que nunca había visto.

Gráficamente podría representarse así.

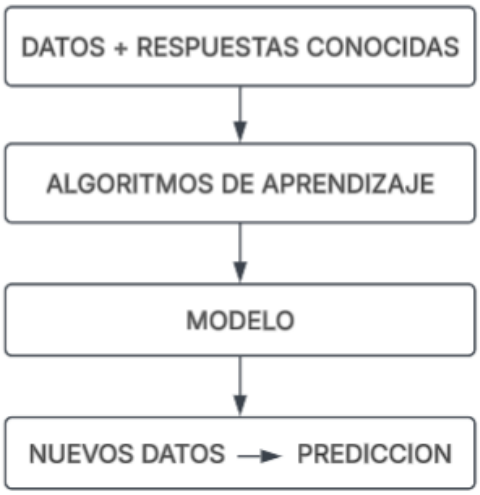


Figura 1.2 — El enfoque de Machine Learning: el modelo se construye a partir de datos y respuestas conocidas.

Esta figura será muy útil para la presentación porque resume visualmente una idea compleja utilizando muy pocos elementos.

1.5.2. Un ejemplo sencillo: aprender a reconocer frutas

Imaginemos que queremos construir un sistema capaz de distinguir manzanas de naranjas.

Si utilizáramos programación tradicional probablemente escribiríamos reglas similares a las siguientes.

- Si el color es rojo, probablemente sea una manzana.
- Si el color es naranja, probablemente sea una naranja.
- Si el diámetro supera determinado valor...
- Si el peso es menor...
- Si la textura...

Rápidamente comenzarían a aparecer excepciones.

- Existen manzanas verdes.
- También existen naranjas pequeñas.
- Algunas frutas presentan manchas.
- Otras poseen colores intermedios.
- La cantidad de reglas aumenta continuamente.

Ahora imaginemos un enfoque diferente.

Reunimos diez mil fotografías correctamente etiquetadas.

- Cinco mil contienen manzanas.
- Cinco mil contienen naranjas.

No escribimos ninguna regla. Simplemente permitimos que el algoritmo observe todos esos ejemplos.

Después del entrenamiento presentamos una fotografía completamente nueva.

Si el modelo fue entrenado correctamente, será capaz de estimar con alta probabilidad a qué categoría pertenece. Lo interesante es que nadie escribió explícitamente la regla que distingue ambas frutas.

Fue el propio algoritmo quien descubrió las características relevantes presentes en los datos. Este ejemplo permite introducir una idea fundamental.

El conocimiento ya no proviene exclusivamente del programador. También proviene de los datos.

1.5.3. Entonces… ¿Qué es exactamente un modelo?

A medida que comenzamos a familiarizarnos con Machine Learning aparece una palabra que será utilizada constantemente durante el resto de la asignatura: **modelo**.

Podemos pensar un modelo como una representación matemática construida a partir de la experiencia.

1. No es un programa tradicional.
2. No es una base de datos.
3. No es un conjunto fijo de reglas escritas manualmente.

Es una estructura matemática cuyos parámetros fueron ajustados utilizando ejemplos históricos.

Una analogía interesante consiste en imaginar un médico con muchos años de experiencia. Después de atender miles de pacientes, comienza a reconocer ciertos patrones clínicos casi de manera inmediata. No recuerda cada consulta individual. Lo que desarrolló fue una experiencia acumulada que le permite estimar rápidamente cuál podría ser el diagnóstico más probable.

Naturalmente esta comparación tiene limitaciones. Un médico comprende fisiología, anatomía, farmacología y razona sobre cada caso. Un modelo de Machine Learning no posee esa comprensión. Sin embargo, la analogía resulta útil para ilustrar que ambos mejoran su desempeño a medida que incorporan más experiencias, aunque lo hagan mediante mecanismos completamente distintos.

1.5.4. Aprender no significa ser perfecto

Existe otro aspecto que resulta importante aclarar. Con frecuencia los medios de comunicación presentan la Inteligencia Artificial como si fuera una tecnología infalible.

Esta percepción resulta completamente equivocada, un modelo nunca garantiza respuestas absolutamente correctas. Siempre existe la posibilidad de equivocarse, incluso los mejores sistemas del mundo producen errores.

- Un vehículo autónomo puede interpretar incorrectamente una señal.
- Un recomendador puede sugerir una película que no nos interesa.
- Un detector de fraude puede bloquear temporalmente una operación legítima.
- Un sistema de reconocimiento facial puede confundirse entre personas con características similares.

La diferencia no consiste en eliminar completamente el error. La diferencia consiste en lograr que el porcentaje de aciertos resulte suficientemente alto como para aportar valor en un contexto real.

Esta idea será especialmente importante cuando estudiemos métricas de evaluación durante las próximas semanas. En Machine Learning no hablamos de programas "correctos" o "incorrectos"; hablamos de modelos con mayor o menor capacidad predictiva.

1.6. El mapa de la materia: dónde estamos y hacia dónde vamos

Una de las mayores dificultades de quienes comienzan a estudiar Inteligencia Artificial es la enorme cantidad de términos nuevos: aprendizaje supervisado, aprendizaje no supervisado, clasificación, regresión, clustering, redes neuronales, recomendadores, árboles de decisión, entre muchos otros.

Si estos conceptos aparecen de manera aislada, se puede percibir la materia como una colección de algoritmos sin relación entre sí. Por ese motivo, antes de profundizar en cualquiera de ellos conviene presentar un mapa general del recorrido que realizará la asignatura.

En la parte superior del esquema ubicaremos la **Inteligencia Artificial**, entendida como el área amplia que busca desarrollar sistemas capaces de resolver problemas que normalmente asociamos con capacidades inteligentes.

Dentro de ella encontraremos una de sus ramas más importantes: el **Machine Learning**, disciplina que estudia cómo construir modelos capaces de aprender a partir de los datos.

A partir de ese punto, el camino comienza a dividirse.

Por un lado aparecerá el **Aprendizaje Supervisado**, donde el algoritmo aprende utilizando ejemplos cuya respuesta correcta ya es conocida. Este será el tema central de las primeras semanas de la materia y permitirá abordar problemas como la clasificación de imágenes, la detección de fraude o la predicción de abandono de clientes, tal como se plantea en la planificación de la asignatura.

Por otro lado estudiaremos el **Aprendizaje No Supervisado**, donde los datos no poseen etiquetas y el objetivo consiste en descubrir estructuras ocultas, agrupar elementos similares o identificar relaciones que previamente no conocíamos. En esta parte aparecerán algoritmos como K-Means, DBSCAN y posteriormente las reglas de asociación y los sistemas de recomendación, siguiendo el recorrido previsto para las semanas finales del programa.

Este mapa no pretende explicar todavía cada algoritmo. Su función es mucho más importante: ofrecer una visión global del camino que se recorrerá durante el cuatrimestre. Es el equivalente al plano de una ciudad antes de comenzar un viaje. Todavía no conocemos cada calle, pero ya sabemos cuál será la dirección general.

Lo verdaderamente importante es que se haya modificado la manera de comprender el desarrollo de software.

Hasta hoy probablemente se concebía la programación como el proceso de escribir instrucciones que una computadora debía ejecutar exactamente en el orden establecido por el desarrollador. A partir de ahora se comienza a descubrir que existe otro paradigma complementario, en el cual el

papel del programador ya no consiste únicamente en escribir reglas, sino también en diseñar procesos capaces de aprender a partir de la información disponible.

Ese cambio de perspectiva constituye el verdadero punto de partida de la Inteligencia Artificial moderna.

Durante el resto de la asignatura iremos profundizando progresivamente en cada una de las herramientas que hacen posible este aprendizaje. Comenzaremos por el aprendizaje supervisado, avanzaremos hacia técnicas no supervisadas y finalizaremos aplicando estos conocimientos a problemas reales como la segmentación de clientes, los sistemas de recomendación y el análisis de reglas de asociación.

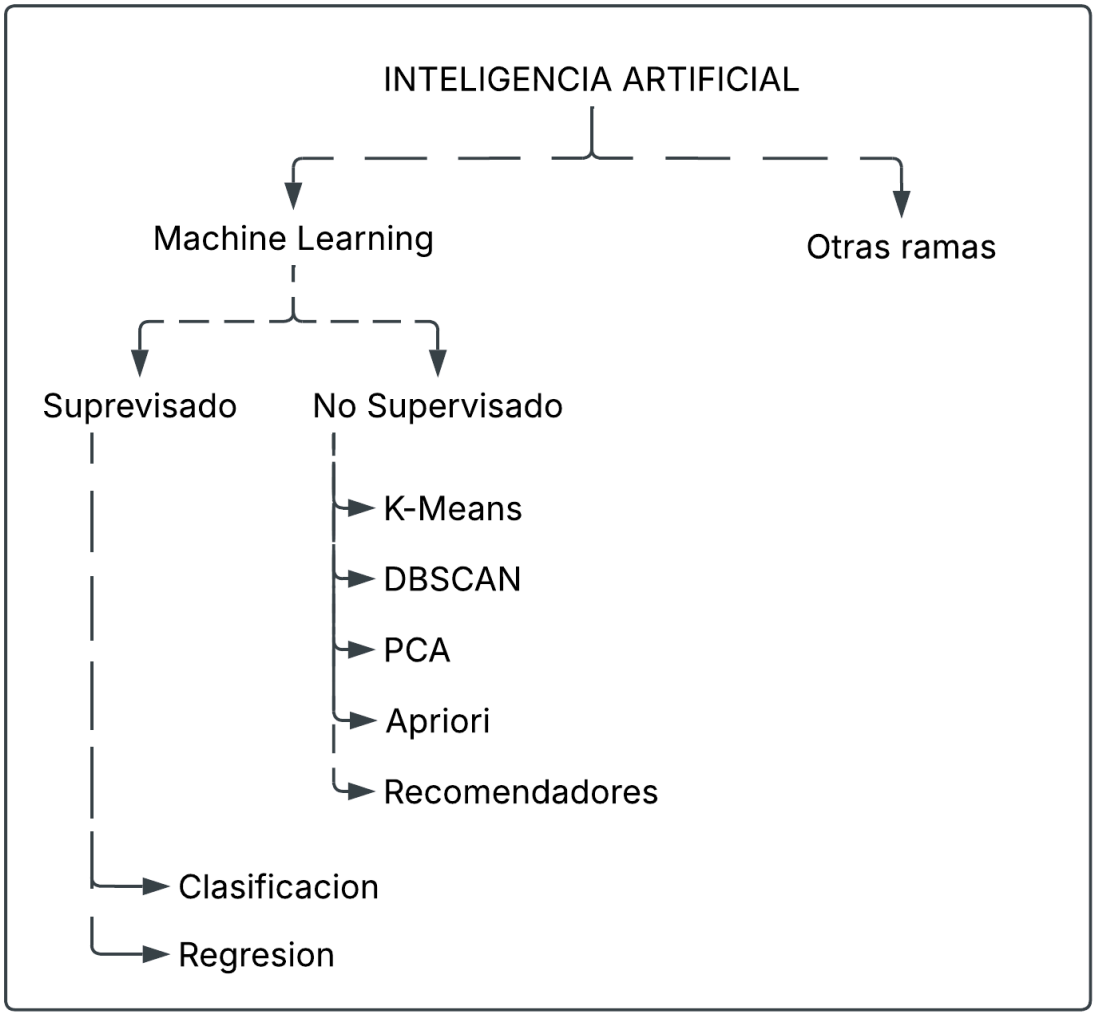


Figura 1.3 — Mapa general de la materia.