Unidad 2. Machine Learning: aprender a partir de los datos

2.1. Cuándo programar ya no alcanza: el nacimiento del aprendizaje automático

En el capítulo anterior llegamos a una conclusión que modificó la manera tradicional de entender el desarrollo de software. Durante décadas, programar significó describir con precisión todas las reglas que una computadora debía seguir para resolver un problema. Ese enfoque continúa siendo válido para una enorme cantidad de aplicaciones, desde sistemas de gestión empresarial hasta plataformas de comercio electrónico. Sin embargo, también vimos que existen situaciones donde esa estrategia deja de ser suficiente.

Problemas como reconocer rostros, traducir automáticamente un texto, detectar operaciones bancarias fraudulentas o recomendar una película adecuada para cada usuario poseen una característica en común: las reglas que gobiernan el problema son demasiado numerosas, demasiado cambiantes o demasiado complejas como para ser escritas manualmente por un programador.

Frente a esta dificultad apareció una idea completamente diferente. En lugar de dedicar meses o incluso años intentando describir todas las situaciones posibles, ¿sería posible construir un sistema capaz de descubrir esas reglas por sí mismo observando ejemplos?

Esa pregunta dio origen al **Machine Learning**, una de las ramas más importantes de la Inteligencia Artificial moderna.

Es importante detenerse un momento para comprender el verdadero alcance de esta idea. Cuando escuchamos la expresión *aprendizaje automático*, muchas veces imaginamos computadoras que aprenden de una manera similar a las personas. Sin embargo, esa interpretación puede resultar engañosa. Una computadora no desarrolla curiosidad, no formula preguntas por iniciativa propia ni adquiere experiencias como lo hace un ser humano. Lo que realmente ocurre es que determinados algoritmos modifican internamente sus parámetros a medida que procesan grandes cantidades de datos, mejorando progresivamente su capacidad para realizar una tarea específica.

En otras palabras, el aprendizaje automático no consiste en dotar a la máquina de inteligencia humana, sino en permitirle encontrar relaciones matemáticas que resultan demasiado complejas para ser descubiertas manualmente.

Esta diferencia puede parecer sutil, pero cambia completamente nuestra forma de pensar el desarrollo de software.

Hasta hace algunos años, la calidad de un programa dependía casi exclusivamente de la habilidad del desarrollador para escribir reglas correctas. En Machine Learning ocurre algo diferente. El

programador continúa siendo indispensable, pero ahora su responsabilidad principal consiste en formular correctamente el problema, seleccionar los datos adecuados, elegir el algoritmo apropiado y evaluar si el modelo obtenido realmente aprende aquello que se espera.

El conocimiento deja de estar únicamente en el código fuente. Comienza a construirse también a partir de los datos.

Esta afirmación resume uno de los cambios más profundos que ha experimentado la informática durante las últimas décadas.

2.1.1. Aprender observando ejemplos

Para comprender esta transformación conviene abandonar por un momento el mundo de las computadoras y pensar en una situación completamente cotidiana.

Imaginemos un profesor que comienza a trabajar por primera vez en una universidad. Durante los primeros días apenas conoce a sus estudiantes. Todos le resultan desconocidos y todavía no puede anticipar cómo trabajará cada uno durante el cuatrimestre.

Sin embargo, a medida que transcurren las semanas comienza a observar ciertos comportamientos. Algunos alumnos participan activamente en clase, realizan consultas frecuentes y entregan todas las actividades prácticas. Otros, en cambio, faltan con regularidad, estudian únicamente antes de los exámenes y presentan dificultades para completar las tareas propuestas.

Después de varios años de experiencia, ese profesor desarrolla una capacidad interesante. Sin necesidad de conocer el resultado final, muchas veces puede estimar cuáles estudiantes probablemente aprobarán la materia y cuáles necesitarán un acompañamiento adicional.

¿Significa esto que el docente posee una capacidad sobrenatural?

Por supuesto que no.

Lo que ocurrió fue algo mucho más sencillo y, al mismo tiempo, profundamente significativo. Su cerebro fue acumulando experiencias hasta identificar patrones que aparecen repetidamente entre alumnos con desempeños similares.

Cada nuevo curso aporta información adicional. Algunas intuiciones se fortalecen, otras desaparecen y otras deben ser revisadas porque la realidad demuestra que no eran correctas. En definitiva, el profesor aprende a partir de la experiencia.

Este ejemplo resulta particularmente útil porque nos permite introducir una idea esencial del Machine Learning. Un algoritmo también aprende observando ejemplos históricos. La diferencia es que, mientras el docente construye conocimiento mediante procesos cognitivos extraordinariamente complejos, la computadora lo hace ajustando relaciones matemáticas entre los datos disponibles.

- No existe comprensión.

- No existe intuición.
- No existe sentido común.

Existe, simplemente, un proceso de optimización matemática cuyo objetivo consiste en encontrar regularidades suficientemente consistentes como para realizar predicciones sobre situaciones futuras.

2.1.2. La experiencia también puede equivocarse

Hasta aquí podría parecer que aprender consiste únicamente en acumular experiencias. Sin embargo, tanto las personas como los modelos de Machine Learning pueden aprender de manera incorrecta.

Supongamos que un médico observa durante varios años únicamente pacientes pediátricos. Su experiencia clínica será extraordinariamente valiosa para diagnosticar enfermedades infantiles. Pero si de un día para otro comienza a trabajar exclusivamente con adultos mayores, descubrirá rápidamente que muchos de los patrones que había aprendido ya no resultan suficientes. Deberá incorporar nuevos conocimientos y adaptar su experiencia a una población completamente distinta.

Con los algoritmos ocurre exactamente lo mismo.

Si un modelo fue entrenado utilizando información incompleta, sesgada o poco representativa, las conclusiones que obtenga también estarán limitadas por esa información.

Este aspecto tiene enormes implicancias prácticas.

Durante mucho tiempo se creyó que el éxito de un proyecto de Inteligencia Artificial dependía principalmente de seleccionar el algoritmo más sofisticado. Hoy sabemos que esa idea es incorrecta. Numerosas investigaciones y experiencias industriales muestran que gran parte del éxito de un modelo depende de la calidad de los datos utilizados durante el entrenamiento.

Por este motivo, en proyectos reales de ciencia de datos suele dedicarse mucho más tiempo a recopilar, limpiar y preparar la información que al entrenamiento propiamente dicho. Diversos estudios de la industria estiman que entre el 60 % y el 80 % del tiempo total de un proyecto puede invertirse en tareas relacionadas con la preparación y comprensión de los datos, mientras que el entrenamiento del modelo representa solo una parte del proceso.

Este hecho suele sorprender a quienes se acercan por primera vez al Machine Learning. Existe una percepción bastante difundida de que el trabajo más importante consiste en ejecutar un algoritmo complejo. Sin embargo, la experiencia demuestra exactamente lo contrario. Un modelo sencillo entrenado con datos de excelente calidad suele obtener mejores resultados que un algoritmo extremadamente sofisticado alimentado con información deficiente.

Aquí aparece una enseñanza que acompañará toda la asignatura.

Los datos no son un complemento del algoritmo. Son parte del algoritmo.

Desde el punto de vista práctico, un modelo aprende únicamente aquello que los datos le permiten aprender. Si los ejemplos contienen errores, omisiones o representan solo una pequeña parte de la realidad, el modelo inevitablemente heredará esas mismas limitaciones.

Esta observación nos conduce naturalmente a la siguiente pregunta.

Si los datos constituyen el elemento central del aprendizaje automático, **¿qué tipo de información necesita exactamente un algoritmo para comenzar a aprender?**

2.2. Los datos: la materia prima del aprendizaje

En la sección anterior afirmamos que un modelo de Machine Learning aprende a partir de los datos. Esta idea aparece repetidamente en libros, artículos científicos y cursos introductorios, hasta el punto de convertirse en una frase casi automática dentro del área. Sin embargo, pocas veces nos detenemos a analizar qué significa realmente.

Cuando decimos que un algoritmo aprende utilizando datos, ¿de qué tipo de información estamos hablando? ¿Qué forma tienen esos datos? ¿Cómo los interpreta una computadora? ¿Existe alguna estructura específica que deban respetar?

Responder estas preguntas resulta fundamental porque, independientemente del algoritmo que utilicemos en el futuro, todos ellos trabajarán sobre una representación organizada de la información.

Imaginemos que una universidad desea desarrollar un sistema capaz de anticipar qué estudiantes presentan riesgo de abandonar una materia antes del primer examen parcial. El objetivo no consiste en reemplazar al docente ni en decidir automáticamente el futuro académico de una persona. La finalidad es mucho más práctica: detectar tempranamente a aquellos estudiantes que podrían necesitar apoyo adicional para evitar el abandono.

Para construir ese sistema, la universidad dispone de información correspondiente a varios años de cursado. Entre los datos registrados aparecen variables como la cantidad de clases asistidas, las actividades prácticas entregadas, el tiempo promedio dedicado al estudio semanal y la calificación obtenida en el examen final.

Si organizáramos esa información en una planilla de cálculo, probablemente observaríamos algo similar a esto:

Asistencia (%)	Horas de estudio	Trabajos prácticos	¿Aprobó?
95	12	8	Sí
82	9	7	Sí
40	2	1	No
67	5	4	No

Asistencia (%)	Horas de estudio	Trabajos prácticos	¿Aprobó?
91	11	8	Sí

A primera vista parece una tabla bastante común. De hecho, podría haber sido construida en Excel, LibreOffice Calc o cualquier gestor de bases de datos.

Sin embargo, para un algoritmo de Machine Learning esta tabla representa mucho más que una simple colección de números.

Constituye la experiencia sobre la cual aprenderá.

- Cada fila representa un caso real ocurrido en el pasado.
- Cada columna describe una característica de ese caso.
- Y la última columna indica cuál fue el resultado observado.

En otras palabras, estamos mostrando al algoritmo miles de historias resumidas en forma numérica.

- No le explicamos qué significa estudiar.
- No le enseñamos qué es la responsabilidad.
- Tampoco le hablamos sobre motivación, disciplina o esfuerzo.

Simplemente le mostramos ejemplos históricos y dejamos que descubra por sí mismo qué relaciones parecen existir entre las distintas variables.

Esta idea puede parecer sorprendente al principio.

Los seres humanos tendemos a explicar los fenómenos mediante conceptos. Cuando un profesor intenta ayudar a un estudiante, suele razonar en términos de compromiso, hábitos de estudio, contexto familiar o motivación personal. El algoritmo, en cambio, desconoce completamente esos conceptos.

Para él solamente existen números. Y, sin embargo, muchas veces esos números contienen suficiente información como para construir modelos sorprendentemente precisos.

2.2.1. Las variables: distintas formas de describir una misma realidad

Cada una de las columnas de la tabla anterior recibe el nombre de **variable** o **característica** (*feature*).

Las variables representan distintos aspectos del problema que deseamos analizar.

En el ejemplo universitario utilizamos la asistencia, las horas de estudio y la cantidad de trabajos prácticos entregados porque suponemos que estos factores guardan alguna relación con el rendimiento académico.

Pero imaginemos por un momento un problema completamente diferente.

Supongamos que deseamos construir un sistema capaz de estimar el precio de una vivienda.

Naturalmente ya no tendría sentido utilizar las horas de estudio o la asistencia a clases. En este nuevo escenario aparecerían variables completamente distintas: la superficie del terreno, la cantidad de habitaciones, la antigüedad del inmueble, la ubicación geográfica, la existencia de cochera o la distancia al centro de la ciudad.

Observemos que el algoritmo continúa siendo el mismo. Lo único que cambia es la información que recibe. Esto demuestra una característica extraordinariamente poderosa del Machine Learning.

Los algoritmos no están diseñados para resolver un único problema específico. Lo que cambia de un proyecto a otro no suele ser el mecanismo de aprendizaje, sino la representación de la realidad mediante variables adecuadas.

Por este motivo, uno de los trabajos más importantes dentro de un proyecto de Inteligencia Artificial consiste precisamente en decidir **qué información resulta relevante** y cuál puede descartarse.

Esta tarea, conocida como **selección de características** (*feature selection*), constituye una de las actividades más importantes de la ingeniería de datos y, en muchos casos, tiene un impacto mayor sobre la calidad del modelo que la elección del algoritmo de aprendizaje.

2.2.2. No toda la información resulta útil

Si los datos permiten aprender, entonces cuanto mayor sea la cantidad de información disponible, mejores serán necesariamente los resultados. Aunque esta afirmación parece razonable, en la práctica no siempre es cierta.

Imaginemos nuevamente el problema de predecir el rendimiento académico.

Además de las variables ya mencionadas, decidimos incorporar la marca del teléfono celular utilizado por cada estudiante.

¿Existe alguna razón objetiva para pensar que poseer un determinado modelo de teléfono influye directamente sobre la aprobación de una materia? Probablemente no.

Podría ocurrir que, por casualidad, muchos estudiantes aprobados utilicen un determinado dispositivo. Sin embargo, esa coincidencia no implica una relación causal.

Si el algoritmo comienza a utilizar esa información para realizar predicciones, es posible que construya patrones completamente equivocados. Este ejemplo introduce una diferencia muy importante entre dos conceptos que con frecuencia se confunden.

Correlación y **causalidad**.

Dos variables pueden aparecer relacionadas estadísticamente sin que una sea la causa de la otra. En ciencia de datos esta diferencia resulta fundamental. Un modelo puede detectar relaciones extremadamente fuertes entre determinadas variables, pero corresponde al especialista del dominio decidir si esas relaciones poseen realmente sentido desde el punto de vista del problema.

Por esta razón, el desarrollo de un sistema de Machine Learning nunca constituye una tarea exclusivamente informática.

- En un proyecto médico participan profesionales de la salud.
- En un proyecto financiero intervienen economistas y analistas de riesgo.
- En un proyecto agrícola colaboran ingenieros agrónomos.

Y en un laboratorio clínico —un ejemplo especialmente cercano para nosotros como futuros desarrolladores de sistemas— resulta indispensable trabajar junto a bioquímicos y profesionales del diagnóstico. Ellos son quienes comprenden el significado clínico de los datos y pueden determinar cuáles variables poseen verdadero valor predictivo y cuáles simplemente representan coincidencias sin importancia.

Esta colaboración interdisciplinaria constituye una de las características más interesantes de la Inteligencia Artificial aplicada.

El éxito del proyecto depende tanto del conocimiento informático como del conocimiento específico del área donde el modelo será utilizado.

2.2.3. La respuesta que el algoritmo intenta descubrir

Hasta ahora analizamos las variables utilizadas para describir un problema. Sin embargo, todavía falta un elemento indispensable. Volvamos nuevamente a nuestra tabla de estudiantes.

Las columnas correspondientes a la asistencia, las horas de estudio y los trabajos prácticos representan información de entrada. Pero existe una última columna, denominada **¿Aprobó?**, que cumple un papel completamente diferente.

No describe al estudiante. Describe el resultado que deseamos aprender a predecir.

En Machine Learning esta información recibe el nombre de **etiqueta**, **variable objetivo** (*target*) o **clase**, dependiendo del tipo de problema que estemos resolviendo.

La presencia de esta columna modifica completamente el proceso de aprendizaje.

Ahora el algoritmo ya no observa únicamente datos. También conoce cuál fue el resultado correcto para cada caso histórico.

Es precisamente esa combinación entre información de entrada y respuesta conocida la que permitirá construir un modelo capaz de realizar predicciones sobre estudiantes que todavía no

cursaron la materia. Profundizaremos sobre este mecanismo y responderemos una pregunta que suele generar mucha curiosidad entre quienes comienzan a estudiar Inteligencia Artificial:

¿Qué ocurre exactamente durante el entrenamiento de un modelo?

Es decir, una vez que el algoritmo recibe miles de ejemplos correctamente organizados, ¿qué hace internamente para transformar esa información en conocimiento capaz de generar nuevas predicciones?

2.3. El entrenamiento: el momento en que el algoritmo comienza a aprender

Hasta este punto hemos analizado cuáles son los elementos que forman parte de un problema de Machine Learning. Sabemos que disponemos de un conjunto de datos históricos, que cada registro representa un caso real ocurrido en el pasado y que cada columna describe alguna característica de ese caso. También vimos que, en determinadas situaciones, conocemos cuál fue el resultado correcto para cada ejemplo.

Sin embargo, todavía no hemos respondido la pregunta central de este capítulo.

¿Qué hace realmente el algoritmo con toda esa información?

Cuando en los medios de comunicación se afirma que una Inteligencia Artificial fue "entrenada", suele generarse la impresión de que la computadora estudia los datos de una manera similar a un estudiante que lee un libro. Incluso algunas personas imaginan que el sistema analiza cada ejemplo, reflexiona sobre él y finalmente comprende cómo resolver el problema.

Naturalmente, nada de eso ocurre.

La palabra *entrenamiento* se utiliza porque resulta intuitiva para las personas, pero desde el punto de vista informático describe un proceso estrictamente matemático.

Entrenar un modelo significa **ajustar una serie de parámetros internos hasta encontrar una representación matemática capaz de explicar, de la mejor manera posible, la relación existente entre las variables de entrada y el resultado esperado**.

Aunque esta definición pueda parecer compleja, la idea que esconde resulta mucho más sencilla de lo que parece.

2.3.1. Aprender mediante prueba y error

Una forma intuitiva de comprender el entrenamiento consiste en pensar en cómo aprende un niño a lanzar una pelota hacia un aro de básquet.

La primera vez que lo intenta probablemente falle, tal vez lance demasiado fuerte, quizás el ángulo no sea el adecuado o simplemente la dirección sea incorrecta.

Sin embargo, después de cada intento ocurre algo muy importante.

El niño observa el resultado, corrige ligeramente su movimiento y vuelve a intentarlo.

Cada nuevo lanzamiento incorpora información que antes no tenía.

Después de muchos intentos, sin haber resuelto ninguna ecuación física ni calculado trayectorias parabólicas, comienza a lanzar con mucha mayor precisión.

Su cerebro fue ajustando pequeños detalles a partir de la experiencia acumulada.

Los modelos de Machine Learning realizan un proceso sorprendentemente parecido. Al comenzar el entrenamiento, el algoritmo no posee ningún conocimiento sobre el problema sus parámetros internos pueden considerarse prácticamente aleatorios, cuando recibe el primer conjunto de ejemplos intenta producir una respuesta. Naturalmente, casi siempre se equivoca pero aquí aparece el aspecto más importante de todo el proceso el algoritmo **mide cuánto se equivocó**.

No basta con saber que una respuesta fue incorrecta. Es necesario cuantificar el error.

- ¿Cuán lejos estuvo del resultado esperado?
- ¿El error fue pequeño?
- ¿Fue enorme?
- ¿Se equivocó siempre en la misma dirección?

Una vez calculado ese error, el algoritmo modifica ligeramente sus parámetros internos para intentar reducirlo.

- Luego vuelve a procesar todos los ejemplos.
- Calcula nuevamente el error.
- Realiza otra pequeña corrección.
- Y repite el procedimiento cientos, miles o incluso millones de veces.

Cada repetición recibe el nombre de **iteración** o, en muchos algoritmos, **época** (*epoch*).

Entrenar significa **equivocarse, medir el error y corregirse repetidamente**.

2.3.2. Un ejemplo real: predicción del precio de una vivienda

Supongamos ahora que una inmobiliaria desea estimar el precio de las viviendas que ingresan diariamente al mercado. Para ello dispone de información correspondiente a miles de operaciones realizadas durante los últimos años.

Cada registro contiene datos como la superficie construida, la cantidad de habitaciones, la antigüedad del inmueble, la presencia de cochera, el barrio donde se encuentra ubicada la propiedad y el precio final al que efectivamente fue vendida.

Nuestro objetivo consiste en construir un modelo capaz de estimar cuánto podría valer una vivienda nueva antes de ponerla a la venta. Cuando comienza el entrenamiento, el algoritmo todavía no sabe absolutamente nada sobre el mercado inmobiliario.

Presentamos la primera vivienda.

> *El precio real fue de **US$120.000**. El algoritmo responde: **US$185.000.***

Claramente se equivocó. La diferencia es considerable, ahora mostramos una segunda vivienda.

> *Precio real: **US$95.000.** Predicción del modelo: **US$70.000.***

Nuevamente aparece un error. Sin embargo, el algoritmo no "se frustra" ni intenta comprender por qué falló. Simplemente utiliza esa diferencia para modificar internamente sus parámetros matemáticos. Después de procesar miles de ejemplos, las predicciones comienzan a mejorar.

Más adelante el modelo estima:

> *Precio real: **US$180.000.** Predicción: **US$177.500.***

Ahora el error resulta mucho menor. No porque alguien le haya explicado las reglas del mercado inmobiliario. Sino porque encontró relaciones matemáticas suficientemente consistentes entre las características de las viviendas y el precio final observado históricamente.

Esta idea representa uno de los principios fundamentales del aprendizaje automático.

El modelo nunca aprende un caso aislado. Aprende relaciones generales presentes en miles de ejemplos.

2.3.3. ¿Qué ocurre dentro del algoritmo?

La respuesta depende del algoritmo utilizado.

- Un árbol de decisión aprende de una manera completamente diferente a una red neuronal.
- Una regresión lineal utiliza procedimientos distintos de un algoritmo K-Means.
- Random Forest, Support Vector Machines y Gradient Boosting también poseen mecanismos propios.

Sin embargo, todos comparten una misma filosofía. Comienzan realizando predicciones muy malas.

Miden el error - Ajustan sus parámetros - Vuelven a intentarlo.

Repiten el proceso hasta que el error deja de disminuir o alcanza un nivel considerado aceptable. Es interesante observar que esta lógica no pertenece exclusivamente a la informática. También aparece en numerosos procesos de aprendizaje humanos.

- Un músico mejora interpretando una obra cientos de veces.
- Un deportista perfecciona su técnica después de miles de repeticiones.
- Un programador desarrolla mayor habilidad escribiendo código durante años.

En todos los casos existe una secuencia común: **práctica, evaluación, corrección y nueva práctica**.

Naturalmente, esta analogía tiene límites. Un ser humano comprende, reflexiona y puede transferir conocimientos entre contextos muy diferentes. Un algoritmo no posee esas capacidades. Sin embargo, ambos procesos comparten una idea general: el desempeño mejora mediante ajustes sucesivos basados en la experiencia.

2.3.4. Entrenar no significa memorizar

Existe un error conceptual que aparece con mucha frecuencia entre quienes comienzan a estudiar Machine Learning. Si el algoritmo analiza miles de ejemplos históricos, ¿simplemente memoriza las respuestas? La respuesta es no.

Y comprender por qué no lo hace resulta absolutamente fundamental. Volvamos nuevamente al contexto universitario.

Imaginemos que un estudiante memoriza exactamente las respuestas de todos los exámenes tomados durante los últimos diez años.

Cuando llega el examen final, el profesor presenta ejercicios completamente nuevos, aunque los temas sean los mismos, las preguntas fueron modificadas si el estudiante solamente memorizó respuestas, probablemente fracase. En cambio, si comprendió los conceptos, será capaz de resolver situaciones que nunca había visto anteriormente.

Con los modelos ocurre exactamente lo mismo. El verdadero objetivo del entrenamiento no consiste en recordar ejemplos históricos sino en construir un modelo capaz de **generalizar**.

Generalizar significa utilizar la experiencia obtenida durante el entrenamiento para tomar decisiones correctas frente a situaciones completamente nuevas. Si un modelo únicamente recuerda los datos utilizados para entrenarse, entonces resulta prácticamente inútil.

- En un hospital deberá diagnosticar pacientes que nunca atendió.
- En un banco analizará operaciones que jamás había visto.
- En una plataforma de streaming recomendará películas a usuarios nuevos.

En todos estos casos, la capacidad de generalización constituye el verdadero indicador de que el aprendizaje fue exitoso.

Por este motivo, uno de los desafíos más importantes del Machine Learning consiste en encontrar un equilibrio. El modelo debe aprender suficientemente bien los patrones presentes en los datos

históricos, pero evitando memorizar detalles irrelevantes que solamente aparecen en esos ejemplos particulares.

Más adelante veremos que precisamente de este equilibrio nacen dos conceptos fundamentales: **underfitting** y **overfitting**, problemas que analizaremos con profundidad cuando estudiemos la evaluación de modelos.

2.3.5. Una pregunta para debatir

> *Supongamos que un modelo fue entrenado utilizando únicamente datos correspondientes a estudiantes de Ingeniería. ¿Podría utilizarse inmediatamente para predecir el rendimiento de alumnos de Medicina, Derecho o Arquitectura? ¿Por qué?*

2.4. Dos momentos completamente distintos: aprender y utilizar lo aprendido

Cuando una persona escucha por primera vez que un modelo de Inteligencia Artificial fue entrenado, suele imaginar que ese aprendizaje continúa permanentemente mientras el sistema está siendo utilizado. La idea parece razonable. Después de todo, los seres humanos aprendemos durante toda la vida. Cada nueva experiencia modifica, aunque sea ligeramente, nuestros conocimientos previos.

Sin embargo, la mayoría de los modelos de Machine Learning utilizados actualmente funcionan de una manera diferente.

En términos generales, es posible distinguir dos etapas claramente separadas. La primera corresponde al **entrenamiento**. La segunda corresponde al **uso del modelo**, proceso que habitualmente recibe el nombre de **inferencia** o **predicción**.

Comprender esta diferencia evitará numerosas confusiones cuando comencemos a desarrollar nuestros primeros modelos durante las clases prácticas. Durante el entrenamiento, el algoritmo recibe miles o incluso millones de ejemplos históricos. Analiza cada uno de ellos, calcula el error de sus predicciones, ajusta sus parámetros internos y repite el proceso una y otra vez hasta construir un modelo capaz de representar adecuadamente el problema que se intenta resolver.

Ese proceso puede demandar desde algunos segundos hasta varios días de trabajo, dependiendo de la complejidad del algoritmo y del volumen de información disponible. Una vez finalizado el entrenamiento, el modelo queda listo para ser utilizado. Y aquí ocurre algo muy importante.

El entrenamiento termina.

A partir de ese momento el sistema ya no está aprendiendo simplemente utiliza el conocimiento adquirido para realizar nuevas predicciones. Esta idea puede parecer extraña al principio porque solemos asociar la Inteligencia Artificial con sistemas que evolucionan constantemente. Sin embargo, en la práctica la mayor parte de las aplicaciones comerciales funcionan precisamente de esta manera.

2.4.1. Un ejemplo cotidiano: el filtro de correo electrónico

Volvamos a uno de los ejemplos mencionados en el capítulo anterior.

Todos utilizamos diariamente servicios de correo electrónico como Gmail o Outlook. Cada vez que recibimos un mensaje, el sistema decide casi instantáneamente si debe colocarlo en la bandeja principal o enviarlo directamente a la carpeta de spam. La rapidez con la que ocurre este proceso puede dar la impresión de que el algoritmo está aprendiendo en ese mismo instante.

En realidad, no es así.

Antes de llegar a nuestras computadoras, ese modelo fue entrenado utilizando millones de correos electrónicos previamente clasificados. Durante ese entrenamiento aprendió patrones relacionados con el contenido del mensaje, el remitente, la frecuencia de envío, determinados dominios, características del texto y muchas otras variables imposibles de analizar manualmente.

Cuando nosotros recibimos un nuevo correo, el algoritmo ya no necesita volver a aprender. Simplemente aplica el modelo que construyó anteriormente y produce una predicción en una fracción de segundo.

Naturalmente, las empresas vuelven a entrenar periódicamente esos modelos utilizando información más reciente. Los hábitos de los usuarios cambian, aparecen nuevas estrategias de fraude y evolucionan las formas de comunicación. Por esa razón, los modelos deben actualizarse para continuar siendo útiles.

Observemos entonces que existen dos procesos claramente diferentes. Por un lado, entrenar un nuevo modelo. Por otro, utilizar ese modelo para resolver miles o millones de casos nuevos. Confundir ambos procesos constituye uno de los errores más frecuentes durante las primeras etapas del aprendizaje de Machine Learning.

2.4.2. El caso de Netflix: aprender una vez, recomendar millones de veces

La misma idea puede observarse en las plataformas de streaming, supongamos que Netflix desea recomendar películas a sus usuarios.

Durante el entrenamiento analiza enormes cantidades de información histórica. Estudia qué películas fueron vistas, cuáles fueron abandonadas a los pocos minutos, qué géneros suelen aparecer juntos, qué preferencias comparten usuarios con comportamientos similares y muchas otras variables.

Todo ese análisis ocurre previamente. Una vez entrenado el modelo, el proceso de recomendación resulta extremadamente rápido. Cuando un usuario abre la aplicación y aparece la pantalla principal con decenas de sugerencias personalizadas, el sistema no está entrenando nuevamente el algoritmo. Simplemente está utilizando el modelo ya construido para responder una pregunta muy concreta.

¿Qué contenido posee mayor probabilidad de interesarle a esta persona?

Esta distinción explica por qué las recomendaciones aparecen casi instantáneamente. Entrenar un modelo puede requerir horas. Realizar una predicción suele demandar apenas milisegundos.

2.4.3. Una analogía con la universidad

Imaginemos ahora a un estudiante que acaba de finalizar la carrera de Medicina. Durante seis años asistió a clases, estudió anatomía, fisiología, farmacología, realizó prácticas hospitalarias y rindió numerosos exámenes. Todo ese proceso corresponde, de alguna manera, a su entrenamiento. Una vez recibido, comienza a trabajar en un hospital. Cuando atiende a un paciente no vuelve a cursar toda la carrera. No se necesita reaprender desde cero cada concepto de anatomía antes de realizar un diagnóstico. Utiliza el conocimiento adquirido durante su formación para resolver una situación concreta.

Naturalmente, con el paso del tiempo continuará actualizándose mediante cursos, congresos o nuevas experiencias clínicas. Sin embargo, existe una diferencia muy clara entre el período intensivo de formación y el ejercicio cotidiano de la profesión.

Con los modelos de Machine Learning ocurre algo semejante. El entrenamiento representa la etapa de aprendizaje. La predicción representa la aplicación práctica de ese aprendizaje.

Aunque esta analogía resulta útil desde el punto de vista didáctico, es importante recordar una diferencia esencial. Un profesional puede razonar, cuestionar sus decisiones y adaptar conscientemente su conocimiento a contextos completamente nuevos. Un modelo matemático, en cambio, únicamente aplica los patrones aprendidos durante el entrenamiento. Si la realidad cambia significativamente, será necesario volver a entrenarlo con información actualizada.

2.4.4. ¿Qué ocurre cuando el mundo cambia?

Hasta ahora hemos supuesto que los datos históricos representan adecuadamente el problema que intentamos resolver. Sin embargo, la realidad rara vez permanece estática.

- Los hábitos de consumo cambian.
- Las enfermedades evolucionan.
- Las preferencias musicales se modifican.
- Aparecen nuevas formas de fraude bancario.
- Surgen tecnologías completamente diferentes.

Todo esto plantea un desafío muy importante. un modelo entrenado hace varios años podría comenzar a perder precisión simplemente porque el entorno donde fue construido ya no existe. Pensemos en un sistema entrenado antes del año 2020 para estimar la cantidad de pasajeros que utilizarían diariamente el transporte público de una ciudad.

Durante meses el modelo produjo excelentes resultados. Sin embargo, la llegada de la pandemia modificó radicalmente los hábitos de movilidad. Millones de personas comenzaron a trabajar desde sus hogares. Las universidades suspendieron temporalmente las clases presenciales. Las restricciones sanitarias redujeron drásticamente la circulación. Como consecuencia, un modelo que anteriormente realizaba excelentes predicciones comenzó a equivocarse con mucha frecuencia. No porque el algoritmo hubiera dejado de funcionar. Sino porque el mundo había cambiado.

Este fenómeno demuestra que el aprendizaje automático no consiste únicamente en entrenar modelos. También implica monitorear continuamente su desempeño y decidir cuándo resulta necesario volver a entrenarlos utilizando información más reciente.

En proyectos reales esta tarea recibe tanta atención como el desarrollo inicial del modelo.

2.4.5. Entrenar cuesta; predecir es barato

Existe otra diferencia importante entre ambas etapas y tiene que ver con el costo computacional.

Entrenar un modelo suele requerir una enorme cantidad de recursos. Dependiendo del problema, pueden utilizarse cientos de miles de ejemplos, servidores especializados e incluso placas GPU capaces de realizar millones de operaciones simultáneamente. En cambio, una vez construido el modelo, realizar una predicción individual suele ser extremadamente económico desde el punto de vista computacional.

Esta diferencia explica por qué empresas como Google, Amazon o Meta invierten enormes recursos en entrenar modelos muy complejos y posteriormente pueden ofrecer servicios capaces de responder a millones de usuarios en tiempo real. El verdadero esfuerzo ocurre durante el aprendizaje. La utilización cotidiana del modelo suele resultar mucho más eficiente.

2.4.6. Una idea para recordar

Si hubiera que resumir lo visto en una única frase, probablemente sería la siguiente:

> ***Entrenar un modelo consiste en construir conocimiento a partir de datos históricos; utilizar un modelo consiste en aplicar ese conocimiento para tomar decisiones sobre datos nuevos.***

Esta diferencia nos acompañará durante toda la materia. Cada vez que implementemos un algoritmo en Python veremos claramente estas dos etapas. Primero entrenaremos el modelo utilizando un conjunto de ejemplos y, posteriormente, lo utilizaremos para realizar predicciones sobre información que nunca había visto.

En la próxima sección responderemos una nueva pregunta que aparece naturalmente después de comprender este proceso. Si un modelo ya fue entrenado y comienza a realizar predicciones, **¿cómo sabemos si realmente es bueno?** ¿Cómo podemos medir objetivamente si aprendió correctamente o si todavía comete demasiados errores?

2.5. ¿Cómo sabemos si un modelo realmente aprendió?

Hasta este momento hemos construido paso a paso el proceso de aprendizaje de un modelo de Machine Learning. Comprendimos que necesita datos históricos, que ajusta sus parámetros mediante un proceso iterativo y que, una vez finalizado el entrenamiento, puede realizar predicciones sobre información nueva.

Sin embargo, todavía queda una pregunta fundamental.

¿Cómo sabemos si ese aprendizaje fue realmente exitoso?

La respuesta parece obvia: basta con observar si el modelo responde correctamente.

No obstante, cuando analizamos el problema con mayor profundidad descubrimos que la situación es bastante más compleja.

Imaginemos nuevamente el contexto universitario.

Un profesor dicta una materia durante todo el cuatrimestre. Explica los contenidos, propone actividades prácticas, responde consultas y acompaña a sus estudiantes durante varios meses.

Al finalizar las clases afirma con absoluta seguridad:

—Todos mis alumnos aprendieron perfectamente.

Naturalmente, cualquier colega realizaría inmediatamente una pregunta muy sencilla.

—¿Cómo lo comprobaste?

El profesor responde:

—Porque asistieron a clase y parecían entender las explicaciones.

¿Resulta suficiente esa respuesta? - Evidentemente no.

Aunque los estudiantes hayan participado activamente durante las clases, todavía no existe ninguna evidencia objetiva de que realmente hayan incorporado los conocimientos necesarios.

Para responder esa pregunta es indispensable realizar algún tipo de evaluación. Puede tratarse de un examen escrito.

- Una evaluación oral.
- Un trabajo práctico.
- Un proyecto integrador.
- El formato puede variar, pero la idea permanece inalterable.

No alcanza con enseñar. Es necesario comprobar si el aprendizaje realmente ocurrió.

Con los modelos de Machine Learning sucede exactamente lo mismo.

Entrenar un algoritmo no garantiza automáticamente que haya aprendido correctamente.

Después del entrenamiento debemos evaluar su desempeño utilizando información que nos permita medir objetivamente la calidad de sus predicciones.

Aquí aparece una diferencia importante respecto de la programación tradicional.

Cuando desarrollamos un algoritmo convencional, muchas veces podemos afirmar con bastante certeza si el resultado es correcto o incorrecto. Si implementamos un programa para calcular el promedio de cinco números, existe una única respuesta correcta. Si el programa devuelve otro valor, sabemos inmediatamente que contiene un error.

En Machine Learning la situación cambia por completo.

El modelo trabaja con probabilidades, patrones y estimaciones. No esperamos que acierte siempre.

Esperamos que acierte con suficiente frecuencia como para resultar útil en un problema real.

Por este motivo, en Inteligencia Artificial rara vez hablamos de modelos perfectos.

Hablamos de modelos más precisos, más confiables o más robustos que otros.

Este cambio de perspectiva representa una diferencia fundamental entre el desarrollo de software tradicional y el aprendizaje automático.

2.5.1. El examen no puede ser el mismo con el que estudió

Existe otro aspecto que merece especial atención.

Supongamos que un profesor prepara un examen utilizando exactamente las mismas preguntas que resolvió durante todas las clases.

Los estudiantes ya conocen las respuestas de memoria. En esas condiciones es muy probable que la mayoría obtenga una excelente calificación. Pero surge inmediatamente una duda.

¿Aprobaron porque comprendieron los conceptos o simplemente porque recordaban las respuestas?

La única forma de responder esa pregunta consiste en proponer ejercicios nuevos. Problemas que pertenezcan al mismo tema, pero que nunca hayan sido vistos anteriormente. Solo entonces podremos comprobar si el aprendizaje fue genuino.

Con los modelos de Machine Learning ocurre exactamente lo mismo.

No podemos evaluar un modelo utilizando los mismos ejemplos que empleamos para entrenarlo.

Si lo hiciéramos, sería imposible distinguir entre un modelo que realmente comprendió los patrones generales y otro que simplemente memorizó cada caso histórico.

Por esta razón, en prácticamente todos los proyectos de Inteligencia Artificial los datos se dividen en diferentes conjuntos.

Un grupo se utiliza para entrenar el modelo.

Otro grupo, completamente independiente, se reserva exclusivamente para evaluar su desempeño.

Aunque todavía no profundizaremos en las técnicas específicas de partición de datos, es importante que el estudiante incorpore desde este momento la idea de que entrenar y evaluar constituyen procesos diferentes y complementarios.

Uno permite construir el conocimiento. El otro permite verificar si ese conocimiento resulta realmente útil.

2.5.2. Un ejemplo cotidiano

Imaginemos que una empresa desarrolla un modelo capaz de detectar correos electrónicos no deseados. Durante el entrenamiento utiliza un millón de mensajes correctamente clasificados.

Al finalizar el proceso, el algoritmo afirma haber aprendido. ¿Cómo comprobarlo?

La empresa toma entonces otro conjunto de correos que el modelo nunca había visto. Entre ellos existen mensajes legítimos, promociones comerciales, boletines informativos y también intentos reales de fraude.

Ahora sí comienza la evaluación. Cada predicción realizada por el modelo se compara con la clasificación correcta. Si el algoritmo identifica adecuadamente la enorme mayoría de los casos, podremos afirmar que aprendió con éxito. Si, por el contrario, comienza a enviar correos importantes a la carpeta de spam o deja pasar mensajes fraudulentos, será necesario revisar el entrenamiento o incluso volver a construir el modelo.

Este procedimiento puede parecer simple, pero constituye uno de los pilares fundamentales del Machine Learning moderno. Antes de confiar en cualquier modelo debemos demostrar, mediante evidencia objetiva, que funciona correctamente sobre datos nuevos.

No alcanza con que el algoritmo "parezca inteligente". Debe demostrarlo.

2.5.3. ¿Sabías que…?

En el año 2016, un sistema de Inteligencia Artificial desarrollado por Google, conocido como **AlphaGo**, derrotó al campeón mundial del juego Go, Lee Sedol. Sin embargo, antes de enfrentarse al mejor jugador del mundo, el sistema fue evaluado durante miles de partidas contra otros programas y jugadores de distintos niveles. Nadie hubiera aceptado enfrentar al campeón mundial sin evidencias previas de que el modelo realmente había aprendido.

Este caso muestra que, incluso en los desarrollos más avanzados de Inteligencia Artificial, **la evaluación siempre forma parte del proceso de aprendizaje**.

2.6. Cuando aprender demasiado también se convierte en un problema

Hasta ahora podría parecer que el objetivo de cualquier modelo consiste simplemente en aprender la mayor cantidad posible de información.

Después de todo, si aprender es algo positivo, parecería lógico pensar que cuanto más aprenda un algoritmo, mejores serán sus resultados. Sin embargo, esta intuición resulta engañosa.

Paradójicamente, un modelo puede aprender tanto de los datos de entrenamiento que termina funcionando peor cuando enfrenta situaciones nuevas. Este fenómeno constituye uno de los problemas más importantes de todo el Machine Learning y recibe el nombre de **sobreajuste**, conocido internacionalmente como **Overfitting**.

Para comprenderlo, volvamos una vez más al contexto universitario.

Imaginemos dos estudiantes que se preparan para rendir un examen final.

El primero decide estudiar comprendiendo los conceptos. Lee distintos autores, resuelve ejercicios, realiza resúmenes propios y trata de relacionar las ideas entre sí. Cuando aparece un problema nuevo, es capaz de adaptarse porque entiende el razonamiento que existe detrás de cada tema.

El segundo estudiante adopta una estrategia completamente distinta. Consigue los exámenes de los últimos diez años. No intenta comprender la teoría. Simplemente memoriza cada respuesta. Aprende incluso el orden de las preguntas y algunas frases textuales. Llega el día del examen. El profesor presenta ejercicios completamente nuevos. Aunque pertenecen a los mismos temas, las preguntas fueron reformuladas. El estudiante que comprendió los conceptos logra resolver la mayoría de los problemas. El estudiante que solamente memorizó respuestas queda completamente desorientado. No porque no haya estudiado. En realidad, estudió muchísimo. El problema fue **cómo** estudió. Memorizó los ejemplos particulares en lugar de comprender las ideas generales. En Machine Learning sucede exactamente lo mismo. Un modelo con **Overfitting** aprende excesivamente los datos de entrenamiento.

No solo descubre los patrones importantes. También memoriza pequeñas particularidades, errores de medición, valores atípicos e incluso coincidencias que jamás volverán a repetirse. Como consecuencia, obtiene resultados excelentes durante el entrenamiento, pero comienza a cometer errores cuando enfrenta información nueva. Es como un alumno que obtiene el cien por ciento en los ejercicios resueltos en clase, pero fracasa cuando el examen plantea situaciones diferentes.

2.6.1. El problema contrario: aprender demasiado poco

Ahora imaginemos un tercer estudiante.

Durante el cuatrimestre apenas hojea los apuntes, lee algunos títulos, asiste a pocas clases, nunca realiza ejercicios. Cuando llega el examen posee una idea muy superficial de los contenidos.

Naturalmente también obtendrá malos resultados. Pero por una razón completamente distinta. No memorizó demasiado. Simplemente **nunca aprendió lo suficiente**. En Machine Learning este fenómeno recibe el nombre de **Underfitting** o **subajuste**.

El modelo resulta demasiado simple para capturar las relaciones presentes en los datos. Como consecuencia, produce malos resultados tanto durante el entrenamiento como cuando debe analizar nuevos casos.

Podemos resumir ambos problemas utilizando una analogía muy sencilla.

- Un estudiante con **Underfitting** nunca comprendió la materia.
- El estudiante con **Overfitting** memorizó absolutamente todo, pero no comprendió nada.

Entre ambos extremos aparece la situación ideal.

Un estudiante que entiende los conceptos generales, reconoce patrones comunes y puede resolver ejercicios que nunca había visto anteriormente. Ese es exactamente el objetivo que perseguimos cuando entrenamos un modelo de Machine Learning. No queremos que recuerde cada ejemplo histórico.

Queremos que aprenda principios generales que le permitan desenvolverse correctamente frente a situaciones nuevas.Esta capacidad recibe un nombre que aparecerá constantemente durante el resto de la asignatura:

generalización.

Un buen modelo no es el que recuerda mejor el pasado. Es el que utiliza el pasado para tomar mejores decisiones sobre el futuro.

2.6.2. Para pensar

Un hospital desarrolla un modelo capaz de detectar una determinada enfermedad utilizando datos recopilados durante los últimos cinco años. Durante las pruebas realizadas con esos mismos registros históricos, el sistema obtiene un desempeño prácticamente perfecto.

Sin embargo, cuando comienza a utilizarse con pacientes nuevos, el número de errores aumenta considerablemente.

Antes de concluir que el algoritmo "dejó de funcionar", ¿qué preguntas deberían hacerse los profesionales?

- ¿Los nuevos pacientes presentan características diferentes?
- ¿Cambió el equipamiento utilizado para realizar los estudios?
- ¿Aparecieron nuevos protocolos médicos?
- ¿El modelo memorizó demasiado los datos originales?

Reflexionar sobre estas preguntas permite comprender que el verdadero desafío del Machine Learning no consiste únicamente en construir modelos inteligentes, sino en garantizar que continúen siendo útiles cuando la realidad cambia.

2.7. Integrando los conceptos: el ciclo completo del aprendizaje automático

Al comenzar este capítulo nos propusimos responder una pregunta aparentemente sencilla, pero que constituye uno de los pilares de toda la Inteligencia Artificial moderna.

¿Cómo aprende una computadora?

Después del recorrido realizado podemos afirmar que la respuesta es mucho más rica de lo que parecía al principio.

Aprender, en el contexto del Machine Learning, no significa pensar, razonar o comprender el mundo de la misma manera que lo hace una persona. Un algoritmo no desarrolla intuición ni construye explicaciones sobre la realidad. Su aprendizaje consiste en descubrir relaciones matemáticas presentes en grandes volúmenes de información y utilizarlas para realizar predicciones sobre situaciones que todavía no conoce.

Aunque el proceso ocurre mediante operaciones matemáticas extremadamente complejas, desde un punto de vista conceptual puede entenderse como una secuencia ordenada de etapas que siempre aparecen, con pequeñas variaciones, en prácticamente todos los proyectos de aprendizaje automático.

Todo comienza con un problema.

1. Una empresa desea estimar cuáles clientes abandonarán un servicio.
2. Un hospital intenta detectar tempranamente una enfermedad.
3. Una universidad busca identificar estudiantes con riesgo de deserción.
4. Un laboratorio clínico necesita clasificar automáticamente determinados resultados.
5. Un banco pretende detectar operaciones potencialmente fraudulentas.

A pesar de pertenecer a áreas completamente diferentes, todos estos problemas comparten una característica esencial.

Existe una decisión que queremos automatizar o asistir mediante información obtenida a partir de experiencias anteriores.

El siguiente paso consiste en recopilar datos.

Esta etapa, que muchas veces recibe menos atención de la que merece, constituye probablemente la actividad más importante de todo el proyecto. Ningún algoritmo puede descubrir patrones allí

donde no existe información suficiente. Del mismo modo que un estudiante necesita bibliografía adecuada para aprender una materia, un modelo requiere datos representativos de la realidad que intenta comprender.

Una vez organizada la información comienza el entrenamiento.

El algoritmo procesa miles de ejemplos históricos, realiza predicciones iniciales, calcula el error cometido y modifica progresivamente sus parámetros internos con el objetivo de reducir ese error. Este procedimiento se repite una y otra vez hasta obtener un modelo capaz de representar las relaciones presentes en los datos.

Sin embargo, el proceso todavía no ha terminado. Después del entrenamiento llega el momento de la evaluación.

Es necesario comprobar si el modelo realmente aprendió o si simplemente memorizó los ejemplos utilizados durante el entrenamiento. Para ello se utilizan datos que el algoritmo nunca había visto anteriormente. Solamente si demuestra un buen desempeño frente a información nueva podremos confiar en su capacidad para resolver problemas reales.

Finalmente, cuando todas las etapas anteriores fueron satisfactorias, el modelo puede incorporarse a una aplicación informática y comenzar a realizar predicciones sobre nuevos casos.

En ese momento deja de aprender y comienza a trabajar.

Este recorrido puede resumirse mediante el siguiente esquema, que utilizaremos repetidamente durante el resto de la asignatura.

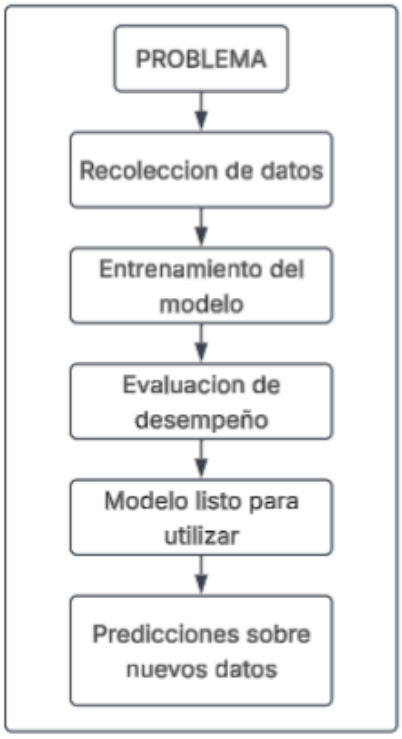


Figura 2.1 — El ciclo completo del aprendizaje automático.

Aunque este diagrama parece sencillo, resume prácticamente todo el proceso que seguiremos durante el cuatrimestre. Cada nuevo algoritmo que estudiaremos representará una manera diferente de realizar alguna de estas etapas, pero la estructura general permanecerá inalterable.

Esta es una idea que vale la pena destacar.

Cuando dentro de algunas semanas trabajemos con árboles de decisión, regresión logística o redes neuronales, el procedimiento seguirá siendo exactamente el mismo. Cambiarán las herramientas matemáticas utilizadas durante el entrenamiento, pero no cambiará la lógica general del aprendizaje.

Comprender este esquema significa comprender la arquitectura conceptual de cualquier proyecto de Machine Learning.

2.7.1. El papel del programador en este nuevo paradigma

Llegados a este punto resulta oportuno reflexionar sobre una pregunta que suele aparecer con frecuencia entre quienes comienzan a estudiar Inteligencia Artificial.

Si los algoritmos aprenden automáticamente, ¿qué papel continúa desempeñando el programador?

La respuesta es mucho más interesante de lo que parece, el programador no desaparece, su trabajo evoluciona. En el desarrollo tradicional gran parte del esfuerzo consistía en escribir reglas que describieran explícitamente el comportamiento del sistema.

En Machine Learning la tarea cambia profundamente.

Ahora el desarrollador debe comprender el problema que intenta resolver, identificar qué información resulta relevante, seleccionar adecuadamente los datos, preparar esa información para el entrenamiento, elegir el algoritmo más apropiado, evaluar críticamente los resultados obtenidos y decidir si el modelo realmente puede utilizarse en un contexto real.

Observemos que ninguna de estas responsabilidades puede delegarse completamente en un algoritmo.

La Inteligencia Artificial automatiza determinadas tareas, pero continúa necesitando profesionales capaces de formular correctamente los problemas, interpretar los resultados y comprender las implicancias técnicas, éticas y sociales de las decisiones tomadas por los modelos.

Por este motivo, estudiar Machine Learning no significa dejar de programar, significa aprender una nueva forma de desarrollar software.

En lugar de escribir todas las respuestas, comenzamos a construir sistemas capaces de encontrarlas utilizando la información disponible.

Esta transformación representa uno de los cambios más importantes que ha experimentado la informática desde la aparición de Internet y explica por qué la Inteligencia Artificial ocupa actualmente un lugar central dentro de prácticamente todas las áreas del desarrollo tecnológico.

2.7.2. Caso de estudio: una aplicación para un laboratorio clínico

Imaginemos un laboratorio que procesa miles de análisis clínicos cada semana. Entre los estudios realizados se encuentran hemogramas, perfiles lipídicos, análisis hormonales y pruebas bioquímicas de rutina.

Con el paso de los años, el laboratorio acumula una enorme cantidad de información histórica. Cada registro contiene resultados de análisis, edad del paciente, sexo, antecedentes clínicos relevantes y el diagnóstico confirmado por el profesional responsable.

A partir de esa información podría entrenarse un modelo capaz de identificar patrones asociados a determinadas patologías o detectar resultados que merezcan una revisión prioritaria por parte del bioquímico.

Es importante remarcar que el sistema no reemplazaría al profesional.

Su función consistiría en asistir el proceso diagnóstico, señalando aquellos casos cuya combinación de variables resulta similar a la observada previamente en pacientes con determinadas condiciones clínicas.

Este ejemplo ilustra claramente el verdadero objetivo del Machine Learning. No sustituir el conocimiento humano. Sino potenciarlo mediante el análisis de cantidades de información que resultarían imposibles de procesar manualmente.

2.7.3. Para reflexionar

Si una computadora puede aprender a partir de los datos...

¿quién decide cuáles datos utilizar?

La respuesta parece sencilla, pero posee enormes implicancias.

Si entrenamos un modelo utilizando información incompleta, desactualizada o sesgada, el sistema aprenderá exactamente esas mismas limitaciones.

Por el contrario, si los datos representan adecuadamente la realidad y fueron cuidadosamente preparados, las posibilidades de construir modelos útiles aumentarán considerablemente.

Esta observación nos recuerda que el éxito de un proyecto de Inteligencia Artificial no depende únicamente de la potencia del algoritmo.

Depende, sobre todo, de la calidad del conocimiento que logramos capturar mediante los datos.

2.8. El primer gran paradigma del aprendizaje automático

A lo largo del capítulo hemos descubierto que el aprendizaje automático constituye mucho más que un conjunto de algoritmos. Hemos visto que un modelo necesita datos para aprender, que ese aprendizaje ocurre mediante un proceso de entrenamiento basado en la reducción progresiva del error y que, una vez finalizado, el conocimiento adquirido puede utilizarse para realizar predicciones sobre situaciones completamente nuevas. Sin embargo, todavía hemos mantenido una suposición que pasó casi desapercibida. En todos los ejemplos utilizados hasta ahora conocíamos cuál era la respuesta correcta.

- Sabíamos qué estudiantes aprobaron la materia.
- Conocíamos el precio final de cada vivienda.
- Disponíamos del diagnóstico confirmado de cada paciente.
- Sabíamos qué correos electrónicos eran legítimos y cuáles correspondían a spam.
- Esa información fue esencial para que el algoritmo pudiera aprender.
- Pero surge entonces una nueva pregunta.

¿Cómo se llama este tipo de aprendizaje?

La respuesta es **aprendizaje supervisado**.

Recibe ese nombre porque, durante el entrenamiento, el algoritmo dispone de un "supervisor": la respuesta correcta para cada ejemplo histórico. Esa información actúa como una guía que le permite medir el error de sus predicciones y corregir progresivamente su comportamiento.

El aprendizaje supervisado constituye la técnica más utilizada dentro del Machine Learning y representa la base de una enorme cantidad de aplicaciones que utilizamos diariamente: sistemas de diagnóstico asistido, detección de fraude financiero, reconocimiento de imágenes, clasificación de documentos, filtros de correo electrónico, predicción de ventas y análisis de riesgo crediticio, entre muchas otras.

Precisamente por su importancia, será el tema central del próximo capítulo.

Comenzaremos a estudiar cómo se clasifican los problemas supervisados, qué diferencias existen entre clasificación y regresión, cuáles son los primeros algoritmos utilizados para resolverlos y cómo implementaremos nuestros primeros modelos utilizando Python.

Con este paso dejaremos atrás la etapa introductoria de la materia y comenzaremos, finalmente, a construir sistemas capaces de aprender a partir de ejemplos reales.