Unidad 3. Aprendizaje Supervisado: cuando conocemos la respuesta correcta

3.1. Introducción: aprender con un maestro

Durante el capítulo descubrimos que un modelo de Machine Learning aprende analizando grandes cantidades de información histórica. También vimos que ese aprendizaje no consiste en memorizar ejemplos individuales, sino en descubrir patrones generales que posteriormente puedan utilizarse para realizar predicciones sobre situaciones nuevas.

Sin embargo, todos los ejemplos analizados compartían una característica que pasó prácticamente desapercibida. En cada uno de ellos **conocíamos cuál era la respuesta correcta**.

Cuando intentábamos predecir el rendimiento académico de un estudiante, sabíamos quiénes habían aprobado y quiénes no.

Al estimar el precio de una vivienda, conocíamos el valor final al que efectivamente fue vendida.

En el caso del filtro de correo electrónico, sabíamos cuáles mensajes correspondían a spam y cuáles eran legítimos.

En un laboratorio clínico, el diagnóstico confirmado por el profesional permitía conocer el resultado correcto para cada paciente utilizado durante el entrenamiento.

Esta información desempeña un papel fundamental dentro del proceso de aprendizaje. No solamente permite saber si el algoritmo respondió correctamente.

También le proporciona una referencia objetiva para calcular el error cometido y corregir progresivamente sus predicciones. Precisamente por esa razón, este paradigma recibe el nombre de **aprendizaje supervisado**.

La palabra ***supervisado*** no debe interpretarse como si existiera una persona observando permanentemente el funcionamiento del algoritmo. El "supervisor" es, en realidad, la información contenida en los datos históricos. Cada ejemplo incorpora la respuesta correcta y esa respuesta funciona como una guía durante todo el proceso de entrenamiento.

Podemos imaginar que cada registro del conjunto de datos contiene, además de la descripción del problema, una pequeña nota que dice al algoritmo:

"Esta era la respuesta correcta. Ahora intenta descubrir por qué."

Aunque esta representación resulta simplificada, captura adecuadamente la esencia del aprendizaje supervisado. El algoritmo no inventa las respuestas.

Las utiliza como referencia para construir un modelo capaz de generalizar ese conocimiento hacia situaciones futuras. Esta característica convierte al aprendizaje supervisado en la técnica más utilizada dentro del Machine Learning moderno.

La enorme mayoría de las aplicaciones de Inteligencia Artificial que utilizamos diariamente pertenecen a esta categoría.

- Los sistemas capaces de detectar fraudes bancarios fueron entrenados utilizando operaciones previamente clasificadas como legítimas o fraudulentas.
- Los modelos empleados para diagnosticar enfermedades utilizan estudios médicos cuyo diagnóstico ya fue confirmado por especialistas.
- Los traductores automáticos aprenden analizando millones de textos traducidos previamente por personas.
- Los sistemas de reconocimiento facial utilizan fotografías correctamente identificadas.
- Los asistentes virtuales mejoran sus respuestas gracias a enormes colecciones de conversaciones previamente etiquetadas.

En todos estos casos aparece el mismo elemento común.

El algoritmo aprende observando ejemplos cuya respuesta ya es conocida.

3.1.1. Una nueva forma de programar

Para comprender verdaderamente la importancia del aprendizaje supervisado conviene compararlo nuevamente con el desarrollo tradicional de software.

Supongamos que una empresa necesita construir un sistema capaz de aprobar automáticamente créditos personales. Si intentáramos resolver este problema utilizando programación convencional, deberíamos escribir manualmente todas las reglas necesarias.

Podríamos comenzar definiendo condiciones como las siguientes:

- Si el ingreso mensual supera determinado valor y la antigüedad laboral es mayor a cinco años, aprobar el crédito.
- Si el solicitante registra antecedentes de incumplimiento, rechazar la solicitud.
- Si la relación entre ingresos y monto solicitado supera cierto límite, enviar el caso a revisión.

Inicialmente este enfoque parece razonable. Sin embargo, rápidamente comienzan a aparecer dificultades.

- ¿Qué ocurre si el cliente posee excelentes ingresos, pero una antigüedad laboral reducida?
- ¿Y si trabaja de manera independiente?
- ¿Qué sucede cuando dos variables parecen indicar decisiones opuestas?

Cada nueva situación obliga a incorporar reglas adicionales. Con el paso del tiempo el sistema se vuelve cada vez más complejo, difícil de mantener y propenso a inconsistencias.

Ahora imaginemos un enfoque completamente diferente.

La entidad financiera dispone de información correspondiente a cientos de miles de créditos otorgados durante los últimos diez años.

Cada registro incluye datos como la edad del solicitante, ingresos, historial crediticio, actividad laboral, monto solicitado y, finalmente, el resultado observado: si el crédito fue pagado correctamente o terminó en incumplimiento.

En lugar de escribir manualmente todas las reglas posibles, el banco decide entrenar un modelo utilizando esa experiencia acumulada.

El algoritmo analiza los casos históricos, identifica relaciones entre las variables y construye un modelo matemático capaz de estimar el riesgo asociado a nuevas solicitudes.

Observemos el cambio conceptual, ya no programamos directamente la decisión. Programamos el mecanismo mediante el cual la computadora aprenderá a tomar esa decisión.

Esta diferencia representa uno de los cambios más profundos introducidos por el Machine Learning y explica por qué tantas organizaciones comenzaron a incorporar Inteligencia Artificial en procesos donde anteriormente resultaba prácticamente imposible definir reglas explícitas.

3.1.2. La importancia de las etiquetas

Hasta este momento hemos mencionado varias veces que los ejemplos utilizados durante el entrenamiento poseen una respuesta correcta. Sin embargo, todavía no hemos analizado cómo se representa esa información.

En aprendizaje supervisado, la respuesta asociada a cada ejemplo recibe el nombre de **etiqueta** (*label*). La etiqueta constituye el conocimiento que el algoritmo intenta aprender.

Horas de estudio	Asistencia	Trabajos prácticos	Resultado
12	95 %	8	Aprobó
3	42 %	2	No aprobó
9	88 %	7	Aprobó
5	60 %	4	No aprobó

Retomemos el ejemplo de los estudiantes universitarios.En esta tabla, las tres primeras columnas describen las características de cada estudiante. La última columna representa la etiqueta.

Durante el entrenamiento, el algoritmo utiliza las características para intentar predecir la etiqueta. Cada vez que se equivoca, calcula el error y ajusta sus parámetros internos. Con miles o millones de ejemplos correctamente etiquetados, el modelo comienza gradualmente a descubrir relaciones generales. En cierto sentido, cada etiqueta funciona como la respuesta al final de un ejercicio de matemática.

No explica cómo resolver el problema, pero permite verificar si el procedimiento utilizado fue correcto.

3.1.3. Un detalle que suele pasar desapercibido

En Machine Learning, **la calidad de las etiquetas es tan importante como la calidad de los datos**.

Imaginemos un hospital que decide entrenar un modelo para detectar neumonía utilizando radiografías de tórax. Si los diagnósticos utilizados como referencia contienen errores, el algoritmo aprenderá exactamente esos mismos errores.

No importa cuán sofisticado sea el modelo, su aprendizaje dependerá directamente de la información que recibe.

Este principio suele resumirse mediante una expresión muy conocida dentro de la informática:

> ***Garbage In, Garbage Out (GIGO).***

La traducción literal sería:

> ***"Basura entra, basura sale."***

La idea es extremadamente sencilla.

Si alimentamos un algoritmo con información incorrecta, incompleta o inconsistente, no podemos esperar resultados confiables. Esta afirmación parece evidente, pero continúa siendo una de las principales causas de fracaso en proyectos reales de Inteligencia Artificial.

Muchas organizaciones concentran todos sus esfuerzos en seleccionar el algoritmo más moderno, cuando en realidad el problema se encuentra en la calidad de los datos utilizados para entrenarlo.

Por esta razón, un científico de datos dedica gran parte de su tiempo a revisar, limpiar, validar y comprender la información disponible antes de comenzar el entrenamiento. En numerosos proyectos industriales, esta etapa consume mucho más tiempo que el desarrollo del modelo propiamente dicho.

3.2. Los dos grandes problemas del aprendizaje supervisado

Hasta este momento hemos aprendido que el aprendizaje supervisado utiliza ejemplos históricos cuya respuesta correcta ya es conocida. También vimos que esas respuestas permiten al

algoritmo calcular el error de sus predicciones y mejorar progresivamente durante el entrenamiento.

Sin embargo, todavía no hemos respondido una pregunta fundamental.

¿Todos los problemas de aprendizaje supervisado son iguales?

La respuesta es no.

Aunque puedan utilizar los mismos principios generales de entrenamiento, los problemas supervisados pueden dividirse en dos grandes grupos según el tipo de respuesta que esperamos obtener. Esta clasificación constituye uno de los conceptos más importantes de toda la asignatura, ya que determina qué algoritmos podrán utilizarse posteriormente para resolver un problema determinado.

Antes de pensar en árboles de decisión, redes neuronales o cualquier otra técnica, el ingeniero debe responder una única pregunta.

¿Qué tipo de resultado quiero predecir?

La respuesta a esa pregunta permitirá identificar inmediatamente si estamos frente a un problema de **clasificación** o de **regresión**.

Esta decisión parece sencilla, pero representa el primer análisis que realiza cualquier científico de datos al comenzar un nuevo proyecto.

No depende del algoritmo. Depende del problema.

3.2.1. Cuando la respuesta pertenece a una categoría

Imaginemos que un hospital desea construir un sistema capaz de analizar estudios clínicos para determinar si un paciente presenta una determinada enfermedad.

El algoritmo recibe información como la edad del paciente, distintos parámetros bioquímicos, antecedentes familiares y resultados de estudios complementarios. Al finalizar el análisis debe responder únicamente una pregunta.

¿El paciente presenta la enfermedad?

Las posibles respuestas son muy limitadas.

Sí.

No.

No existen valores intermedios. El resultado pertenece a una categoría.

Ahora pensemos en un banco que desea detectar operaciones fraudulentas.

Después de analizar la transacción, el sistema debe decidir si la operación parece normal o si presenta características compatibles con un posible fraude.

Nuevamente aparecen categorías.

Fraudulenta.

No es fraudulenta.

Lo mismo ocurre con un filtro de correo electrónico. El mensaje será clasificado como spam o como correo legítimo.

Una empresa de comercio electrónico puede clasificar un comentario como positivo, negativo o neutral.

Un sistema de reconocimiento de imágenes puede indicar que una fotografía contiene un automóvil, una bicicleta, un perro o un gato.

En todos estos casos ocurre exactamente el mismo fenómeno.

El algoritmo no intenta calcular una cantidad numérica.

Su objetivo consiste en decidir **a qué categoría pertenece cada ejemplo**.

Este tipo de problemas recibe el nombre de **clasificación**.

La clasificación constituye probablemente la tarea más difundida dentro del aprendizaje supervisado y aparece prácticamente en todas las áreas de aplicación de la Inteligencia Artificial.

Es importante comprender que el algoritmo no "crea" las categorías. Estas ya existen previamente y forman parte de los datos históricos utilizados durante el entrenamiento. El modelo simplemente aprende a reconocer los patrones que caracterizan a cada una de ellas.

3.2.2. Un ejemplo cercano: un laboratorio clínico

Pensemos en un laboratorio de análisis clínicos.

Supongamos que, a partir de diversos parámetros sanguíneos, deseamos construir un sistema capaz de asistir al bioquímico en la detección de anemia.

Para cada paciente disponemos de información como el nivel de hemoglobina, hematocrito, cantidad de glóbulos rojos, volumen corpuscular medio y otros indicadores obtenidos durante el análisis.

El resultado esperado no consiste en un número nuevo.El objetivo es determinar si el paciente presenta o no indicios compatibles con anemia. La respuesta pertenece a una de dos categorías.

- **Paciente con anemia.**
- **Paciente sin anemia.**

Observemos que el algoritmo no reemplaza el criterio profesional del bioquímico.

Su función consiste en señalar automáticamente aquellos casos cuya combinación de variables resulta similar a la observada anteriormente en pacientes con diagnósticos confirmados.

El profesional continúa siendo quien interpreta el contexto clínico y toma la decisión final.

Este ejemplo permite comprender por qué la Inteligencia Artificial no debe entenderse como un sustituto del especialista, sino como una herramienta de apoyo capaz de analizar grandes volúmenes de información con enorme rapidez.

3.2.3. Cuando la respuesta es un número

Consideremos ahora un problema completamente diferente.

Una inmobiliaria desea estimar el precio de una vivienda antes de ponerla a la venta. Disponemos de información sobre la superficie construida, cantidad de habitaciones, antigüedad, ubicación, calidad de los materiales y muchas otras características.

En este caso el algoritmo ya no debe responder "sí" o "no".

Tampoco debe elegir una categoría.

Debe producir un número.

Por ejemplo:

ARS $185.000.

ARS $97.500.

ARS $420.000.

La respuesta puede adoptar prácticamente cualquier valor dentro de un intervalo continuo.

Este tipo de problemas recibe el nombre de **regresión**.

Aunque el nombre pueda resultar confuso para quienes comienzan a estudiar Machine Learning, no tiene relación con la idea de "retroceder" o "volver hacia atrás".En este contexto, la palabra regresión hace referencia a modelos cuya salida corresponde a una variable numérica continua.

Otros ejemplos aparecen constantemente en la vida cotidiana.

- Una empresa energética puede intentar estimar el consumo eléctrico de una ciudad durante la próxima semana.
- Una compañía agrícola puede predecir la cantidad de toneladas que producirá una cosecha.
- Un laboratorio farmacéutico puede estimar la concentración de una determinada sustancia en una muestra biológica.
- Una empresa logística puede calcular el tiempo estimado de llegada de un envío.

En todos estos casos el algoritmo responde mediante un valor numérico.

- No clasifica.
- No etiqueta.

Estima una cantidad.

3.2.4. El mismo algoritmo, problemas diferentes

Aquí aparece una observación muy interesante.

Muchas veces disponemos exactamente de la misma información de entrada, pero cambiamos la pregunta que queremos responder. Y ese pequeño cambio modifica completamente el tipo de problema.

Imaginemos nuevamente una inmobiliaria.

Disponemos de las siguientes variables:

1. Superficie del terreno.
2. Cantidad de habitaciones.
3. Antigüedad.
4. Barrio.
5. Existencia de cochera.

Si preguntamos:

¿Cuál será el precio aproximado de la vivienda?

Estamos frente a un problema de regresión.

Pero si utilizamos exactamente los mismos datos y preguntamos:

¿La vivienda pertenece al segmento económico, medio o premium?

Ahora el problema dejó de ser una regresión.

Se convirtió en un problema de clasificación.

Observemos que los datos son exactamente los mismos. Lo único que cambió fue la naturaleza de la respuesta esperada. Esta idea posee una enorme importancia práctica.

Cuando un ingeniero comienza un proyecto de Machine Learning, no elige primero el algoritmo. Primero analiza cuál es la pregunta que desea responder, recién después selecciona la técnica más adecuada para ese tipo de problema.

Por este motivo suele afirmarse que **la formulación correcta del problema constituye una de las decisiones más importantes de todo proyecto de Inteligencia Artificial**.

Una pregunta mal planteada conduce inevitablemente a un modelo poco útil, aunque el algoritmo utilizado sea técnicamente impecable.

3.2.5. Caso de estudio: una empresa de transporte

Supongamos que una empresa de transporte urbano desea incorporar Inteligencia Artificial para mejorar la calidad de su servicio. A partir de la información histórica sobre recorridos, horarios, clima y tránsito vehicular, podrían plantearse distintas preguntas.

Cada una de ellas daría origen a un problema diferente, si el objetivo consiste en estimar cuántos minutos tardará un colectivo en llegar a una parada determinada, el resultado esperado será un número.

Estamos frente a un problema de regresión.

En cambio, si la empresa desea determinar si un recorrido probablemente llegará **a tiempo**, **con demora moderada** o **con demora importante**, la salida deja de ser un número y pasa a ser una categoría.

Ahora estamos frente a un problema de clasificación.

La información utilizada podría ser prácticamente la misma, lo que cambia es la pregunta que deseamos responder. Esta observación demuestra que la Inteligencia Artificial no comienza con los algoritmos. Comienza con la formulación adecuada del problema.

3.2.6. Para pensar

Antes de continuar con los algoritmos específicos, conviene realizar un pequeño ejercicio de reflexión.

Imaginemos que una universidad desea utilizar Machine Learning para mejorar el acompañamiento de sus estudiantes.

Analicemos las siguientes preguntas:

- ¿El estudiante aprobará la materia?
- ¿Qué nota obtendrá en el examen final?
- ¿Abandonará la carrera durante el primer año?
- ¿Cuántas materias aprobará durante el próximo cuatrimestre?
- ¿Necesita tutorías académicas?

Intente identificar cuáles corresponden a problemas de clasificación y cuáles a problemas de regresión.

No piense todavía en los algoritmos, concéntrese únicamente en la naturaleza de la respuesta esperada. Ese será siempre el primer paso antes de comenzar cualquier proyecto de aprendizaje supervisado.

3.3. No todas las clasificaciones son iguales

En la sección anterior aprendimos que un problema de clasificación consiste en asignar cada ejemplo a una determinada categoría. Aunque esta definición resulta correcta, todavía es demasiado general para comprender la enorme variedad de situaciones que aparecen en los proyectos reales de Inteligencia Artificial.

A primera vista podría parecer que clasificar siempre significa responder una pregunta con un "sí" o un "no". De hecho, muchos de los ejemplos utilizados hasta ahora seguían precisamente esa estructura. Un paciente presenta una enfermedad o no la presenta. Un correo electrónico corresponde a spam o no corresponde. Una operación bancaria resulta fraudulenta o legítima.

Sin embargo, la realidad suele ser bastante más compleja.

Existen problemas donde las categorías posibles son únicamente dos. Otros presentan decenas o incluso cientos de alternativas. En determinadas situaciones, además, un mismo ejemplo puede pertenecer simultáneamente a varias categorías.

Comprender estas diferencias resulta fundamental porque no todos los algoritmos están diseñados para resolver los mismos tipos de clasificación. Antes de seleccionar una técnica de aprendizaje, el ingeniero debe identificar correctamente cuál de estos escenarios representa mejor el problema que intenta resolver.

3.3.1. Clasificación binaria: cuando solamente existen dos respuestas posibles

La forma más sencilla de clasificación aparece cuando únicamente existen dos categorías mutuamente excluyentes. En estos casos, cada ejemplo debe pertenecer necesariamente a una de ellas.

No existen opciones intermedias. No es posible pertenecer a ambas categorías al mismo tiempo.

Pensemos nuevamente en un laboratorio clínico.

Supongamos que estamos desarrollando un sistema capaz de detectar la presencia de una determinada enfermedad infecciosa a partir de distintos parámetros bioquímicos.

Después de analizar la información del paciente, el algoritmo debe responder una única pregunta.

¿La enfermedad está presente?

Las únicas respuestas posibles son dos.

- **Sí.**
- **No.**

No existe una tercera posibilidad.

Algo similar ocurre con un detector de fraude bancario. Cada transacción será clasificada como fraudulenta o legítima.

- Un filtro de correo electrónico decidirá si un mensaje corresponde a spam o no.
- Un sistema de autenticación biométrica determinará si la huella digital pertenece al usuario registrado o a otra persona.

Todos estos ejemplos representan problemas de clasificación binaria porque el algoritmo únicamente necesita elegir entre dos alternativas.

Este tipo de clasificación posee una enorme importancia práctica. Una gran cantidad de aplicaciones industriales pertenecen precisamente a esta categoría y, por esa razón, muchos de los primeros algoritmos de Machine Learning fueron desarrollados originalmente para resolver este tipo de problemas.

3.3.2. Una decisión aparentemente sencilla

Podría pensarse que clasificar entre dos categorías constituye una tarea trivial. Sin embargo, basta analizar algunos ejemplos para comprender que la realidad es mucho más desafiante.

Imaginemos un sistema utilizado para detectar correos electrónicos fraudulentos.

Algunos mensajes resultan extremadamente fáciles de identificar. Contienen errores ortográficos evidentes, enlaces sospechosos o solicitudes de información personal claramente inusuales.

Pero existen otros casos mucho más difíciles.

Un correo enviado por el banco puede parecer completamente legítimo.

Al mismo tiempo, un atacante puede construir un mensaje prácticamente idéntico utilizando el logotipo oficial de la entidad financiera, incluso para una persona experimentada puede resultar complicado distinguir ambas situaciones, el algoritmo enfrenta exactamente el mismo desafío.

No todas las decisiones presentan el mismo nivel de dificultad.

Existen ejemplos extremadamente claros y otros ubicados muy cerca del límite que separa ambas categorías.

Esta observación nos permitirá comprender más adelante conceptos como la probabilidad de clasificación, el umbral de decisión y las métricas de evaluación.

Por ahora basta con incorporar una idea.

Clasificar no significa únicamente elegir una etiqueta. También implica estimar cuán probable resulta que esa decisión sea correcta.

3.3.3. Clasificación multiclase: cuando existen varias alternativas

Consideremos ahora un problema completamente diferente.

Una universidad desea automatizar la clasificación de documentos recibidos diariamente. Cada archivo debe enviarse automáticamente al área correspondiente.

Las posibles categorías son:

- Departamento Académico.
- Recursos Humanos.
- Tesorería.
- Secretaría de Alumnos.
- Mesa de Entradas.

En este caso ya no existen únicamente dos respuestas.

Las alternativas son cinco. Sin embargo, cada documento pertenece solamente a una de ellas.

Un expediente administrativo no puede enviarse simultáneamente a Tesorería y a Recursos Humanos como resultado de una única clasificación.

El algoritmo debe elegir una única categoría entre varias posibilidades. Este tipo de problemas recibe el nombre de **clasificación multiclase**.

Otros ejemplos aparecen constantemente en aplicaciones cotidianas.

Un sistema capaz de reconocer especies de plantas puede clasificar una fotografía como roble, pino, eucalipto o jacarandá.

Un reconocimiento de escritura manuscrita debe decidir qué número, entre el 0 y el 9, aparece en una imagen. Un clasificador de frutas utilizado en una planta industrial puede identificar manzanas, peras, naranjas o limones.

En todos estos casos existe una característica común. Hay muchas categorías posibles. Pero solamente una de ellas representa la respuesta correcta.

3.3.4. Un ejemplo industrial

Imaginemos una fábrica dedicada al control automático de calidad.

Sobre una cinta transportadora circulan cientos de piezas metálicas por minuto, cada pieza debe clasificarse según su estado.

Las categorías posibles son:

- Pieza correcta.
- Pieza rayada.
- Pieza deformada.
- Pieza con defecto de pintura.
- Pieza con fisuras.

El sistema de visión artificial analiza cada imagen y decide cuál de estas categorías describe mejor la pieza inspeccionada.

Observemos nuevamente que solamente puede elegirse una categoría.

Una misma pieza no será considerada simultáneamente "correcta" y "deformada". El algoritmo debe seleccionar aquella opción que mejor represente la realidad observada.

3.3.5. Clasificación multi etiqueta: cuando una respuesta no alcanza

Hasta ahora todos los ejemplos compartían una característica importante.

Cada caso pertenecía a una única categoría, sin embargo, existen situaciones donde esa restricción deja de tener sentido.

Pensemos en una plataforma de películas.

Una misma película puede describirse simultáneamente como:

- Ciencia ficción.
- Acción.
- Aventura.

Las tres categorías son correctas al mismo tiempo.

No existe ninguna razón para obligar al algoritmo a elegir solamente una. Algo parecido ocurre con la clasificación automática de noticias.

Una noticia puede tratar simultáneamente sobre economía, política e industria.

En medicina sucede algo similar. Un paciente puede presentar hipertensión, diabetes y obesidad de manera simultánea. Todas esas etiquetas describen correctamente la misma situación clínica.

Cuando un ejemplo puede pertenecer simultáneamente a varias categorías hablamos de **clasificación multi etiqueta**.

Aunque conceptualmente resulta parecida a la clasificación multiclase, existe una diferencia muy importante.

- En clasificación multiclase elegimos una única respuesta.
- En clasificación multi etiqueta podemos asignar varias respuestas simultáneamente.

Comprender esta diferencia evita numerosos errores durante el diseño de un proyecto de Machine Learning.

3.3.6. El primer análisis que realiza un ingeniero

Llegados a este punto conviene detenernos un instante para observar cómo piensa un profesional cuando recibe un nuevo problema.

Supongamos que una empresa solicita desarrollar un sistema de Inteligencia Artificial.

Antes de hablar de algoritmos, bibliotecas o lenguajes de programación, el ingeniero comienza realizando una serie de preguntas muy simples.

1. ¿Cuál es exactamente el problema?
2. ¿Qué información estará disponible?
3. ¿Existe una respuesta correcta para cada ejemplo?
4. ¿La salida será un número o una categoría?
5. Si es una categoría, ¿existen solamente dos posibilidades?
6. ¿Hay varias categorías mutuamente excluyentes?
7. ¿O un mismo ejemplo puede pertenecer simultáneamente a varias de ellas?

Estas preguntas parecen elementales.

Sin embargo, constituyen el verdadero punto de partida de cualquier proyecto de aprendizaje supervisado.

Elegir correctamente el tipo de problema permite seleccionar posteriormente los algoritmos, las métricas y las estrategias de evaluación más apropiadas.

En otras palabras, antes de programar una solución, es necesario comprender profundamente la naturaleza del problema.

3.3.7. Caso de estudio: Inteligencia Artificial en un hospital

Imaginemos que un hospital desea incorporar distintos modelos de Machine Learning para asistir a los profesionales de la salud.

Aunque todos pertenezcan al mismo ámbito, no necesariamente resolverán el mismo tipo de problema. Un modelo destinado a detectar la presencia de neumonía en una radiografía responderá simplemente **sí** o **no**. Se trata de un problema de clasificación binaria.

Otro sistema puede analizar imágenes dermatológicas para identificar diferentes enfermedades de la piel. En este caso el algoritmo deberá elegir entre numerosas patologías posibles, por lo que estaremos frente a un problema de clasificación multiclase.

Finalmente, un tercer modelo podría analizar la historia clínica completa de un paciente e identificar simultáneamente diversas enfermedades crónicas presentes en el mismo individuo.

Aquí un mismo paciente puede recibir varias etiquetas al mismo tiempo, convirtiéndose en un ejemplo de clasificación multi etiqueta.

Observemos que el dominio de aplicación continúa siendo exactamente el mismo. Lo único que cambia es la naturaleza de la respuesta esperada, y ese pequeño cambio modifica completamente el enfoque del problema.

3.4. ¿Cómo decide un algoritmo? La idea de una frontera de decisión

Hasta este momento hemos aprendido que un modelo de aprendizaje supervisado recibe información sobre un problema y, a partir de esa información, intenta determinar cuál es la respuesta más probable.

En algunos casos esa respuesta será una categoría, como ocurre cuando un algoritmo decide si un correo electrónico corresponde a spam o si una operación bancaria puede considerarse fraudulenta. En otros casos el resultado será un valor numérico, como sucede al estimar el precio de una vivienda o la temperatura del día siguiente.

Sin embargo, todavía no hemos respondido una pregunta esencial.

¿Cómo decide el algoritmo cuál es la respuesta correcta?

Muchas personas imaginan que el modelo analiza cada variable por separado y aplica una especie de razonamiento lógico parecido al de un ser humano.

La realidad es bastante diferente.

Aunque cada algoritmo utiliza procedimientos matemáticos propios, prácticamente todos comparten una misma idea general. Intentan encontrar una forma de **separar los ejemplos que pertenecen a grupos diferentes**.

Esa separación recibe el nombre de **frontera de decisión** (*decision boundary*).

La frontera de decisión no es un objeto físico, no existe dentro de la computadora como una línea dibujada sobre una pantalla es una representación matemática que divide el espacio de los datos en regiones diferentes, cada región corresponde a una decisión distinta cuando un nuevo ejemplo aparece, el algoritmo simplemente determina en qué lado de esa frontera se encuentra dependiendo de la región donde quede ubicado, asignará una categoría u otra. Aunque esta explicación resulte abstracta, veremos que puede entenderse fácilmente mediante algunos ejemplos.

3.4.1. Un ejemplo muy simple

Imaginemos que deseamos construir un modelo extremadamente sencillo para decidir si un estudiante probablemente aprobará una materia. Para simplificar el problema utilizaremos únicamente dos variables.

- Horas de estudio por semana.

- Porcentaje de asistencia a clase.

Representemos ahora cada estudiante como un punto dentro de un plano, en el eje horizontal colocaremos las horas de estudio y en el eje vertical representaremos el porcentaje de asistencia. Cada estudiante ocupará una posición diferente dependiendo de sus características. Después de observar muchos casos históricos comenzaremos a notar algo interesante. Los estudiantes que finalmente aprobaron tienden a concentrarse en una determinada zona del gráfico. Quienes desaprobaron aparecen mayoritariamente en otra región. Naturalmente existirán excepciones. Habrá estudiantes que estudiaron poco y aprobaron, otros habrán asistido siempre a clase, pero igualmente desaprobaron. Sin embargo, la tendencia general comienza a hacerse visible.

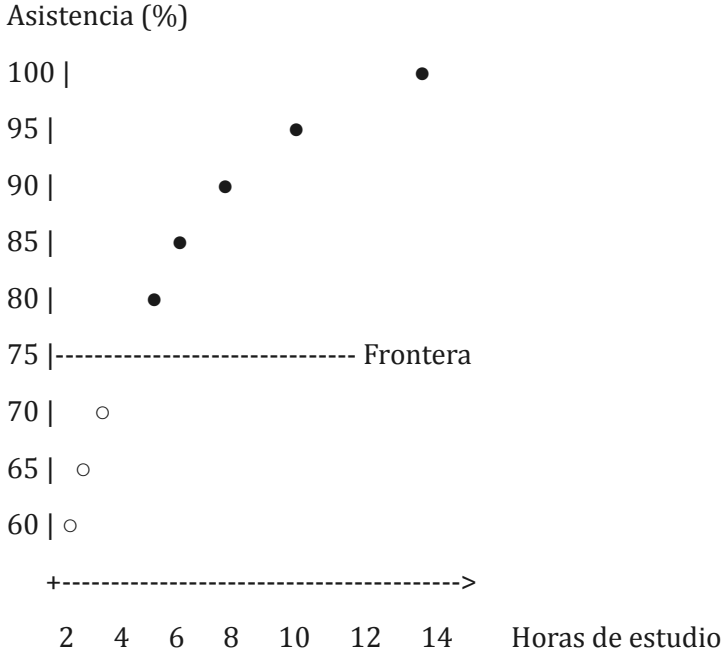
El trabajo del algoritmo consiste precisamente en encontrar una frontera que separe, de la mejor manera posible, ambos grupos.

- Podría tratarse de una línea recta.
- Podría ser una curva.
- Incluso podría adoptar formas extremadamente complejas.

Todo dependerá del algoritmo utilizado y de la naturaleza del problema. Lo importante es comprender que el objetivo no consiste en memorizar la posición de cada estudiante, sino en descubrir una regla general que permita clasificar correctamente casos nuevos.

3.4.2. Un dibujo vale más que muchas definiciones

El siguiente esquema representa una situación muy simplificada.



En este ejemplo, los círculos negros representan estudiantes que aprobaron y los círculos blancos corresponden a quienes desaprobaron.

La línea horizontal simboliza una posible frontera de decisión, cuando un nuevo estudiante ingrese al sistema, el algoritmo observará su posición respecto de esa frontera, si queda dentro de la región donde históricamente predominan los estudiantes aprobados, la predicción será "Aprobó", si aparece en la región opuesta, el modelo responderá "No aprobó".

Naturalmente, los algoritmos reales trabajan con decenas, cientos o incluso miles de variables simultáneamente. En esas condiciones ya no resulta posible dibujar el problema sobre una hoja de papel. Sin embargo, la idea continúa siendo exactamente la misma. Buscar una frontera que separe adecuadamente los diferentes grupos.

3.4.3. Cuando la frontera no puede ser una línea recta

Hasta ahora la frontera parecía muy simple. Sin embargo, la realidad rara vez resulta tan ordenada.

Supongamos ahora que deseamos clasificar frutas únicamente utilizando dos variables:

- Peso.
- Diámetro.

Después de representar cientos de ejemplos observamos que las naranjas forman un grupo aproximadamente circular. Las manzanas rodean parcialmente ese grupo. En esta situación una línea recta ya no alcanza para separar correctamente ambas categorías, el algoritmo necesitará construir una frontera curva. Esto explica por qué algunos modelos poseen un desempeño excelente en determinados problemas y resultados mucho más modestos en otros.

No todos los algoritmos son capaces de construir fronteras igualmente complejas. Algunos únicamente generan divisiones lineales, otros permiten superficies curvas.

Las redes neuronales modernas incluso pueden representar fronteras extremadamente irregulares capaces de adaptarse a problemas de enorme complejidad.

Comprender esta idea permitirá entender más adelante por qué existen tantos algoritmos diferentes dentro del aprendizaje supervisado.

Todos intentan resolver el mismo problema. Lo que cambia es la manera en que construyen esa frontera.

3.4.4. ¿Por qué dos algoritmos producen resultados diferentes?

Supongamos que entrenamos dos modelos distintos utilizando exactamente los mismos datos.

Por ejemplo, una regresión logística y un árbol de decisión, sorprendentemente, ambos producen resultados diferentes.

¿Quién tiene razón?

La respuesta es que ninguno intenta construir exactamente la misma representación del problema.

Cada algoritmo utiliza una estrategia distinta para encontrar la frontera que mejor separa los datos, algunos buscan fronteras simples que permitan generalizar mejor, otros aceptan fronteras mucho más complejas con el objetivo de adaptarse al máximo a los datos de entrenamiento.

Precisamente aquí reaparecen los conceptos estudiados en la clase anterior.

Una frontera excesivamente simple puede producir **underfitting**, porque no logra capturar adecuadamente las relaciones presentes en los datos, por el contrario, una frontera demasiado compleja puede adaptarse incluso al ruido y generar **overfitting**, perdiendo capacidad para generalizar frente a información nueva.

Observemos cómo los conceptos comienzan a conectarse entre sí.

Ya no aparecen como definiciones aisladas. Forman parte de un único modelo conceptual.

3.4.5. Un ejemplo aplicado a un laboratorio clínico

Supongamos que un laboratorio desea desarrollar un sistema para asistir en la detección de diabetes utilizando distintos análisis bioquímicos.

Cada paciente queda representado mediante variables como glucemia en ayunas, hemoglobina glicosilada, índice de masa corporal, edad y antecedentes familiares. Durante el entrenamiento, el algoritmo observa miles de pacientes cuyo diagnóstico ya fue confirmado.

Al analizar esa información descubre que las personas con diabetes tienden a concentrarse en determinadas regiones del espacio de datos, mientras que los pacientes sanos aparecen mayoritariamente en otras. La frontera de decisión representa precisamente el límite matemático que separa ambas regiones. Cuando un nuevo paciente llega al laboratorio, el sistema no compara su caso con uno o dos pacientes anteriores. Lo ubica dentro de ese espacio construido durante el entrenamiento y determina de qué lado de la frontera se encuentra.

Si aparece dentro de la región asociada históricamente a pacientes diabéticos, el modelo asignará una alta probabilidad de que el nuevo caso pertenezca a esa categoría. Es importante remarcar nuevamente que el algoritmo no realiza un diagnóstico médico. Su función consiste en identificar patrones estadísticos similares a los observados previamente. La decisión clínica continúa siendo responsabilidad del profesional de la salud.

Aunque todavía no conozcamos árboles de decisión, máquinas de soporte vectorial, redes neuronales o modelos de vecinos más cercanos, todos ellos pueden entenderse a partir de una misma pregunta:

> ***¿Cómo construye este algoritmo su frontera de decisión?***

A medida que avancemos veremos que cada algoritmo responde esta pregunta de una manera distinta.

- Algunos lo hacen mediante líneas rectas.
- Otros utilizan regiones rectangulares.
- Otros generan superficies curvas extremadamente complejas.

Sin embargo, todos persiguen exactamente el mismo objetivo: **separar los datos de manera que los ejemplos pertenecientes a una misma categoría queden agrupados y sea posible clasificar correctamente casos que nunca fueron vistos durante el entrenamiento**.

3.4.6. Para discutir

> *Una universidad desarrolló un modelo para predecir si un estudiante aprobará una materia utilizando únicamente dos variables: porcentaje de asistencia y cantidad de horas de estudio semanales. Sin embargo, el modelo comete muchos errores. ¿Significa necesariamente que el algoritmo es malo? ¿Qué otras variables podrían influir en el resultado y ayudar a construir una mejor frontera de decisión?*

3.5. Las variables (*Features*): el verdadero lenguaje con el que aprende un algoritmo

Hasta este momento hemos analizado numerosos ejemplos de aprendizaje supervisado. Hemos visto modelos capaces de detectar enfermedades, clasificar correos electrónicos, estimar el precio de una vivienda o predecir el rendimiento académico de un estudiante. Aunque estos problemas pertenecen a ámbitos completamente diferentes, todos comparten una característica fundamental. En ningún caso el algoritmo observa directamente la realidad.

- Nunca "ve" al estudiante como una persona.
- No comprende qué es una vivienda.
- No sabe qué significa una enfermedad.
- No entiende el concepto de correo electrónico.

Todo lo que recibe son números, categorías o valores almacenados dentro de una base de datos. Esta observación puede parecer evidente, pero constituye uno de los principios fundamentales del Machine Learning. Para un algoritmo, el mundo está formado exclusivamente por información y esa información llega organizada mediante un conjunto de variables que describen cada ejemplo.

Estas variables reciben el nombre de **características** o, utilizando el término más difundido internacionalmente, **features**.

Las *features* representan la única forma que posee un modelo para conocer el problema que intenta resolver. Si las variables describen adecuadamente la realidad, el algoritmo tendrá posibilidades de aprender patrones útiles.

Si las variables resultan incompletas, ambiguas o poco representativas, ningún algoritmo será capaz de producir buenos resultados, por más sofisticado que sea. Esta idea puede resumirse mediante una frase muy utilizada en Ciencia de Datos:

> ***Un modelo nunca puede aprender información que no está presente en sus variables.***

3.5.1. Cómo "ve" una computadora a un estudiante

Pensemos nuevamente en un estudiante universitario. Para nosotros, una persona posee innumerables características.

- motivaciones.
- Experiencias previas.
- Dificultades personales.
- Hábitos de estudio.
- Intereses.
- Capacidad de concentración.

Sin embargo, la computadora no puede trabajar directamente con conceptos tan abstractos. Necesita que toda esa información sea transformada en variables concretas.

Por ejemplo:Para el algoritmo, ese estudiante deja de ser una persona. Pasa a convertirse en un conjunto ordenado de valores.

Variable	Valor
Edad	21
Horas de estudio semanales	12
Asistencia	94 %
Trabajos prácticos entregados	8
Promedio anterior	7,8

- No existe nada más.
- No conoce su historia.
- No conoce sus emociones.
- No conoce sus expectativas.

Toda la información disponible está contenida en esas variables. Cuando decimos que un modelo "aprende", en realidad estamos diciendo que descubre relaciones matemáticas entre esas variables y la respuesta que intentamos predecir.

3.5.2. Un ejemplo en un laboratorio clínico

Supongamos ahora que queremos construir un modelo capaz de detectar pacientes con riesgo de diabetes.

Un bioquímico experimentado puede observar numerosos aspectos clínicos simultáneamente. Sin embargo, el algoritmo solamente trabajará con la información que nosotros decidamos registrar.

Por ejemplo:

Variable	Valor
Edad	58
Índice de masa corporal	31,2
Glucemia en ayunas	145 mg/dL
Hemoglobina glicosilada	7,3 %
Antecedentes familiares	Sí

Cada una de estas columnas constituye una *feature*.

Durante el entrenamiento, el modelo intentará descubrir qué combinación de esas variables aparece con mayor frecuencia en pacientes cuyo diagnóstico fue confirmado como diabetes. Observemos nuevamente un aspecto muy importante.

- El algoritmo no sabe qué significa "glucemia".
- No comprende la fisiología humana.
- No conoce el metabolismo de la glucosa.

Simplemente detecta patrones estadísticos. Descubre que determinadas combinaciones de valores suelen aparecer asociadas a pacientes pertenecientes a una determinada categoría. Por

esta razón, el conocimiento médico continúa siendo indispensable. El especialista decide qué variables poseen significado clínico. El algoritmo únicamente aprende relaciones entre ellas.

3.5.3. No todas las variables aportan la misma información

Hasta ahora podría parecer que cuantas más variables utilicemos, mejores serán los resultados obtenidos.

Después de todo, si cada variable aporta información adicional, parecería lógico pensar que agregar nuevas columnas siempre mejora el aprendizaje.

Sin embargo, esta intuición no siempre resulta correcta.

Imaginemos que deseamos predecir si un estudiante aprobará una materia. Seleccionamos las siguientes variables:

- Horas de estudio.
- Asistencia.
- Promedio anterior.
- Cantidad de trabajos prácticos entregados.

Hasta aquí todas parecen razonables.

Ahora agregamos otras columnas.

- Color favorito.
- Número de calzado.
- Mes de nacimiento.
- Marca del teléfono celular.

¿Realmente esperamos que estas nuevas variables ayuden a predecir el rendimiento académico?

Probablemente no.

Aunque contienen información sobre el estudiante, difícilmente guarden una relación significativa con la aprobación de la materia. El algoritmo intentará analizarlas igualmente.

No posee sentido común para decidir cuáles variables resultan importantes y cuáles no. Si nosotros las incorporamos al conjunto de datos, el modelo asumirá que podrían contener información relevante. En consecuencia, parte del entrenamiento se dedicará a intentar encontrar relaciones donde probablemente no existan.

Esto puede aumentar innecesariamente la complejidad del modelo e incluso perjudicar su capacidad para generalizar. Por esta razón, la selección adecuada de variables constituye una de las tareas más importantes dentro de cualquier proyecto de Ciencia de Datos.

No se trata simplemente de acumular información. Se trata de elegir aquella información que realmente describe el fenómeno que deseamos estudiar.

3.5.4. Una analogía con una investigación policial

Imaginemos que un grupo de investigadores intenta resolver un caso policial. Durante la investigación recopilan cientos de datos. Algunos resultan claramente importantes:

- Las huellas digitales.
- Las grabaciones de cámaras de seguridad.
- El horario del hecho.
- Los registros telefónicos.

Sin embargo, también aparecen numerosos datos irrelevantes.

- El color de las paredes del edificio.
- La marca del café que tomó un testigo esa mañana.
- La cantidad de árboles existentes en la cuadra.

Aunque toda esa información pertenece al mismo contexto, no toda contribuye a resolver el caso.

Un investigador experimentado aprende rápidamente a distinguir entre evidencia relevante y datos circunstanciales.

En Machine Learning ocurre exactamente lo mismo.

Las variables representan la evidencia con la que trabajará el algoritmo. Si elegimos cuidadosamente aquellas que realmente describen el problema, aumentarán considerablemente las posibilidades de construir un buen modelo. Si incorporamos información irrelevante, solamente estaremos introduciendo ruido que dificultará el aprendizaje.

3.5.5. Variables observables y variables derivadas

En muchos proyectos, las mejores variables ni siquiera existen inicialmente dentro de la base de datos. Es necesario construirlas.

Supongamos que una empresa desea predecir si un cliente abandonará un servicio de suscripción. La base contiene información como:

- Fecha de alta.

- Cantidad de compras.
- Fecha de la última compra.

Individualmente, estas columnas poseen cierta utilidad. Sin embargo, un analista puede crear nuevas variables mucho más informativas.

Por ejemplo:

- Antigüedad como cliente.
- Días transcurridos desde la última compra.
- Promedio mensual de compras.
- Frecuencia de utilización del servicio.

Estas nuevas variables reciben el nombre de **variables derivadas** o **variables construidas**, porque no estaban presentes originalmente en la información disponible. Su creación forma parte de una disciplina muy importante denominada **Ingeniería de Características** (*Feature Engineering*), que estudia cómo transformar los datos originales para facilitar el aprendizaje de los algoritmos.

Aunque profundizaremos este tema más adelante, conviene introducirlo desde ahora porque explica por qué dos equipos distintos pueden obtener resultados completamente diferentes utilizando exactamente el mismo conjunto de datos.

Muchas veces la diferencia no está en el algoritmo. Está en la calidad de las variables construidas.

3.5.6. El algoritmo aprende únicamente aquello que puede medir

> ***Si una característica importante no fue medida, para el algoritmo simplemente no existe.***

Volvamos al ejemplo del rendimiento académico.

Supongamos que el principal factor que explica la aprobación de una materia es la motivación personal del estudiante. Sin embargo, esa variable nunca fue registrada, el algoritmo jamás podrá descubrir su influencia. No porque el modelo sea malo, sino porque trabaja exclusivamente con la información disponible.

Esta idea explica por qué la construcción de un conjunto de datos constituye una tarea profundamente interdisciplinaria. El informático comprende cómo entrenar modelos. El especialista del dominio comprende qué variables describen realmente el fenómeno. Cuando ambos conocimientos se combinan, aumentan considerablemente las posibilidades de construir sistemas útiles.

3.5.7. Caso de estudio: Predicción de fallas en una planta industrial

Imaginemos una fábrica equipada con motores eléctricos que funcionan las veinticuatro horas del día. La empresa desea desarrollar un modelo capaz de anticipar fallas antes de que ocurran, evitando paradas inesperadas de la producción.

Inicialmente se recopilan algunas variables básicas, como la identificación del motor y la fecha de instalación. Sin embargo, los ingenieros advierten rápidamente que esa información resulta insuficiente para describir el estado real del equipo.

Deciden entonces incorporar sensores que registran temperatura, vibraciones, consumo de corriente, presión, velocidad de rotación y horas acumuladas de funcionamiento.

Estas nuevas variables contienen información directamente relacionada con el desgaste mecánico de los motores. Gracias a ellas, el algoritmo comienza a identificar patrones que suelen aparecer días antes de una avería.

Observemos que el éxito del proyecto no depende únicamente del algoritmo seleccionado. Depende, en gran medida, de haber elegido variables capaces de representar correctamente el comportamiento físico del sistema. En otras palabras, el modelo no "aprendió sobre motores". Aprendió sobre las mediciones que describen su funcionamiento.

3.5.8. Para debatir

Una empresa desea construir un modelo para predecir si un empleado abandonará la organización durante el próximo año.

Entre las posibles variables se encuentran:

- Edad.
- Antigüedad en la empresa.
- Cantidad de capacitaciones realizadas.
- Distancia entre el domicilio y el lugar de trabajo.
- Salario.
- Departamento al que pertenece.
- Color favorito.
- Marca del automóvil.
- Cantidad de reuniones semanales.
- Nivel de satisfacción laboral.

¿Cuáles de estas variables parecen aportar información relevante para el problema? ¿Cuáles podrían introducir ruido innecesario? ¿Existen otras variables que sería conveniente incorporar?

3.6. Las variables no son todas iguales: comprendiendo los tipos de datos

En la sección anterior aprendimos que las variables constituyen el lenguaje mediante el cual un algoritmo observa la realidad. También vimos que un modelo solamente puede aprender a partir de la información contenida en esas variables y que la selección adecuada de las mismas resulta mucho más importante de lo que habitualmente imaginamos.

Sin embargo, todavía existe un aspecto fundamental que debemos analizar.

Aunque todas las variables describen alguna característica del problema, **no todas representan el mismo tipo de información**.

- Algunas expresan cantidades que pueden medirse numéricamente.
- Otras describen categorías.
- Algunas poseen un orden natural.
- Otras simplemente identifican grupos sin que exista ninguna jerarquía entre ellos.

Esta diferencia puede parecer un detalle menor, pero tiene enormes consecuencias durante el entrenamiento de un modelo.

Un algoritmo no interpreta de la misma manera una temperatura corporal que un grupo sanguíneo. Tampoco procesa igual una edad que el nombre de una ciudad. Para comprender por qué ocurre esto, debemos comenzar clasificando las variables según la naturaleza de la información que contienen.

3.6.1. Variables numéricas: cuando la información puede medirse

Las variables numéricas representan cantidades que pueden expresarse mediante valores matemáticos. Generalmente corresponden a mediciones, conteos o magnitudes físicas. Cuando observamos una variable numérica resulta natural realizar operaciones matemáticas con ella.

- Podemos sumar.
- Podemos calcular promedios.
- Podemos obtener diferencias.
- Podemos construir gráficos.

- Podemos estimar tendencias.

Todo esto resulta posible porque el valor posee un significado cuantitativo. Pensemos en algunos ejemplos.

En un laboratorio clínico encontramos variables como:

- Concentración de glucosa en sangre.
- Nivel de colesterol.
- Temperatura corporal.
- Peso del paciente.
- Edad.

Todas ellas representan cantidades medibles.

- Tiene sentido afirmar que una persona pesa más que otra.
- También podemos calcular el promedio de edad de un grupo de pacientes.

En una empresa industrial aparecen otras variables numéricas.

- La temperatura de un horno.
- La velocidad de rotación de un motor.
- La presión dentro de una tubería.
- El consumo eléctrico.
- La cantidad de piezas fabricadas durante un turno.

Todas estas mediciones permiten realizar cálculos matemáticos y describen fenómenos continuos del mundo físico. Sin embargo, incluso dentro de las variables numéricas existen diferencias importantes.

3.6.2. Variables continuas

Una variable continua puede asumir prácticamente cualquier valor dentro de un intervalo. No se encuentra limitada únicamente a números enteros.

Pensemos en la temperatura corporal.

Una persona puede presentar:

36,2 °C

36,8 °C

37,15 °C

37,153 °C

Siempre resulta posible aumentar la precisión de la medición.

Lo mismo ocurre con:

- Peso.
- Altura.
- Tiempo.
- Presión.
- Voltaje.
- Concentración de una sustancia.

En todos estos casos no existen "saltos" naturales entre un valor y otro.

Las posibilidades forman un continuo.

Las variables continuas aparecen con enorme frecuencia en Ingeniería porque gran parte de los procesos físicos se describen precisamente mediante magnitudes continuas.

3.6.3. Un ejemplo real

Supongamos que un laboratorio desea predecir el tiempo necesario para completar un análisis automatizado.

Entre las variables disponibles encontramos:

Variable	Valor
Cantidad de muestras	38
Temperatura ambiente	23,6 °C
Tiempo promedio por muestra	1,85 minutos
Tiempo total	70,3 minutos

Observemos que tanto la temperatura como el tiempo pueden adoptar una enorme cantidad de valores posibles. No tendría sentido limitar estas variables únicamente a números enteros. Precisamente por ello las consideramos continuas.

3.6.4. Variables discretas

A diferencia de las variables continuas, las variables discretas representan cantidades obtenidas mediante conteo.

En estos casos solamente determinados valores tienen sentido.

Pensemos en la cantidad de hijos de una persona.

Podemos tener:

0 1 2 3 4

Pero difícilmente alguien tenga 2,7 hijos.

Lo mismo ocurre con:

- Cantidad de alumnos presentes en una clase.
- Número de computadoras de un laboratorio.
- Cantidad de pedidos realizados durante un día.
- Número de vehículos que atraviesan un peaje.
- Cantidad de errores encontrados durante una prueba de software.

Todas estas variables representan conteos. Por esa razón adoptan valores enteros. Aunque continúan siendo variables numéricas, su naturaleza resulta diferente de la observada en una medición física.

3.6.5. Una diferencia importante

Muchos modelos matemáticos realizan supuestos acerca de la distribución de los datos. Otros algoritmos calculan probabilidades de manera diferente dependiendo del tipo de variable analizada. Incluso durante la visualización de la información elegiremos gráficos distintos para representar una variable continua o una discreta. Comprender esta diferencia permitirá interpretar correctamente los resultados obtenidos durante el análisis exploratorio de datos que realizaremos en las próximas clases prácticas.

3.6.6. Variables categóricas: cuando el número deja de tener sentido

Hasta ahora todas las variables podían interpretarse mediante operaciones matemáticas. Sin embargo, numerosos problemas contienen información completamente diferente.

Supongamos que una base de datos almacena el grupo sanguíneo de cada paciente.

Los posibles valores son:

A

B

AB

O

Aquí desaparece completamente la idea de cantidad. No tiene sentido afirmar que el grupo A "vale menos" que el grupo AB. Tampoco podemos calcular un promedio entre ambos. Simplemente representan categorías distintas.

Lo mismo ocurre con:

- Ciudad de residencia.
- Carrera universitaria.
- Tipo de vehículo.
- Especialidad médica.
- Sistema operativo.
- Marca de un teléfono celular.

Todas estas variables permiten clasificar los ejemplos en grupos, pero no expresan cantidades. Por esta razón reciben el nombre de **variables categóricas**.

3.6.7. Variables nominales

Dentro de las variables categóricas aparece un primer grupo muy importante.

Las variables nominales.

Una variable nominal simplemente identifica categorías diferentes. No existe ningún orden entre ellas.

Pensemos en el grupo sanguíneo.

¿Es mejor A que B?

No.

¿AB es mayor que O?

Tampoco.

Simplemente representan categorías distintas.

Otros ejemplos son:

- Nacionalidad.
- Color de ojos.

- Provincia.
- Fabricante del automóvil.
- Género musical preferido.

Todas estas categorías sirven para identificar grupos, no poseen jerarquía, no existe una secuencia lógica entre ellas.

3.6.8. Variables ordinales

Ahora imaginemos otra situación.

Una universidad realiza una encuesta de satisfacción.

Las respuestas posibles son:

- Muy malo
- Malo
- Regular
- Bueno
- Excelente

Aquí también hablamos de categorías. Sin embargo, aparece una diferencia muy importante.

Existe un orden natural.

- "Excelente" representa una valoración superior a "Bueno".
- "Bueno" expresa una valoración mayor que "Regular".

Aunque no podamos afirmar que Excelente sea exactamente el doble de Bueno, sí sabemos cuál ocupa una posición superior.

Lo mismo ocurre con:

- Nivel educativo.
- Prioridad de una tarea.
- Nivel de riesgo.
- Calificación de un servicio.
- Nivel de experiencia laboral.

Estas variables reciben el nombre de **ordinales** porque poseen un orden lógico entre sus categorías.

3.6.9. Variables binarias

Existe un caso particular que merece mencionarse por separado.

Las variables binarias.

Solamente admiten dos posibilidades.

- Sí / No
- Verdadero / Falso
- Aprobó / No aprobó
- Presente / Ausente
- Activo / Inactivo

Aunque conceptualmente constituyen un tipo particular de variable categórica, aparecen con tanta frecuencia en Machine Learning que habitualmente se estudian como una categoría independiente.

Muchas de las primeras aplicaciones del aprendizaje supervisado utilizan precisamente este tipo de variables.

3.6.10. ¿Por qué todo esto es importante para un algoritmo?

Hasta aquí podría parecer que simplemente estamos aprendiendo una clasificación teórica. Sin embargo, la razón es mucho más profunda. Los algoritmos realizan operaciones matemáticas y las matemáticas solamente tienen sentido cuando los datos representan cantidades.

Supongamos que almacenamos el sexo biológico de un paciente utilizando los números:

- Masculino = 1
- Femenino = 2

Si el algoritmo interpretara esos números literalmente podría concluir erróneamente que "2 es mayor que 1" y asignar un significado matemático inexistente.

Naturalmente, eso no representa la realidad, los números fueron utilizados únicamente como códigos para almacenar información no describen cantidades. Por esta razón, antes de entrenar muchos modelos resulta necesario transformar las variables categóricas en representaciones numéricas adecuadas.

Más adelante aprenderemos técnicas como **One-Hot Encoding**, **Label Encoding** y otros procedimientos que permiten realizar esta transformación correctamente.

Por ahora basta con comprender la idea central.

No todos los números representan cantidades. Y no todas las categorías pueden tratarse como números.

Esa distinción constituye uno de los principios más importantes del preprocesamiento de datos.

3.6.11. Caso de estudio: un conjunto de datos hospitalario

Supongamos que un hospital dispone de la siguiente información sobre sus pacientes:

Variable	Tipo
Edad	Numérica continua*
Cantidad de internaciones previas	Numérica discreta
Grupo sanguíneo	Categórica nominal
Nivel de prioridad del triage	Categórica ordinal
Requiere internación	Binaria

(*En algunos contextos la edad también puede tratarse como discreta si se registra únicamente en años completos. Lo importante es comprender que depende de cómo se mida y almacene la variable).

Observemos que todas estas columnas pertenecen al mismo paciente, sin embargo, describen tipos de información completamente diferentes. Un modelo de Machine Learning no puede analizarlas correctamente si primero no comprendemos la naturaleza de cada una de ellas. Por ese motivo, una de las primeras tareas de cualquier científico de datos consiste en inspeccionar cuidadosamente cada columna de un conjunto de datos y preguntarse:

- ¿Qué representa esta variable?
- ¿Cómo fue medida?
- ¿Qué significado tiene?
- ¿Cómo debería prepararse antes del entrenamiento?

Estas preguntas, aunque parezcan simples, suelen marcar la diferencia entre un modelo que apenas funciona y uno capaz de producir resultados realmente útiles.

3.7. Antes de entrenar un modelo: el verdadero trabajo de un científico de datos

Después de recorrer los conceptos fundamentales del aprendizaje supervisado podría parecer que ya estamos preparados para comenzar a construir modelos.

- Disponemos de un conjunto de datos.
- Conocemos las variables.
- Sabemos cuál es la respuesta que queremos predecir.

Bastaría entonces con seleccionar un algoritmo y entrenarlo, sin embargo, los proyectos reales rara vez siguen un camino tan simple, de hecho, uno de los errores más frecuentes entre quienes comienzan a estudiar Machine Learning consiste en pensar que el entrenamiento representa la etapa más importante del proceso, paradójicamente, ocurre exactamente lo contrario. En la práctica profesional, el entrenamiento suele ocupar una pequeña parte del tiempo total del proyecto. La mayor parte del esfuerzo se dedica a comprender el problema, analizar los datos, detectar errores, limpiar la información y preparar un conjunto de datos que realmente permita aprender al algoritmo. Esta diferencia explica por qué muchas organizaciones fracasan al incorporar Inteligencia Artificial. El problema no suele encontrarse en el algoritmo, generalmente aparece mucho antes, en los datos.

3.7.1. Comprender el problema antes que el algoritmo

Supongamos que una empresa se acerca a un equipo de Ciencia de Datos con la siguiente solicitud.

> *"Necesitamos una Inteligencia Artificial."*

Aunque esta frase resulta habitual, en realidad no constituye una definición del problema.

El primer trabajo del científico de datos no consiste en abrir Python, tampoco en elegir una red neuronal, mucho menos en buscar el algoritmo "más moderno". Su primera tarea consiste en hacer preguntas, muchas preguntas.

- ¿Qué desea resolver la organización?
- ¿Por qué ese problema resulta importante?
- ¿Cómo toman actualmente esa decisión?
- ¿Qué información utilizan?
- ¿Qué resultado esperan obtener?
- ¿Existe realmente información suficiente para entrenar un modelo?

Observemos que todavía no apareció ninguna línea de código y, sin embargo, ya comenzó el proyecto.

Comprender el contexto constituye probablemente la habilidad más importante que puede desarrollar un profesional dedicado al Machine Learning. Los algoritmos pueden aprender patrones. Pero únicamente las personas pueden comprender el problema de negocio que esos patrones intentan resolver.

Un ejemplo: un laboratorio de análisis clínicos

Imaginemos un laboratorio que desea utilizar Inteligencia Artificial para mejorar el proceso de validación de resultados.

En una primera reunión, el responsable del laboratorio plantea el siguiente objetivo:

"Queremos que la IA detecte automáticamente resultados anormales."

A simple vista parece un problema perfectamente definido, sin embargo, un científico de datos comenzará inmediatamente a profundizar mediante nuevas preguntas.

- ¿Qué significa exactamente "anormal"?
- ¿Se refiere únicamente a valores fuera del rango de referencia?
- ¿Existen patologías donde un resultado aparentemente normal también puede indicar un problema?
- ¿Todos los análisis poseen los mismos criterios de validación?
- ¿Quién decide actualmente si un resultado requiere revisión?
- ¿Existen registros históricos de esas decisiones?

Cada una de estas preguntas modifica profundamente el proyecto.

En muchos casos, después de varias reuniones, el problema inicial termina siendo completamente diferente del planteado originalmente. Esto demuestra que desarrollar modelos de Machine Learning no consiste solamente en trabajar con datos. También implica comprender profundamente el dominio donde esos datos fueron generados.

3.7.2. Conocer los datos

Una vez comprendido el problema comienza una nueva etapa, explorar la información disponible. Muchas personas imaginan que las bases de datos utilizadas en Inteligencia Artificial son perfectas, completas, ordenadas y sin errores, la realidad suele ser exactamente la contraria. Los conjuntos de datos reales contienen todo tipo de inconvenientes.

1. Registros incompletos.
2. Valores repetidos.

3. Errores de carga.
4. Información desactualizada.
5. Variables inconsistentes.
6. Mediciones incorrectas.
7. Incluso columnas cuyo significado nadie recuerda con precisión.

Antes de pensar en entrenar un modelo debemos responder preguntas mucho más básicas.

1. ¿Cuántos registros existen?
2. ¿Cuántas variables posee el conjunto de datos?
3. ¿Qué representa cada columna?
4. ¿Qué unidades de medida fueron utilizadas?
5. ¿Existen valores imposibles?
6. ¿Hay información faltante?

Responder estas preguntas constituye el primer paso de cualquier análisis exploratorio de datos.

Más adelante aprenderemos a realizar este proceso utilizando Pandas, por ahora nos interesa comprender su importancia conceptual.

3.7.3. Los datos faltantes

Uno de los problemas más frecuentes aparece cuando determinada información no fue registrada.

Supongamos que un hospital almacena información sobre miles de pacientes, sin embargo, observamos que la columna correspondiente al peso corporal contiene numerosos valores vacíos.

¿Por qué ocurre esto?

Tal vez algunos pacientes nunca fueron pesados, quizás el equipamiento presentó fallas o simplemente ese dato dejó de registrarse durante un determinado período. Independientemente de la causa, aparece un problema importante, el algoritmo no puede aprender correctamente utilizando información inexistente. Naturalmente, existen diversas estrategias para tratar este tipo de situaciones.

1. Podemos eliminar registros.
2. Completar valores.
3. Construir estimaciones.

4. Incluso entrenar modelos específicos para imputar datos faltantes.

No profundizaremos todavía en estas técnicas, lo importante es comprender que un científico de datos nunca ignora este problema antes de entrenar cualquier modelo verifica cuidadosamente qué información falta y por qué.

3.7.4. Los datos duplicados

Otro inconveniente habitual consiste en la existencia de registros repetidos.

Pensemos nuevamente en un laboratorio clínico.

Por un error administrativo, algunos pacientes fueron cargados dos veces dentro de la base de datos, si entrenamos el algoritmo utilizando esa información duplicada, determinados casos aparecerán con mayor frecuencia que otros, como consecuencia, el modelo podría otorgar una importancia exagerada a ejemplos que, en realidad, representan exactamente la misma situación.

Detectar registros duplicados constituye una tarea aparentemente sencilla, sin embargo, en bases de datos con millones de ejemplos puede transformarse en un desafío considerable. Por esta razón forma parte de las primeras actividades realizadas durante el análisis exploratorio.

3.7.5. Los valores imposibles

Existen errores que resultan mucho más evidentes.

Imaginemos un conjunto de datos donde aparece el siguiente paciente.

Edad:

-8 años

Claramente existe un problema o bien alguien cometió un error durante la carga de información o el sistema permitió registrar valores inválidos.

Observemos otro ejemplo.

Temperatura corporal:

142 °C

Nuevamente encontramos una situación imposible desde el punto de vista clínico.

Estos errores reciben el nombre de **valores inválidos** o **datos inconsistentes**. Aunque parezcan casos extremos, aparecen con sorprendente frecuencia en proyectos reales, el algoritmo no posee sentido común para detectarlos. Si nosotros no corregimos esa información, el modelo intentará aprender a partir de datos completamente erróneos.

3.7.6. Los valores atípicos (*Outliers*)

Existen otro tipo de situaciones mucho más interesantes.

Supongamos que registramos la estatura de mil estudiantes universitarios.

La enorme mayoría presenta valores comprendidos entre 1,55 metros y 1,95 metros, sin embargo, aparece un registro con una altura de **3,80 metros**.

¿Qué ocurrió?

Podría tratarse de un error de carga, tal vez alguien escribió incorrectamente un número, pero también existe otra posibilidad, quizás la medición sea correcta y corresponda a una persona con una condición médica extremadamente poco frecuente.

Aquí aparece un aspecto muy importante, no todos los valores extraños constituyen errores, algunos representan situaciones reales que simplemente ocurren con muy poca frecuencia. Estos casos reciben el nombre de **valores atípicos** o **outliers**.

Antes de eliminarlos debemos comprender por qué aparecen, un error debe corregirse, un caso excepcional puede contener información extremadamente valiosa.

El trabajo del científico de datos consiste precisamente en distinguir entre ambas situaciones.

3.7.7. Preparar los datos para el aprendizaje

Una vez revisada toda la información comienza la etapa de preparación. Dependiendo del problema, esta fase puede incluir numerosas actividades.

1. Transformar variables categóricas en representaciones numéricas.
2. Normalizar escalas de medición.
3. Eliminar columnas irrelevantes.
4. Construir nuevas variables derivadas.
5. Detectar inconsistencias.
6. Corregir errores.
7. Seleccionar únicamente la información verdaderamente útil para el problema.

Aunque todavía no implementaremos estas técnicas mediante código, resulta importante comprender que todas ellas tienen un mismo objetivo.

Facilitar el aprendizaje del algoritmo.

Un modelo inteligente no compensa automáticamente datos mal preparados. Al contrario, cuanto más complejo sea el algoritmo, mayor importancia adquiere la calidad de la información utilizada durante el entrenamiento.

3.7.8. Una analogía final: construir una casa

Imaginemos que una empresa desea construir un edificio.

Antes de colocar el primer ladrillo es necesario estudiar el terreno, analizar el suelo, preparar los cimientos, revisar los materiales y planificar cuidadosamente toda la obra. Ningún ingeniero comenzaría levantando paredes sin haber realizado previamente esas tareas. En Machine Learning ocurre exactamente lo mismo, el entrenamiento representa solamente una parte del proyecto. Todo el trabajo previo determina, en gran medida, la calidad del resultado final. Podemos utilizar el algoritmo más avanzado del mundo, pero si los datos contienen errores, las variables fueron mal seleccionadas o el problema nunca se comprendió correctamente, el modelo difícilmente producirá resultados confiables.

Esta idea resume uno de los principios más importantes de toda la Ciencia de Datos.

> ***Los buenos modelos comienzan mucho antes del entrenamiento. Comienzan comprendiendo el problema y preparando cuidadosamente la información.***

3.7.9. Caso de estudio: mantenimiento predictivo en una fábrica

Una planta industrial desea anticipar fallas en sus motores eléctricos mediante Machine Learning. Durante varios años ha registrado datos provenientes de sensores instalados en cada equipo: temperatura, vibración, corriente consumida, presión, velocidad de rotación y horas de funcionamiento.

Antes de entrenar cualquier modelo, el equipo de Ciencia de Datos realiza una revisión exhaustiva de la información. Descubre que algunos sensores dejaron de transmitir datos durante ciertos períodos, que existen registros duplicados debido a problemas de sincronización y que varias mediciones muestran valores físicamente imposibles como temperaturas negativas en motores que operan permanentemente por encima de los 60 °C.

Si estos problemas pasaran inadvertidos, el algoritmo aprendería patrones incorrectos y generaría predicciones poco confiables.

Después de corregir las inconsistencias, eliminar duplicados y documentar cuidadosamente cada variable, el conjunto de datos queda finalmente preparado para el entrenamiento.

Este ejemplo muestra que el éxito del proyecto no depende únicamente del algoritmo utilizado. Depende, sobre todo, de la calidad del trabajo realizado antes de ejecutar la primera línea de entrenamiento.

3.8. Integrando los conceptos: cómo pensar un problema de Machine Learning

A lo largo de esta unidad hemos recorrido numerosos conceptos que, a primera vista, podrían parecer independientes. Hemos hablado de aprendizaje supervisado, de clasificación, de regresión, de variables, de fronteras de decisión y de preparación de los datos.

Sin embargo, un ingeniero no trabaja con estos conceptos por separado, cuando enfrenta un problema real, todos ellos aparecen simultáneamente. Por ese motivo, antes de finalizar la clase, resulta conveniente reconstruir el camino completo que sigue un científico de datos desde que recibe un problema hasta que finalmente entrena un modelo. Más que memorizar definiciones, el objetivo consiste en comprender una forma de pensar.

3.8.1. Todo comienza con un problema

Ningún proyecto de Inteligencia Artificial nace preguntando qué algoritmo utilizar.

La primera pregunta siempre es otra.

¿Qué problema queremos resolver?

- Puede tratarse de un hospital que desea detectar pacientes con riesgo de desarrollar una enfermedad.
- Puede ser una empresa que intenta anticipar el abandono de clientes.
- Puede tratarse de una universidad interesada en identificar estudiantes con riesgo académico.
- O una industria que busca detectar fallas antes de que una máquina se detenga.

Observemos que, en todos los casos, el punto de partida no es la tecnología.

Es una necesidad concreta. La Inteligencia Artificial aparece como una herramienta para ayudar a resolver ese problema.

3.8.2. Comprender el dominio

Una vez identificado el problema, el siguiente paso consiste en comprender el contexto donde ocurre.

- Si trabajamos con información médica necesitaremos comprender conceptos básicos de medicina.
- Si analizamos procesos industriales deberemos conocer cómo funcionan las máquinas.

- Si estudiamos datos financieros necesitaremos entender el significado de las variables económicas.

Esta etapa resulta fundamental porque los algoritmos no poseen conocimiento del dominio. Quienes deben comprender el problema son las personas que diseñan el proyecto. Por esta razón, la Ciencia de Datos constituye una disciplina profundamente interdisciplinaria, no alcanza con saber programar, tampoco basta con conocer matemáticas es necesario comprender el fenómeno que se desea modelar.

3.8.3. Formular correctamente la pregunta

Cuando ya conocemos el problema aparece una nueva decisión.

¿Qué queremos predecir?

Esta pregunta determina inmediatamente el tipo de aprendizaje supervisado que utilizaremos.

- Si buscamos estimar una cantidad numérica, estaremos frente a un problema de regresión.
- Si deseamos asignar una categoría, estaremos resolviendo un problema de clasificación.

Aunque parezca una decisión sencilla, representa uno de los pasos más importantes de todo el proyecto. Una pregunta mal formulada conduce inevitablemente a un modelo poco útil.

3.8.4. Elegir las variables adecuadas

Definido el problema, debemos decidir qué información utilizaremos para describir cada ejemplo.

En otras palabras, debemos seleccionar las *features*.

Aquí reaparece una de las ideas centrales desarrolladas durante esta clase, el algoritmo no aprende observando la realidad, aprende observando variables.

Si una característica importante nunca fue registrada, para el modelo simplemente no existe. Por esta razón, la selección de variables constituye una tarea tan importante como la elección del algoritmo. En numerosos proyectos, la diferencia entre un modelo mediocre y uno excelente no se encuentra en la técnica utilizada, sino en la calidad de las variables elegidas.

3.8.5. Analizar la calidad de los datos

Una vez seleccionadas las variables todavía no estamos listos para entrenar.

Antes debemos verificar cuidadosamente la información disponible.

1. ¿Existen datos faltantes?
2. ¿Hay registros duplicados?

3. ¿Aparecen valores imposibles?

4. ¿Las mediciones fueron realizadas correctamente?

5. ¿Las variables representan realmente aquello que creemos?

Responder estas preguntas permite construir un conjunto de datos confiable y un modelo solamente puede ser tan bueno como los datos con los que fue entrenado.

3.8.6. Recién ahora aparece el algoritmo

Resulta interesante observar cuánto recorrido hemos realizado sin mencionar ningún algoritmo específico y esto no es casualidad, en la práctica profesional, el entrenamiento representa únicamente una parte del proyecto. Cuando finalmente llegamos a este punto, el científico de datos ya comprende el problema, conoce las variables, revisó la calidad de la información y preparó cuidadosamente el conjunto de datos.

Recién entonces selecciona el algoritmo más apropiado.

- Podrá utilizar una regresión lineal.
- Un árbol de decisión.
- Un modelo de vecinos más cercanos.
- Una máquina de soporte vectorial.
- O una red neuronal.

La elección dependerá del problema que intenta resolver y de las características de los datos disponibles.

3.8.7. Un ejemplo integrador

Imaginemos que una empresa de transporte urbano desea reducir los retrasos de sus unidades. El objetivo consiste en predecir si un colectivo llegará con demora a una parada determinada.

Veamos cómo aplicaríamos todo lo aprendido durante esta clase.

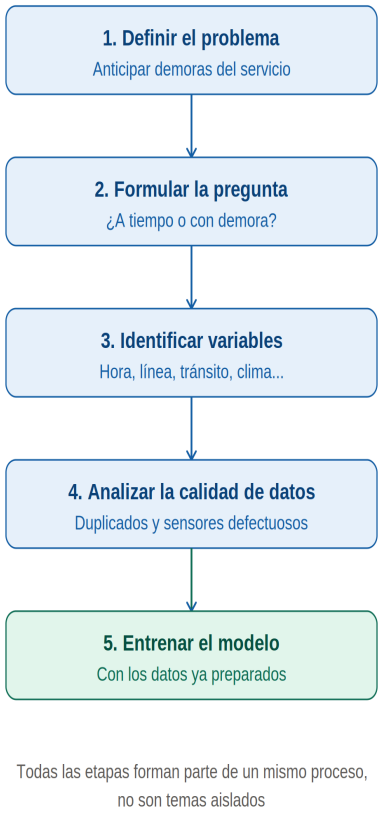


Figura 3.1 — Ejemplo integrador: predicción de demoras en el transporte urbano.

Observemos cómo todos los conceptos estudiados durante la clase aparecen naturalmente dentro del mismo proyecto.

3.8.8. Una nueva forma de pensar

Si tuviéramos que resumir toda la unidad en una única idea, probablemente sería la siguiente.

El Machine Learning no consiste en elegir algoritmos. Consiste en aprender a formular problemas utilizando datos.

- Los algoritmos son herramientas.
- Las variables representan la información.
- Los datos constituyen la evidencia.
- El conocimiento del dominio permite interpretar correctamente esa evidencia.

- Y el entrenamiento transforma toda esa información en un modelo capaz de realizar predicciones sobre situaciones nuevas.

Cuando comprendemos este proceso completo dejamos de pensar como programadores que utilizan librerías y comenzamos a pensar como científicos de datos. Ese será, precisamente, el objetivo del resto de la asignatura.

Antes de continuar con el siguiente tema, conviene detenerse unos minutos y responder mentalmente las siguientes preguntas.

- ¿Cuál es la diferencia entre un problema de clasificación y uno de regresión?
- ¿Por qué un algoritmo solamente puede aprender a partir de las variables disponibles?
- ¿Qué consecuencias puede tener entrenar un modelo utilizando datos incorrectos o incompletos?
- ¿Por qué la comprensión del problema resulta tan importante como la elección del algoritmo?
- ¿Qué significa realmente "entrenar" un modelo?

3.9. Del concepto al primer algoritmo

Hasta este momento hemos trabajado principalmente sobre ideas.

- Aprendimos qué significa aprender a partir de los datos.
- Comprendimos cómo se representan los problemas mediante variables.
- Descubrimos que un modelo intenta encontrar patrones capaces de generalizar hacia situaciones nuevas.
- También vimos que la calidad de las variables y de los datos resulta determinante para el éxito de cualquier proyecto de Inteligencia Artificial.

Sin embargo, todavía no hemos visto **cómo realiza matemáticamente un algoritmo ese aprendizaje**, ha llegado el momento de responder esa pregunta.

En la próxima unidad dejaremos de hablar de Machine Learning de forma conceptual para comenzar a estudiar el primer algoritmo de aprendizaje supervisado: **la Regresión Lineal**.

A primera vista podría parecer una técnica sencilla e incluso limitada frente a modelos modernos como las redes neuronales profundas. Sin embargo, la Regresión Lineal ocupa un lugar privilegiado dentro de la Ciencia de Datos por una razón muy importante: permite comprender, con claridad, los principios matemáticos que luego aparecerán en algoritmos mucho más complejos.

Será la primera vez que veremos cómo un modelo utiliza datos históricos para construir una función matemática capaz de realizar predicciones.

Aprenderemos qué significa ajustar un modelo, cómo se calcula el error, por qué una recta puede representar un conjunto de datos y cuáles son las limitaciones de este enfoque.

Más importante aún, comenzaremos a escribir nuestras primeras líneas de código utilizando Python y Scikit-Learn para entrenar un modelo real.